Datalake de uso — evidências

SolarVision · branch `feat/datalake-uso` · pipeline rodando no console do datalake (S3 · Glue · Athena) sobre o floci, em Docker · 22/10/2026

Aplicação do projeto-modelo de engenharia de dados ao uso da plataforma SolarVision. Os 8 jobs rodaram pelo workflow `medalhao` do console, a partir de camadas vazias (Bronze, Silver e Gold apagadas antes), sobre a landing do gerador (seed 42, 3.000 usuários, 28 dias, 3% de sujeira).

Requisitos e onde está a prova

Req.	O que pede	Prova
R1	PySpark lendo `landing/` e gravando Parquet por `s3a://`, sem boto3	prints 3–7, 9–14
R2	Um job por camada; sem a camada anterior, para com "Rode antes: ..."	prints 2, 30
R3	Script/sequência que roda os 8 jobs	print 1 (workflow) e `pipeline/rodar_tudo.py`
R4	Bronze append-only, schema explícito, partições, proveniência	prints 7, 10–12, 16, 19
R5–R10	Dedup, params tipados, rejeitados com motivo, sessões, stitching, itens	prints 4, 13, 17, 20–22
5.3	15 tabelas Gold, ML sem vazamento	prints 5, 14, 18, 23–26
R11	Mapa de calor exportado e aceso no app	prints 6, 26–29

Resultado

Camada	Linhas	event_id distintos	Conferência
landing	57.094	—	21 valores de `event_name` (20 do contrato + `share_report`, fora do catálogo)
bronze	57.094	56.520	= landing em todos os 21 eventos
silver (válidos)	54.789	54.789	6.450 sessões · 2.997 pessoas
silver (rejeitados)	1.731	1.731	54.789 + 1.731 = 56.520; 574 duplicatas descartadas
silver (itens)	11.040	6.530	uma linha por placa por evento
gold	15 tabelas	—	funil, engajamento, aquisição/retenção, ML (AUC 0,972) e mapa de calor

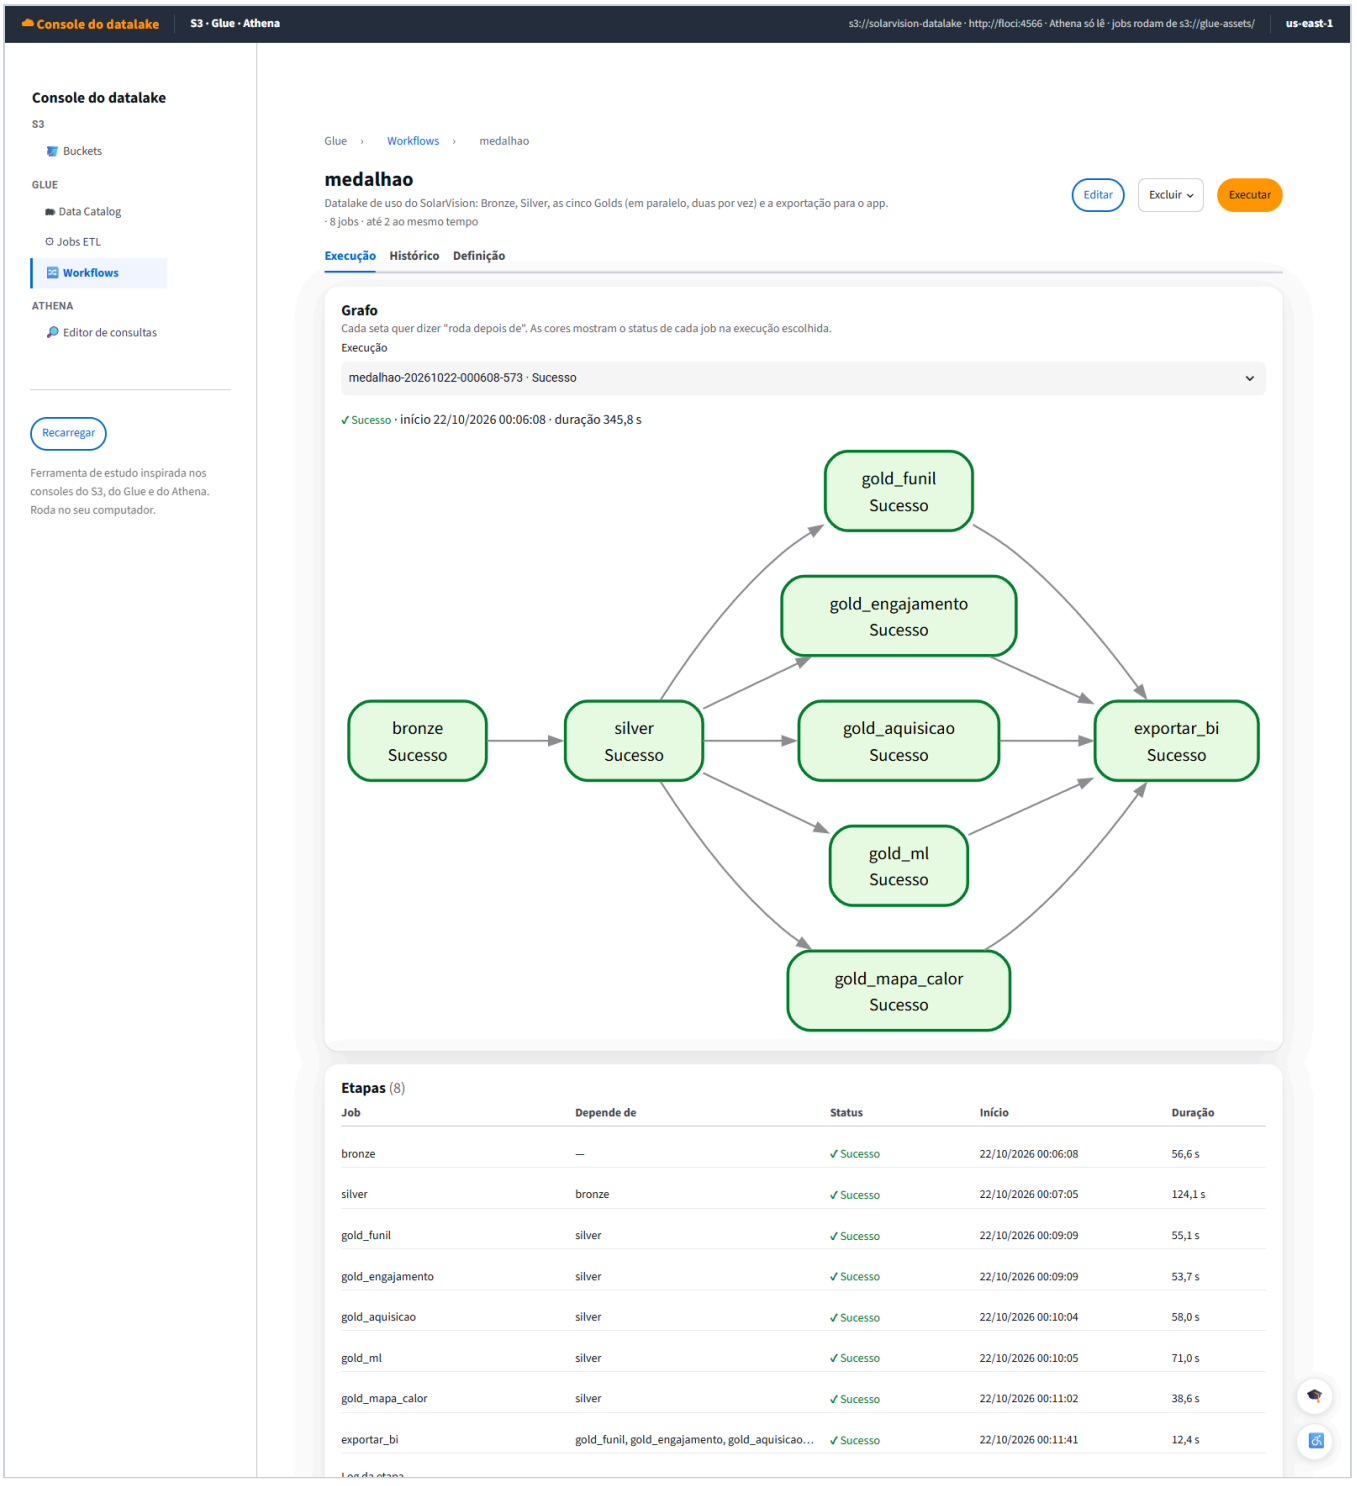
Testes: `docker compose run --rm app pytest` → 304 passed (gerador, coletor, jobs, comum e explorador).

CSVs exportados pelo botão "Baixar resultados (CSV)" do Athena, em `datalake/evidencias/`: `landing_x_bronze.csv`, `bronze_x_silver.csv`, `rejeitados_por_motivo.csv`, `sessoes_e_stitching.csv`, `gold_funil_ativacao.csv`, `gold_retencao_d7.csv`, `gold_metricas_modelo.csv`, `gold_mapa_calor_home.csv`.

A. Execução no console

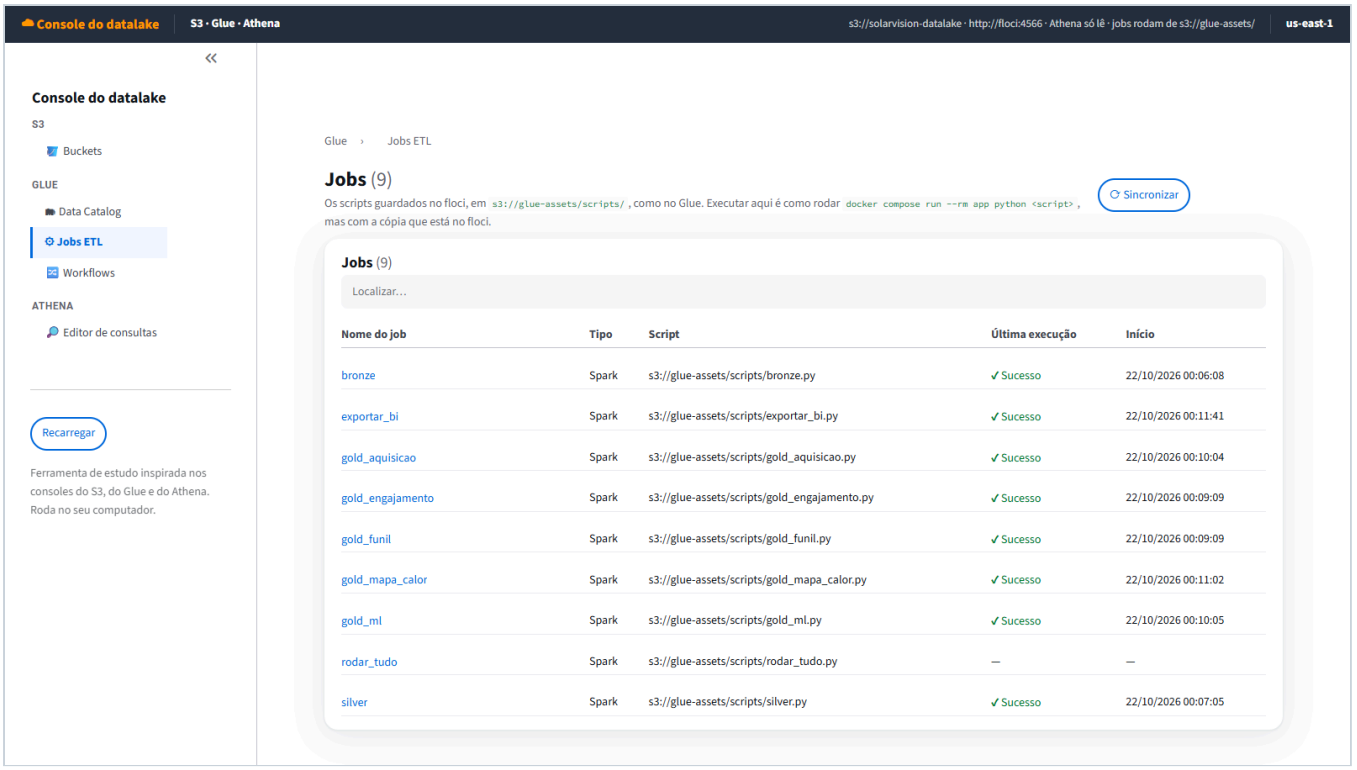
Os jobs ficam no floci (`s3://glue-assets/scripts/`) e rodam a partir de lá, como no Glue.

1. Glue · Workflows · medalhao



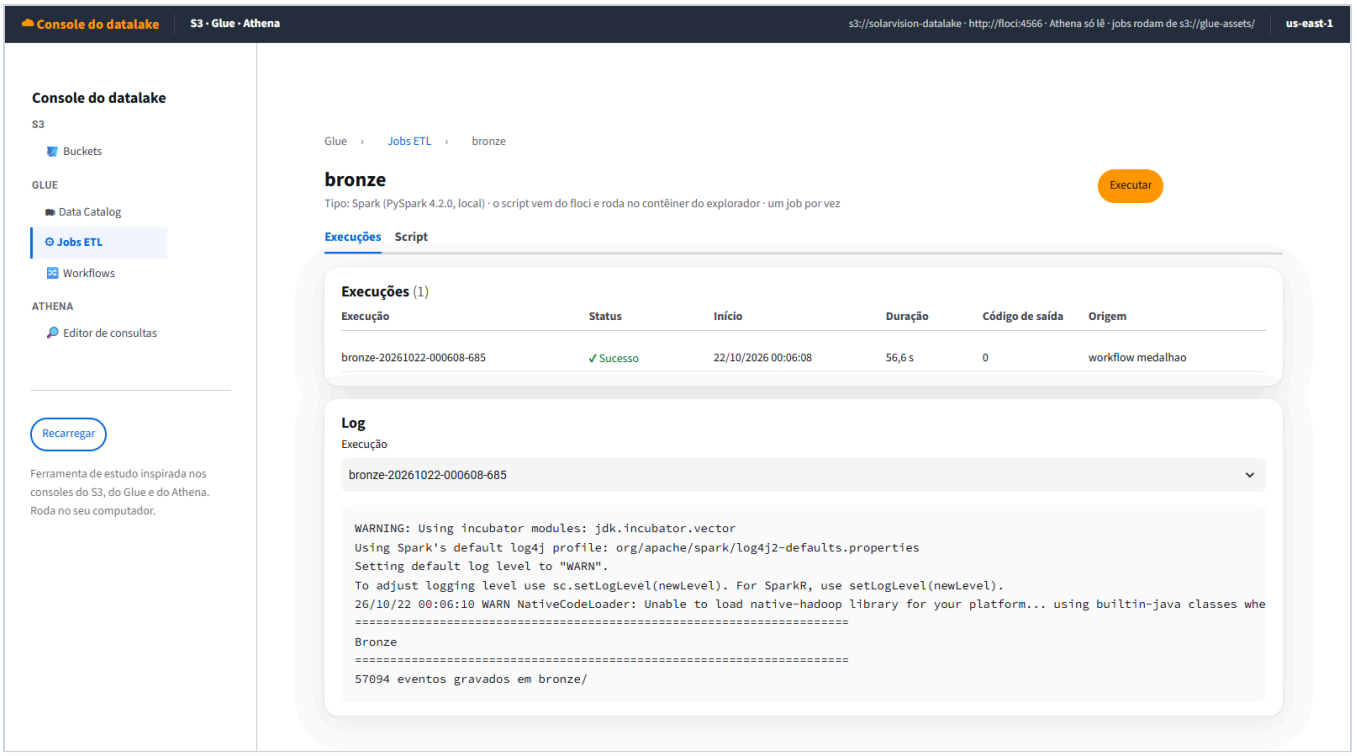
Grafo de dependências e execução `medalhao-20261022-000608` com Sucesso em 345,8 s: bronze → silver → cinco Golds em paralelo (duas por vez) → exportar_bi. É a sequência do R3 (o mesmo grafo de `pipeline/rodar_tudo.py`).

2. Glue · Jobs ETL



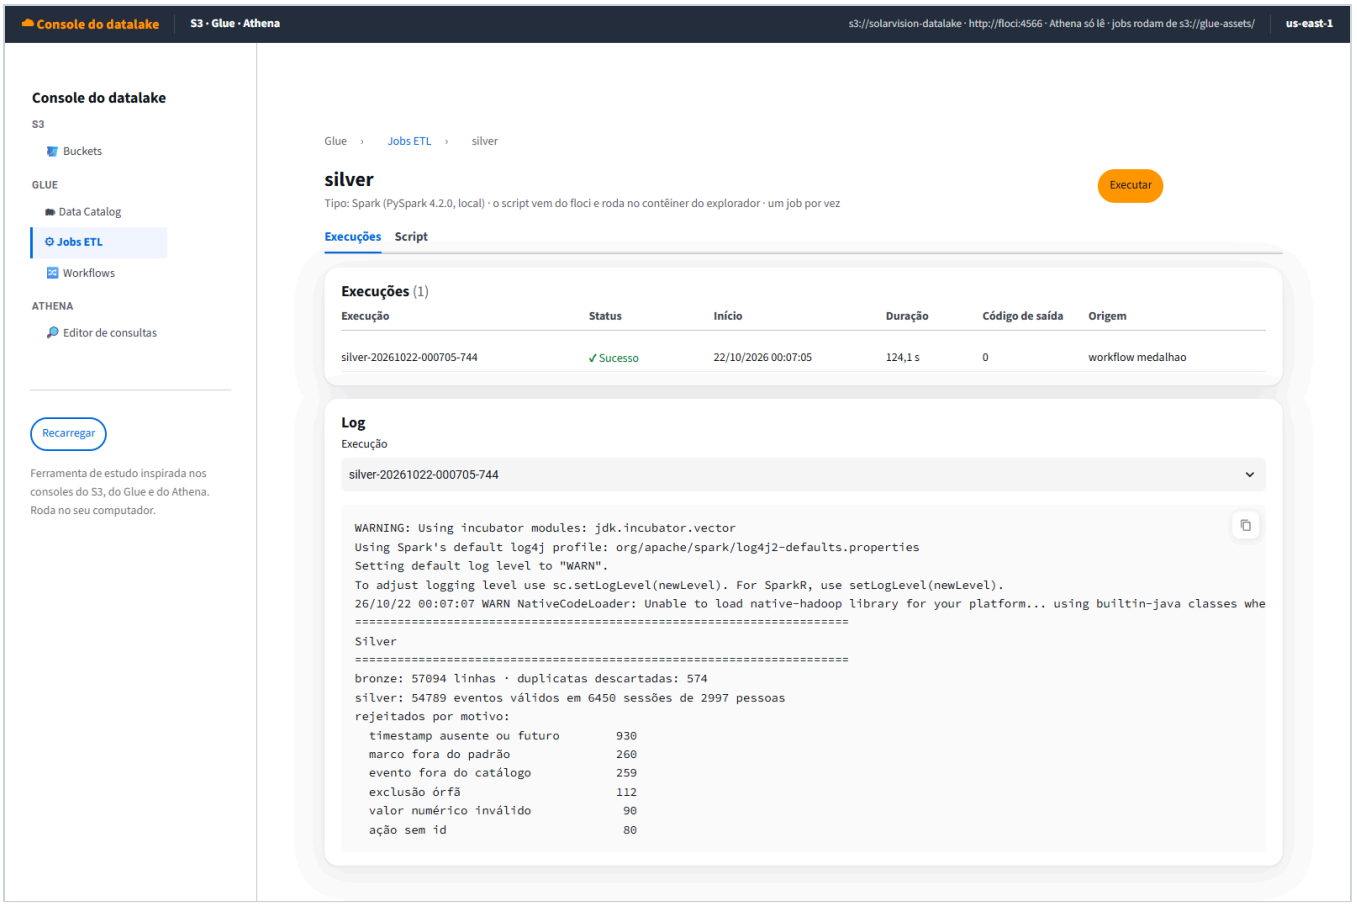
Um job por camada (R2): bronze, silver, gold_funil, gold_engajamento, gold_aquisicao, gold_ml, gold_mapa_calor e exportar_bi, todos com Sucesso na execução de 22/10/2026. `rodar_tudo` é o script de sequência para o terminal; no console a sequência é o workflow.

3. Execução do job bronze



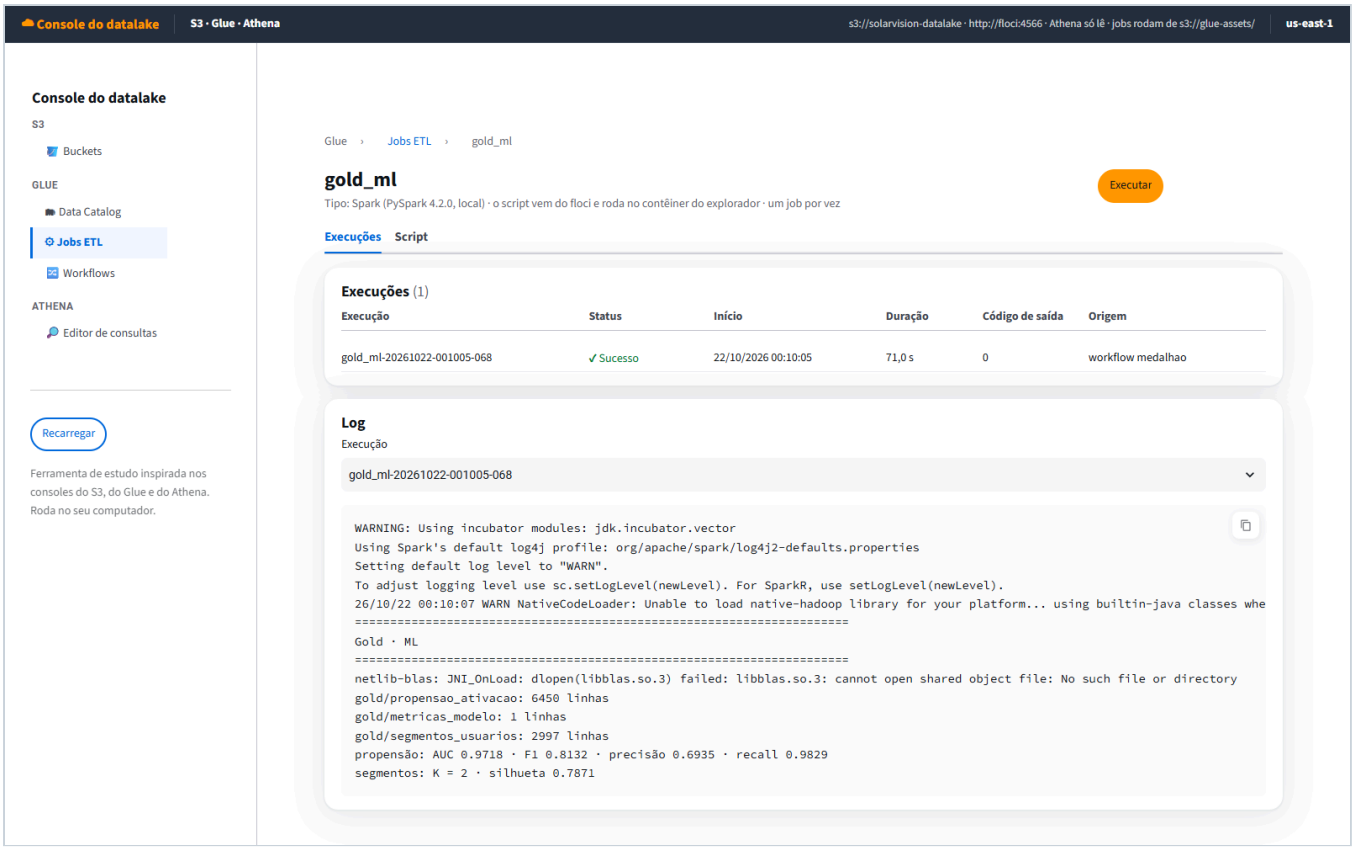
Sucesso, código de saída 0, origem "workflow medalhao": 57.094 eventos gravados em bronze/.

4. Execução do job silver



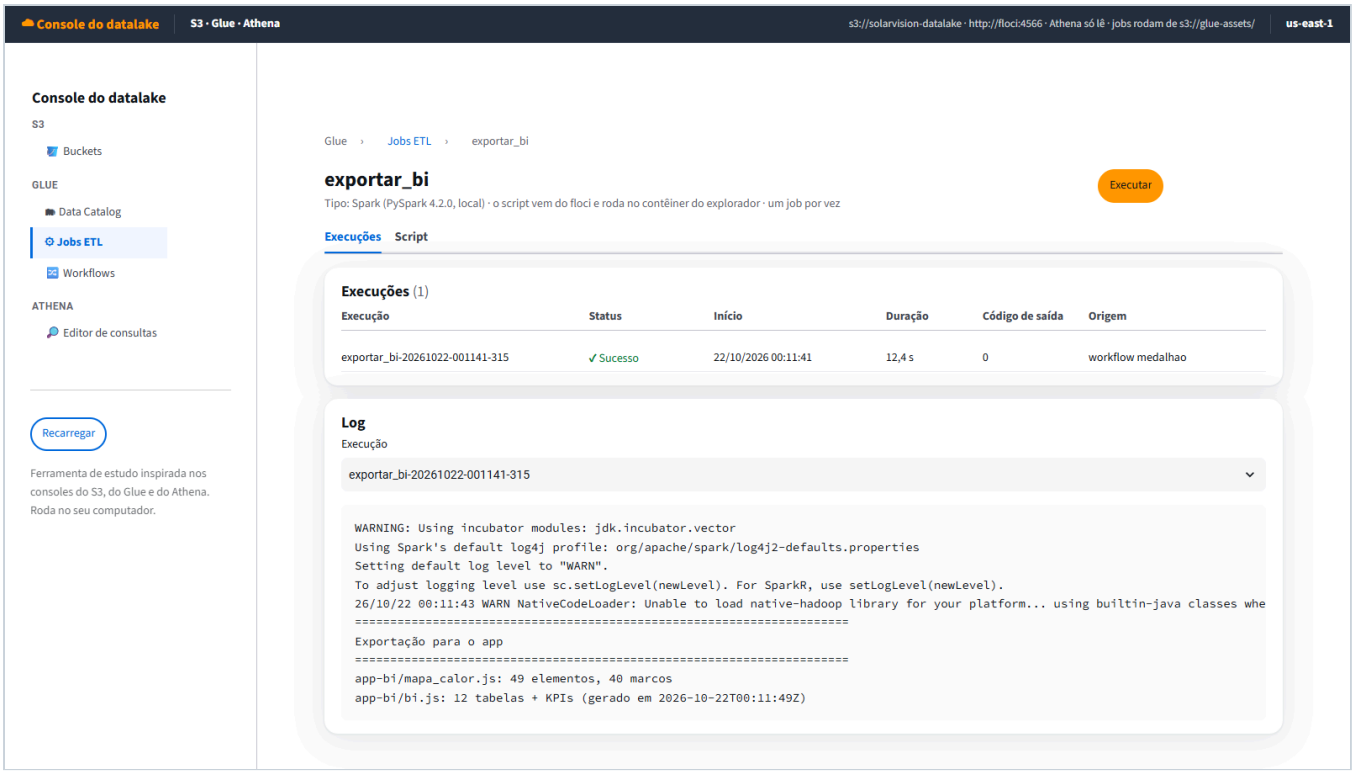
574 duplicatas descartadas (R5), 54.789 eventos válidos em 6.450 sessões de 2.997 pessoas (R8, R9) e os rejeitados por motivo (R7), que batem com os defeitos injetados pelo gerador.

5. Execução do job gold_ml



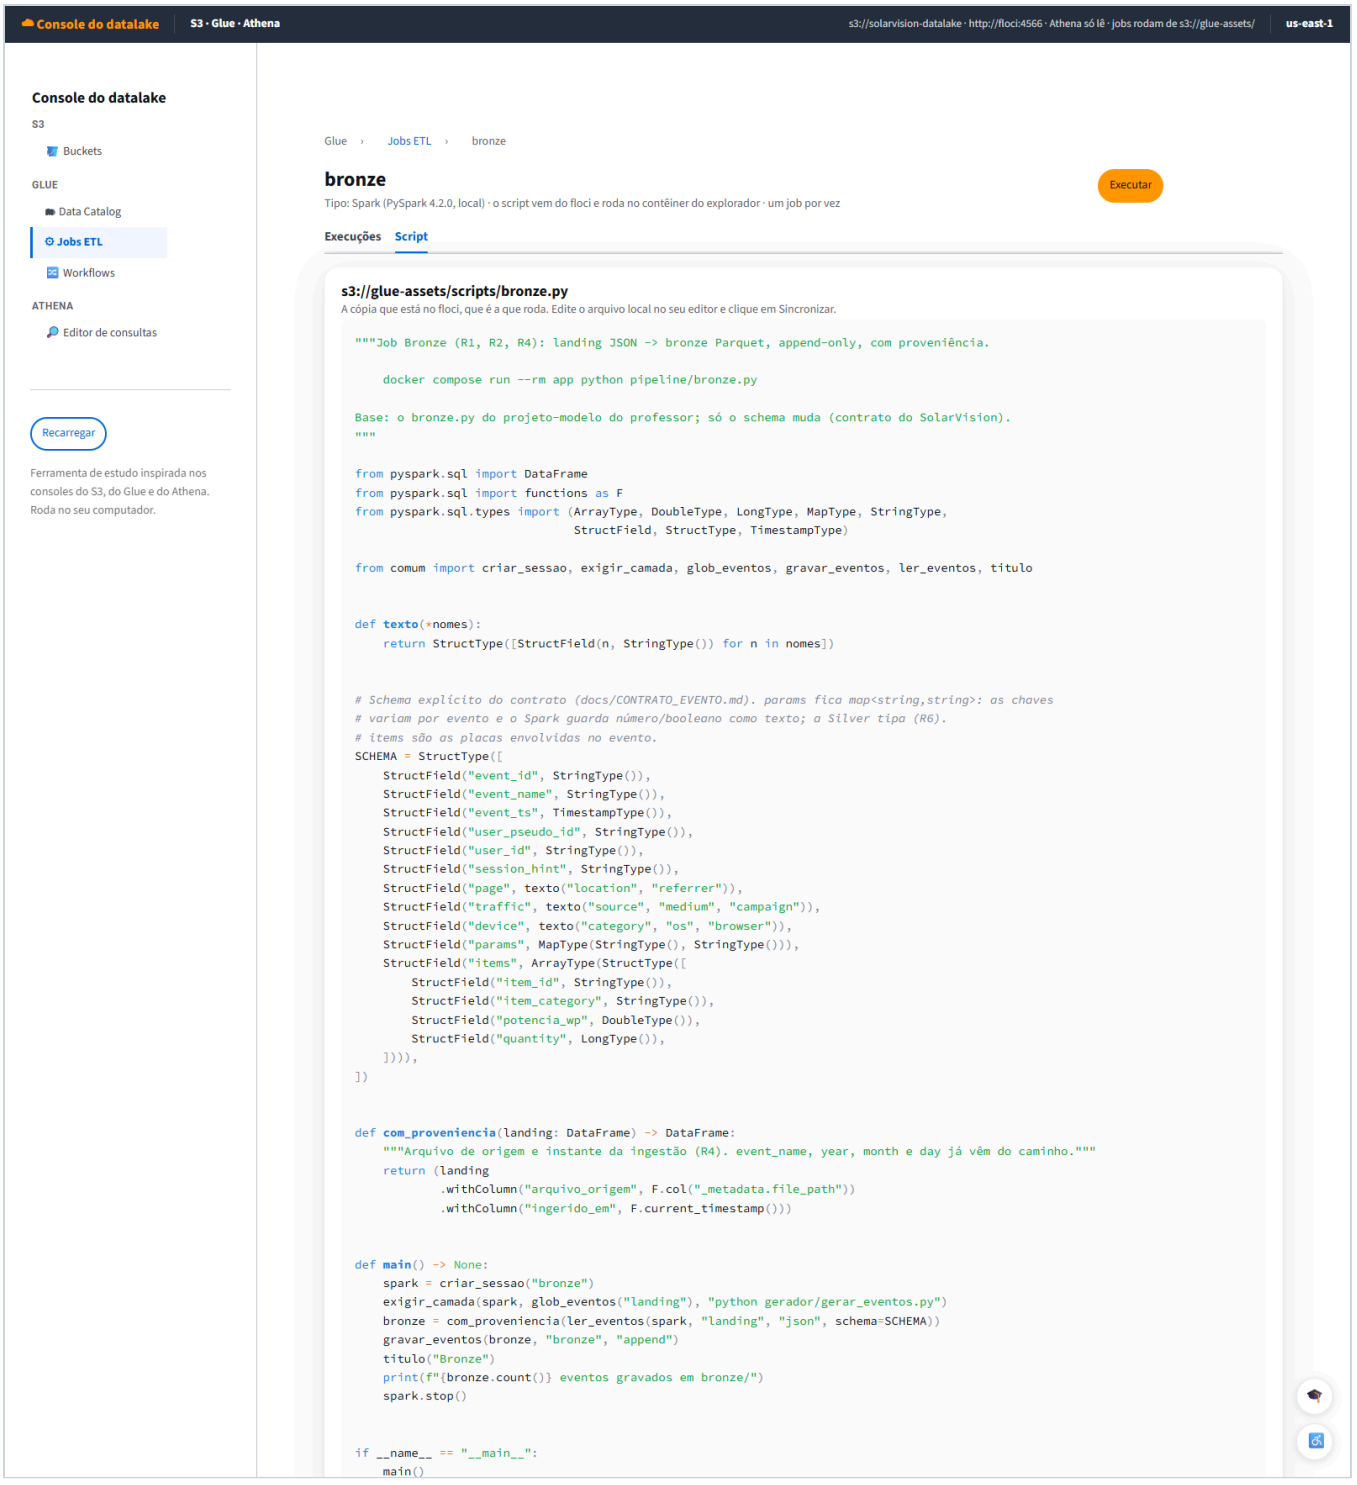
Spark ML: propensão de ativação (regressão logística) com AUC 0,9718 e F1 0,8132 no teste; segmentos de usuários com K-Means, K = 2 e silhueta 0,787. O aviso `netlib-blas` só indica que o Spark usou a implementação Java da álgebra linear.

6. Execução do job exportar_bi



R11: lê as Golds pelo Spark e grava `app-bi/mapa_calor.js` (49 elementos, 40 marcos de rolagem) e `app-bi/bi.js`, que o app lê em `frontend/public/bi/`.

7. Script do job bronze

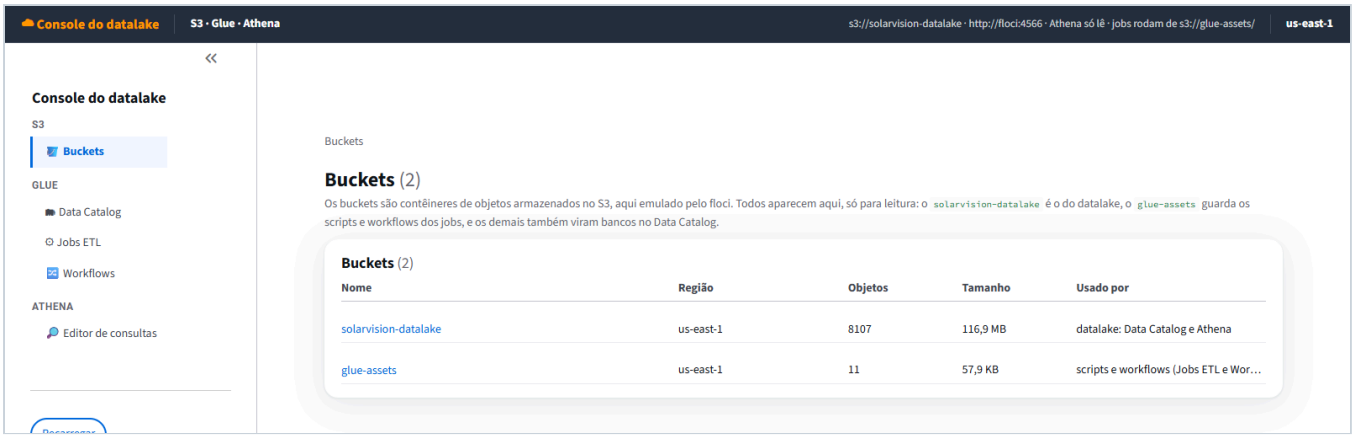


A cópia no floci: schema explícito do contrato (params como map, as placas em items), colunas de proveniência e gravação append particionada (R4).

B. Bronze

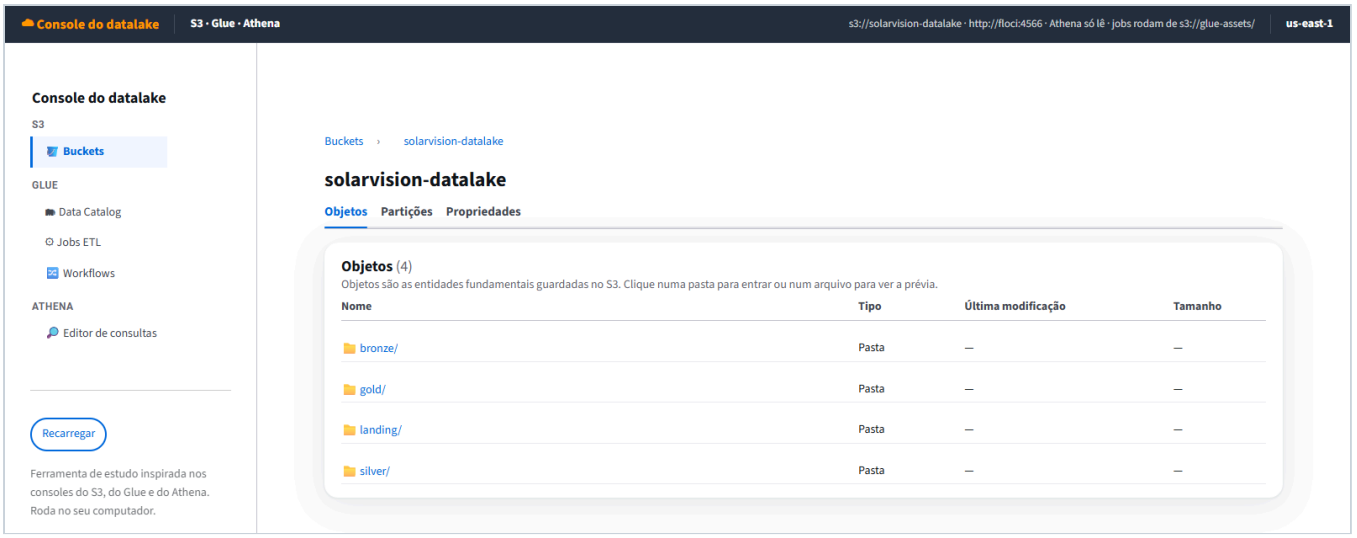
R1, R2 e R4: cópia fiel da landing em Parquet, append-only, com proveniência.

8. S3 · buckets



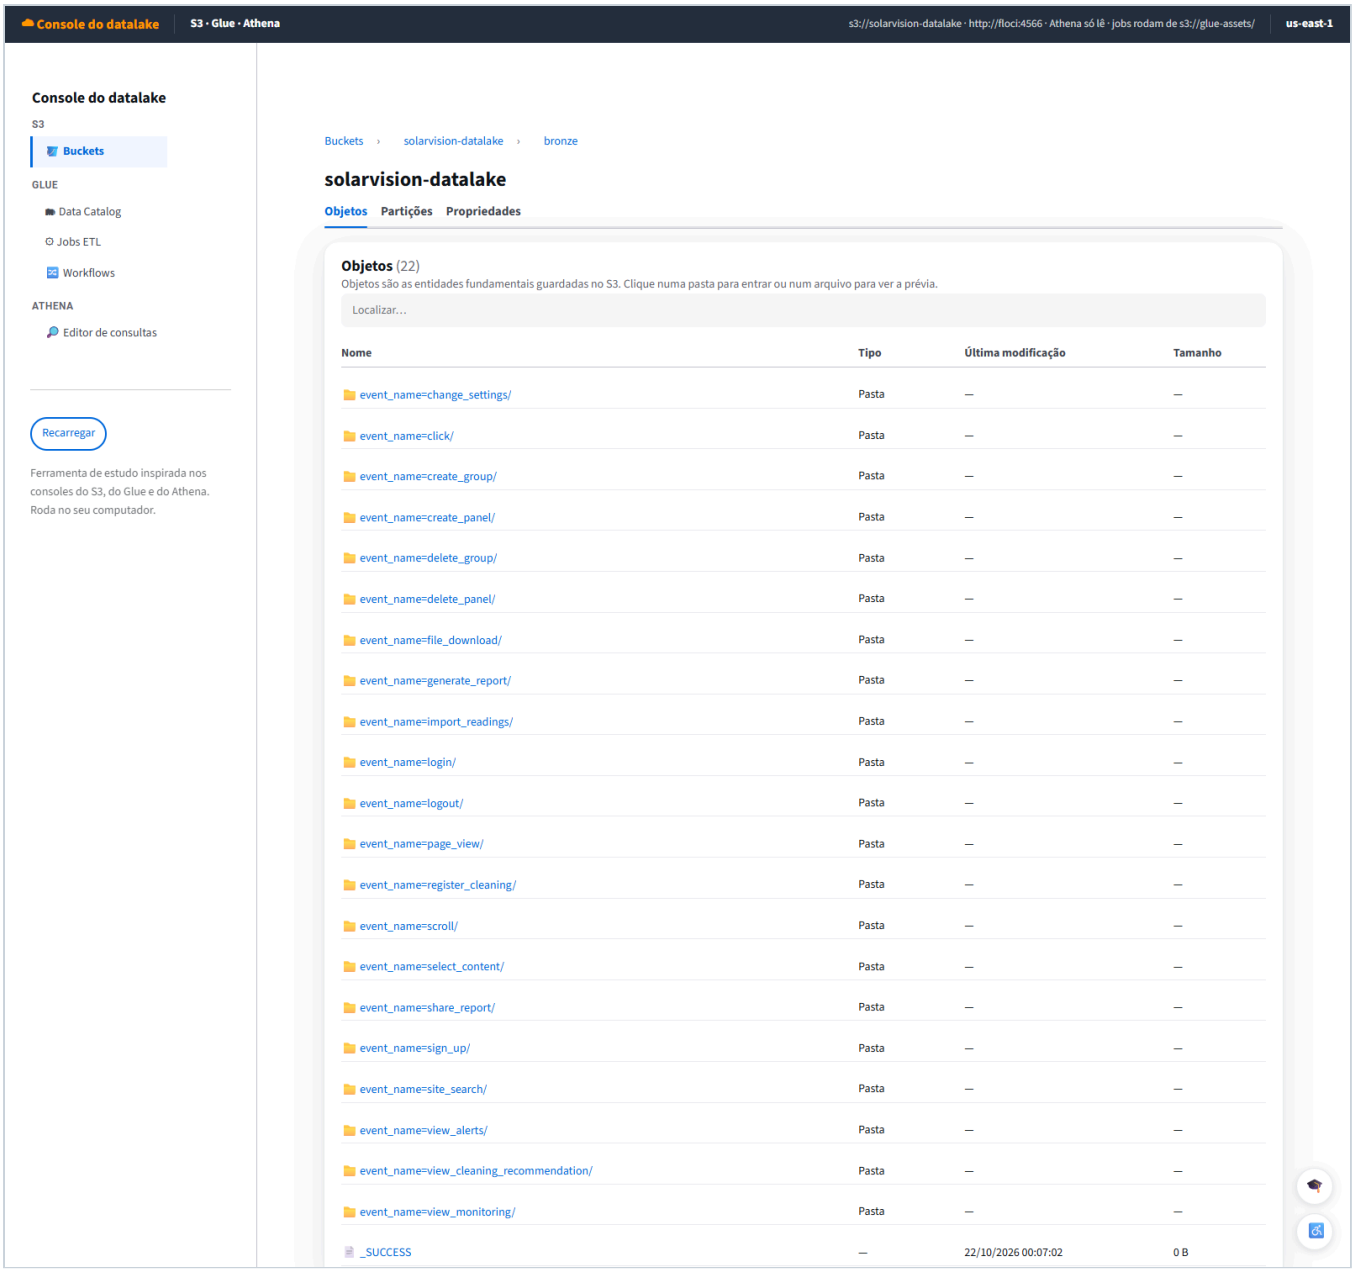
`solarvision-datalake` (o datalake) e `glue-assets` (scripts e workflows dos jobs).

9. S3 · as camadas do medalhão



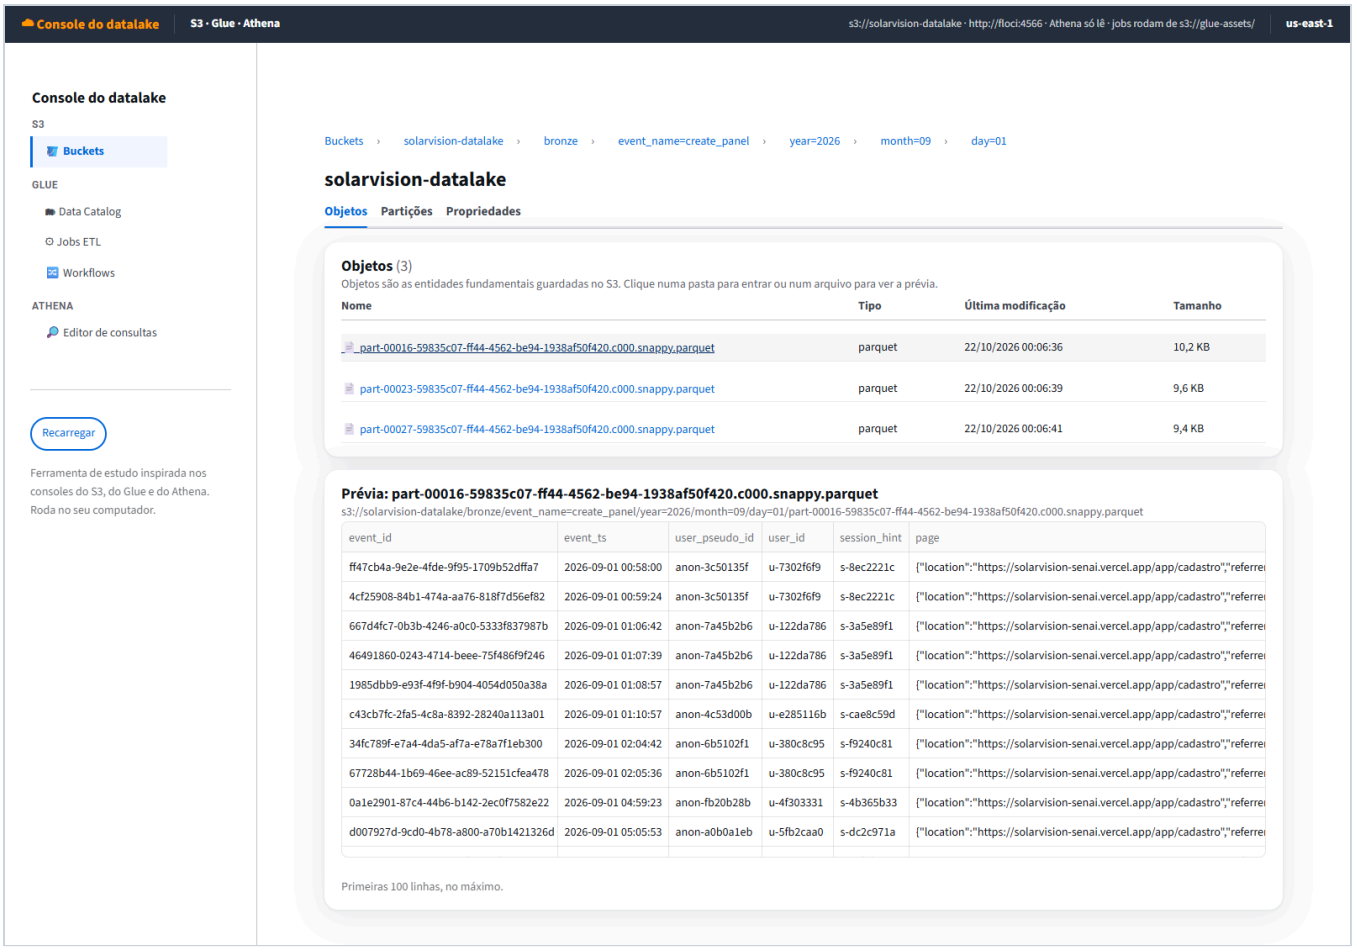
landing/ (entrada, vinda do gerador e do coletor), bronze/, silver/ e gold/ no mesmo bucket.

10. S3 · bronze/



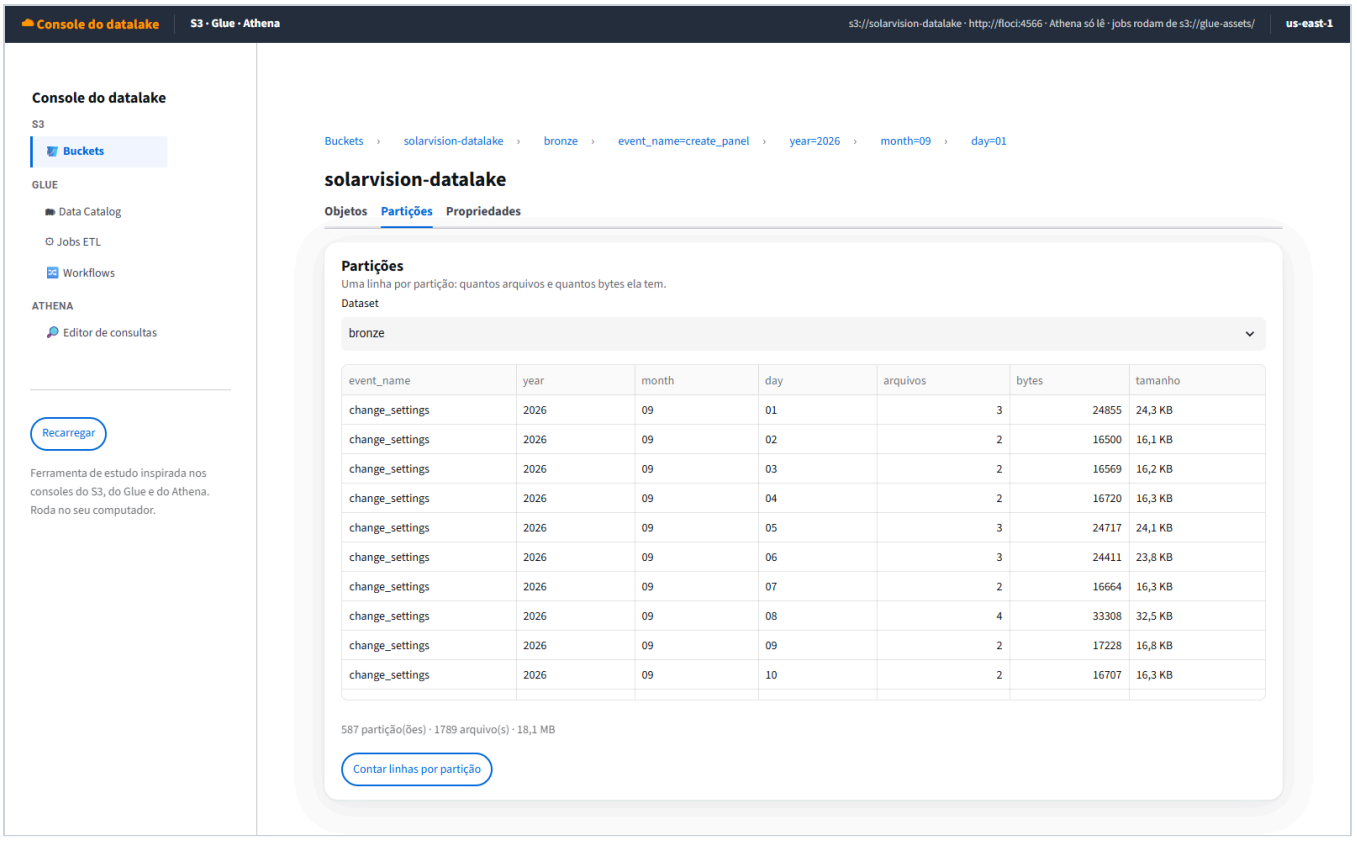
Uma pasta `event_name=` por evento, inclusive o fora do catálogo (`share_report`): a Bronze não filtra, guarda o que chegou.

11. S3 · arquivos Parquet



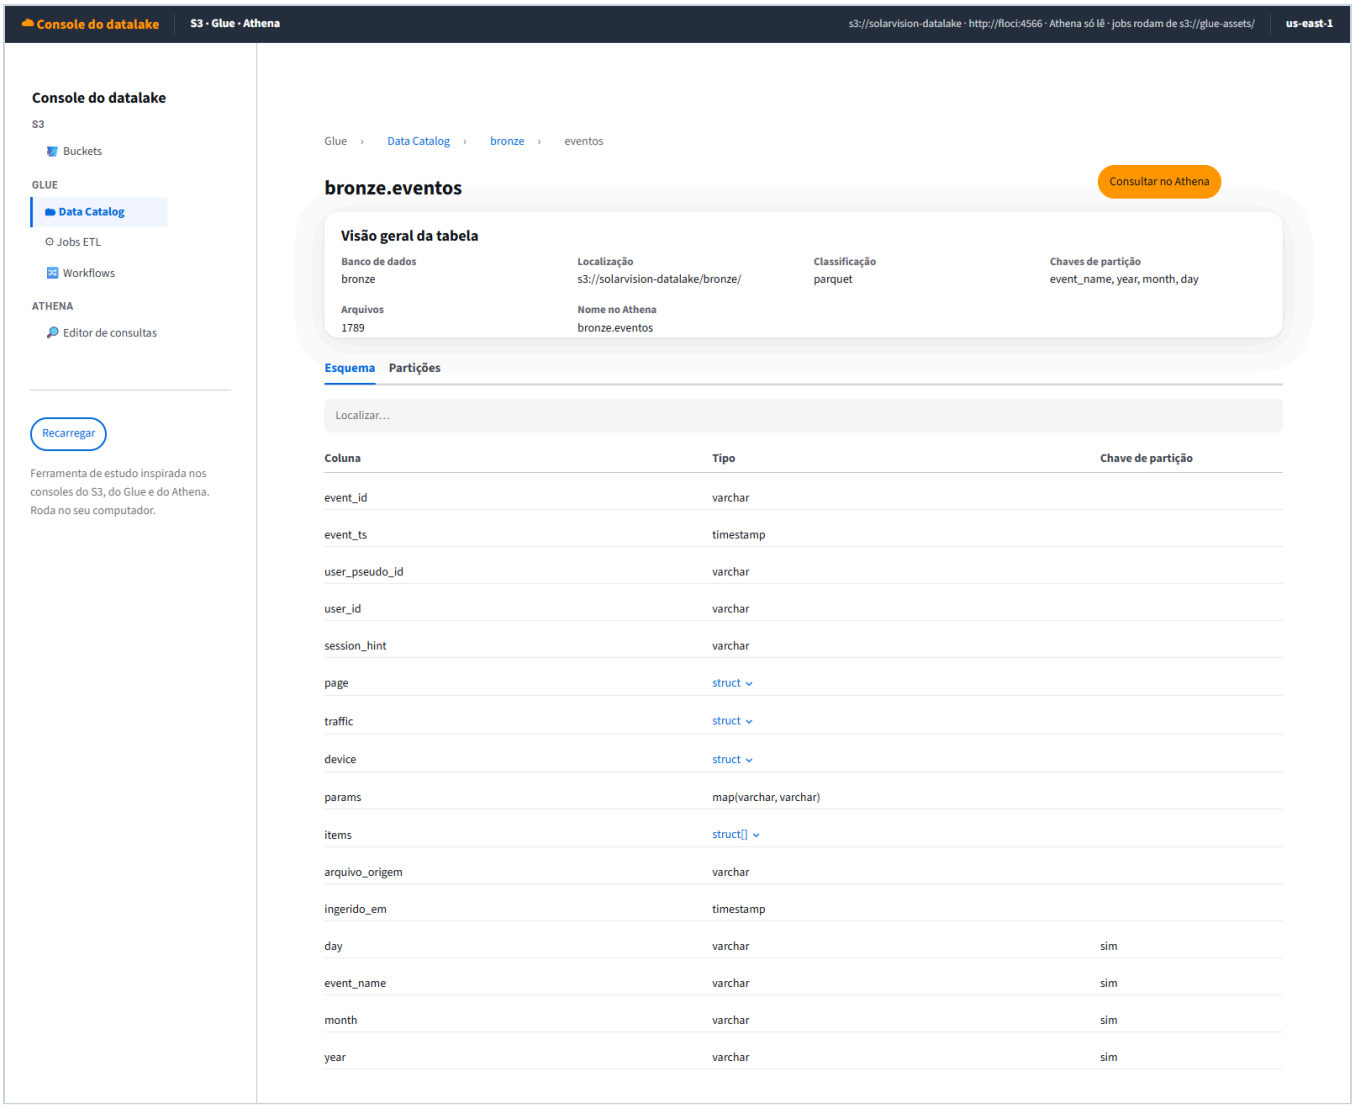
bronze/event_name=create_panel/year=2026/month=09/day=01/: arquivos Parquet e a prévia, com os campos do contrato (user_id pseudonimizado `u-…`, telas do app em `page.location`).

12. S3 · partições da Bronze



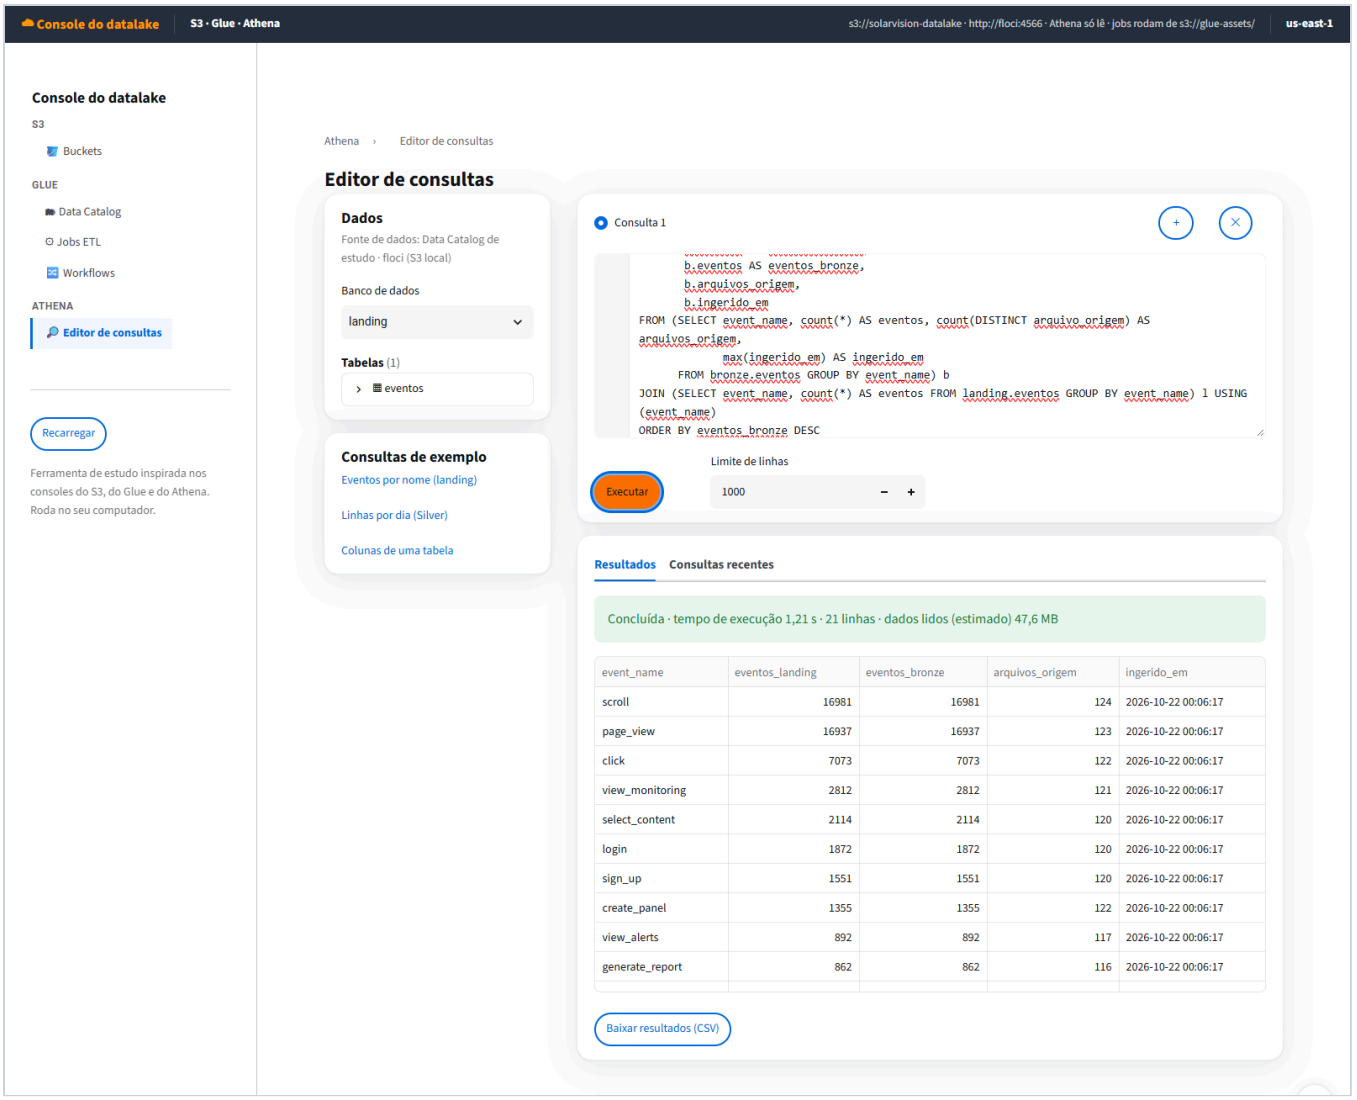
event_name / year / month / day, com mês e dia em dois dígitos, tirados do caminho da landing (dia de coleta).

16. Glue Data Catalog · bronze.eventos



Schema explícito (params como map, items como struct[]), proveniência (arquivo_origem, ingerido_em) e as quatro chaves de partição.

19. Athena · landing x bronze

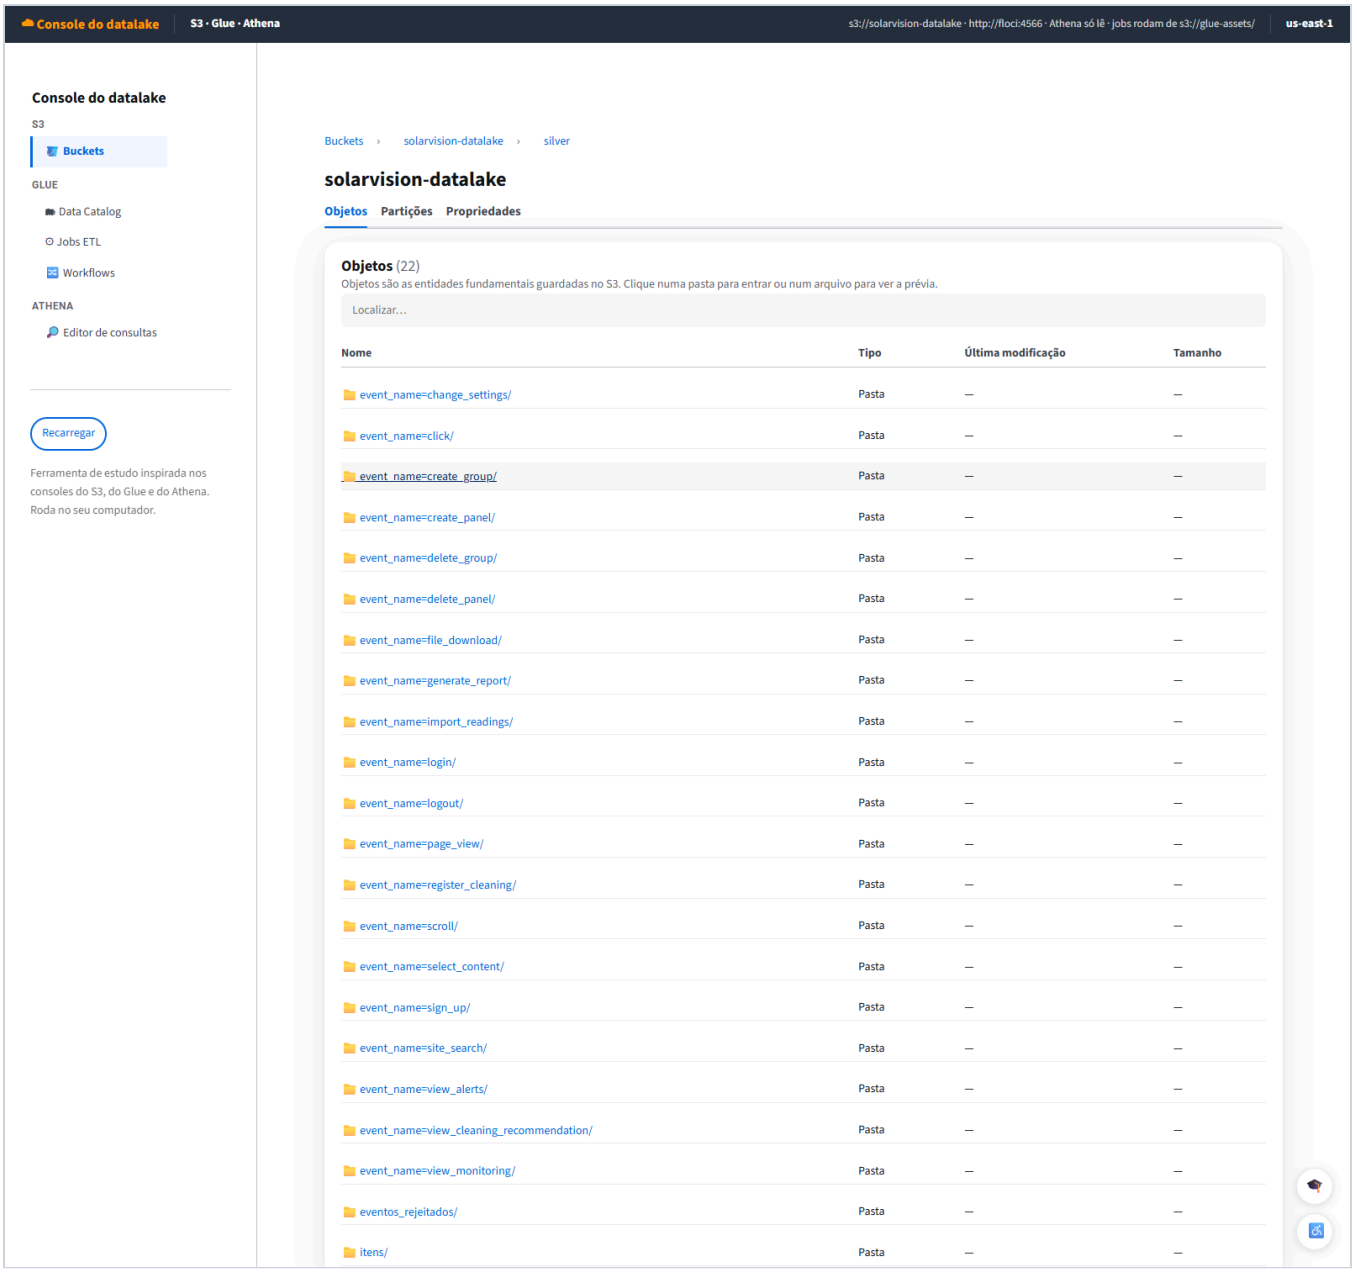


Contagem por evento nas duas camadas: idêntica nos 21 valores de event_name. Resultado em `landing_x_bronze.csv`.

C. Silver

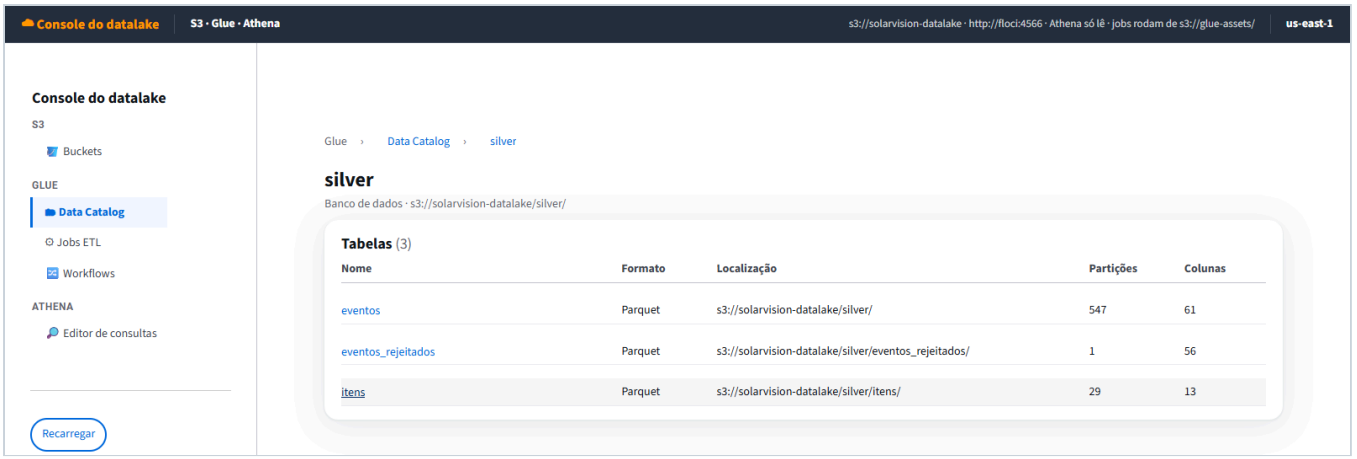
R5 a R10: sem duplicatas, tipada, com rejeitados por motivo, sessões próprias, identity stitching e itens.

13. S3 · silver/



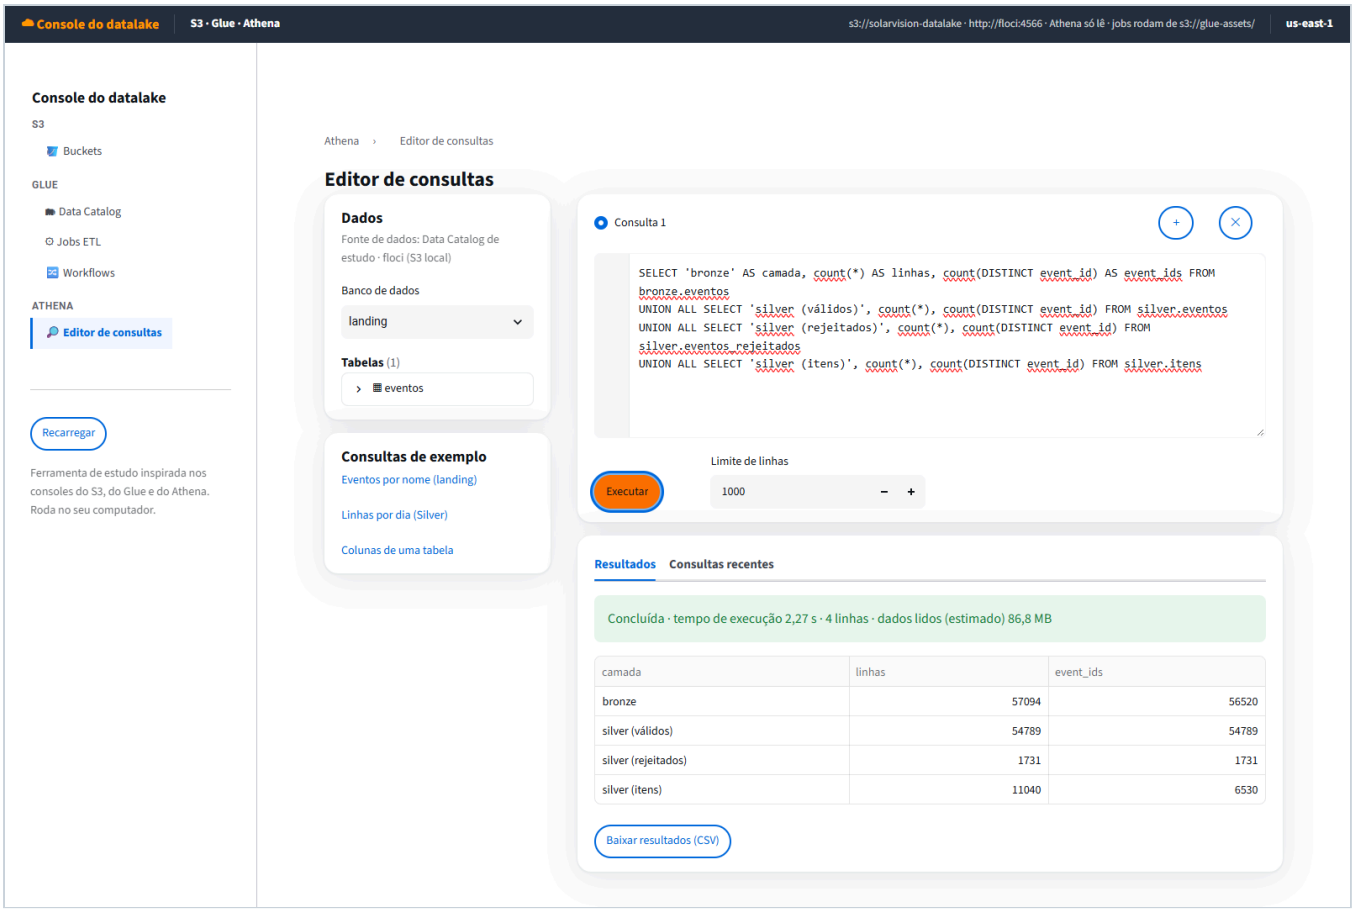
As 20 pastas `event_name=` do catálogo (o `share_report` não passa) e, ao lado, `eventos_rejeitados/` e `itens/`.

17. Glue Data Catalog · silver



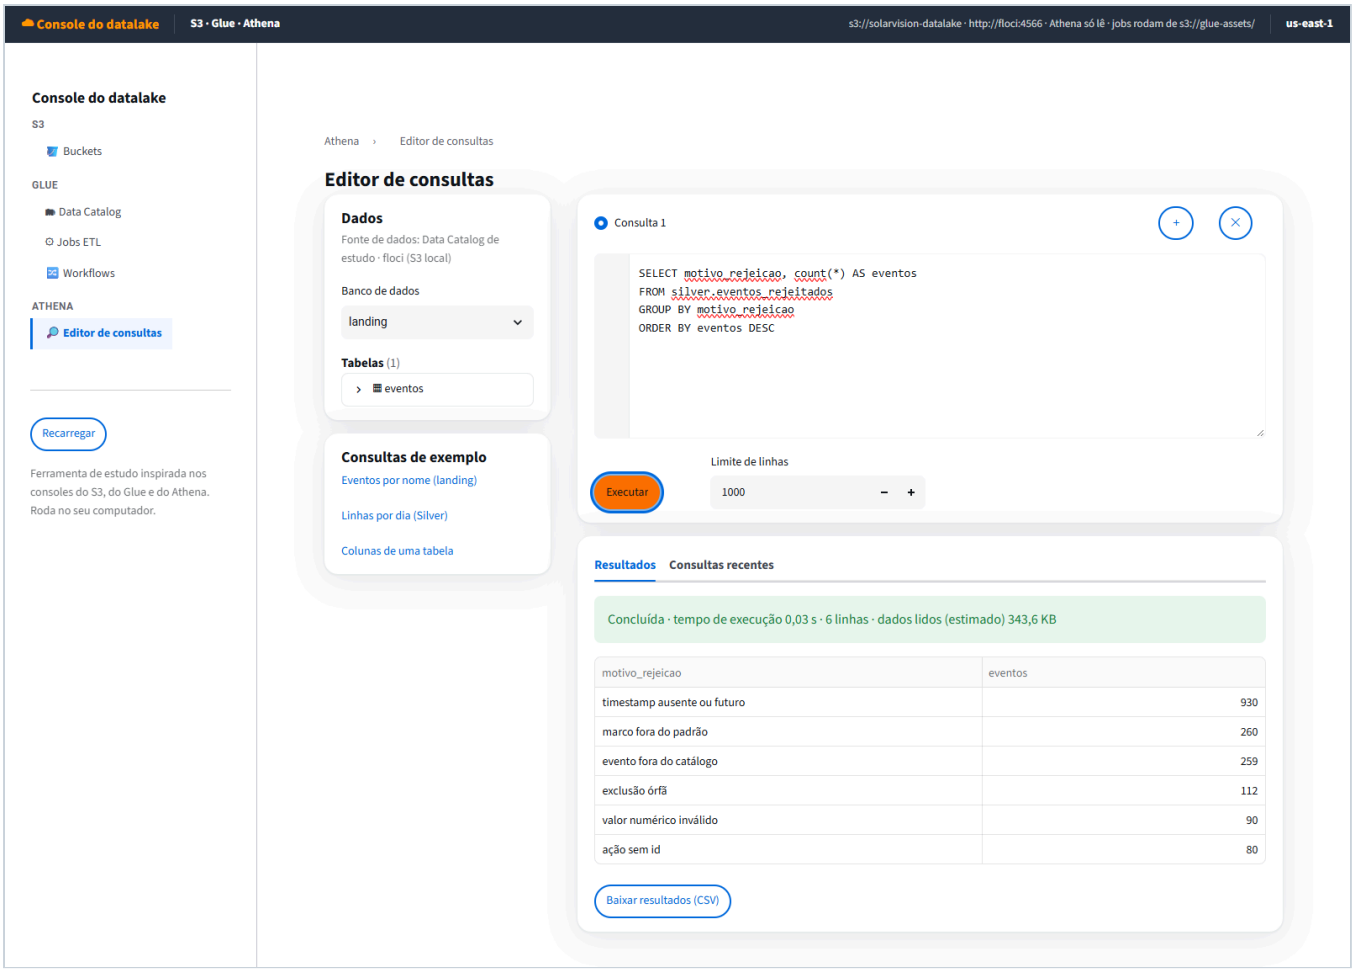
Três tabelas: eventos, eventos_rejeitados e itens.

20. Athena · bronze x silver



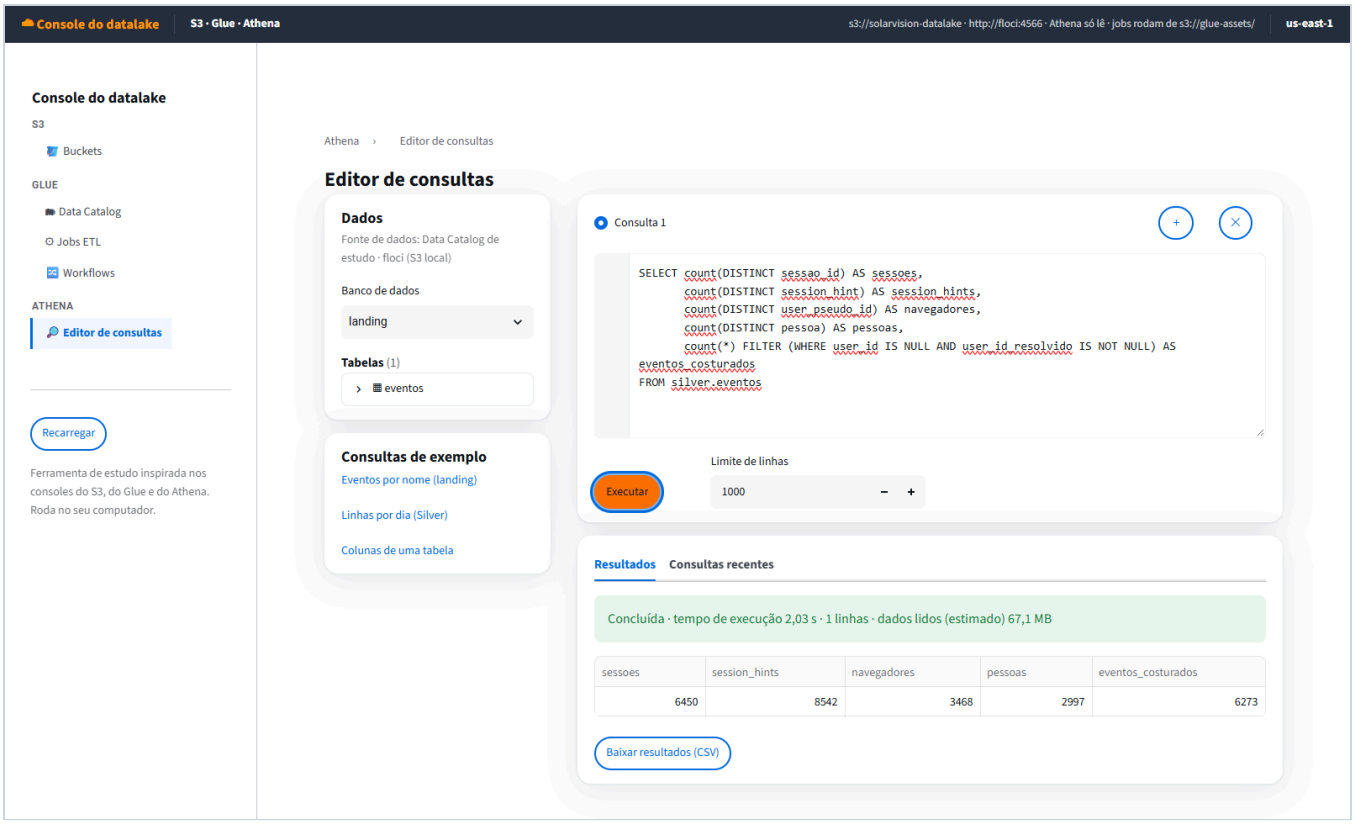
Bronze: 57.094 linhas e 56.520 event_id distintos (574 cópias de reenvio, R5). Silver: 54.789 válidos + 1.731 rejeitados = 56.520. Itens: 11.040 linhas de 6.530 eventos (R10). Resultado em `bronze_x_silver.csv`.

21. Athena · rejeitados por motivo (R7)



timestamp ausente ou futuro 930, marco fora do padrão 260, fora do catálogo 259, exclusão órfã 112, valor numérico inválido 90, ação sem id 80. A exclusão órfã inclui 35 eventos legítimos de usuários antigos (ver datalake/RELATORIO.md, "Qualidade do dado"). Resultado em `rejeitados_por_motivo.csv`.

22. Athena · sessões e identity stitching (R8, R9)

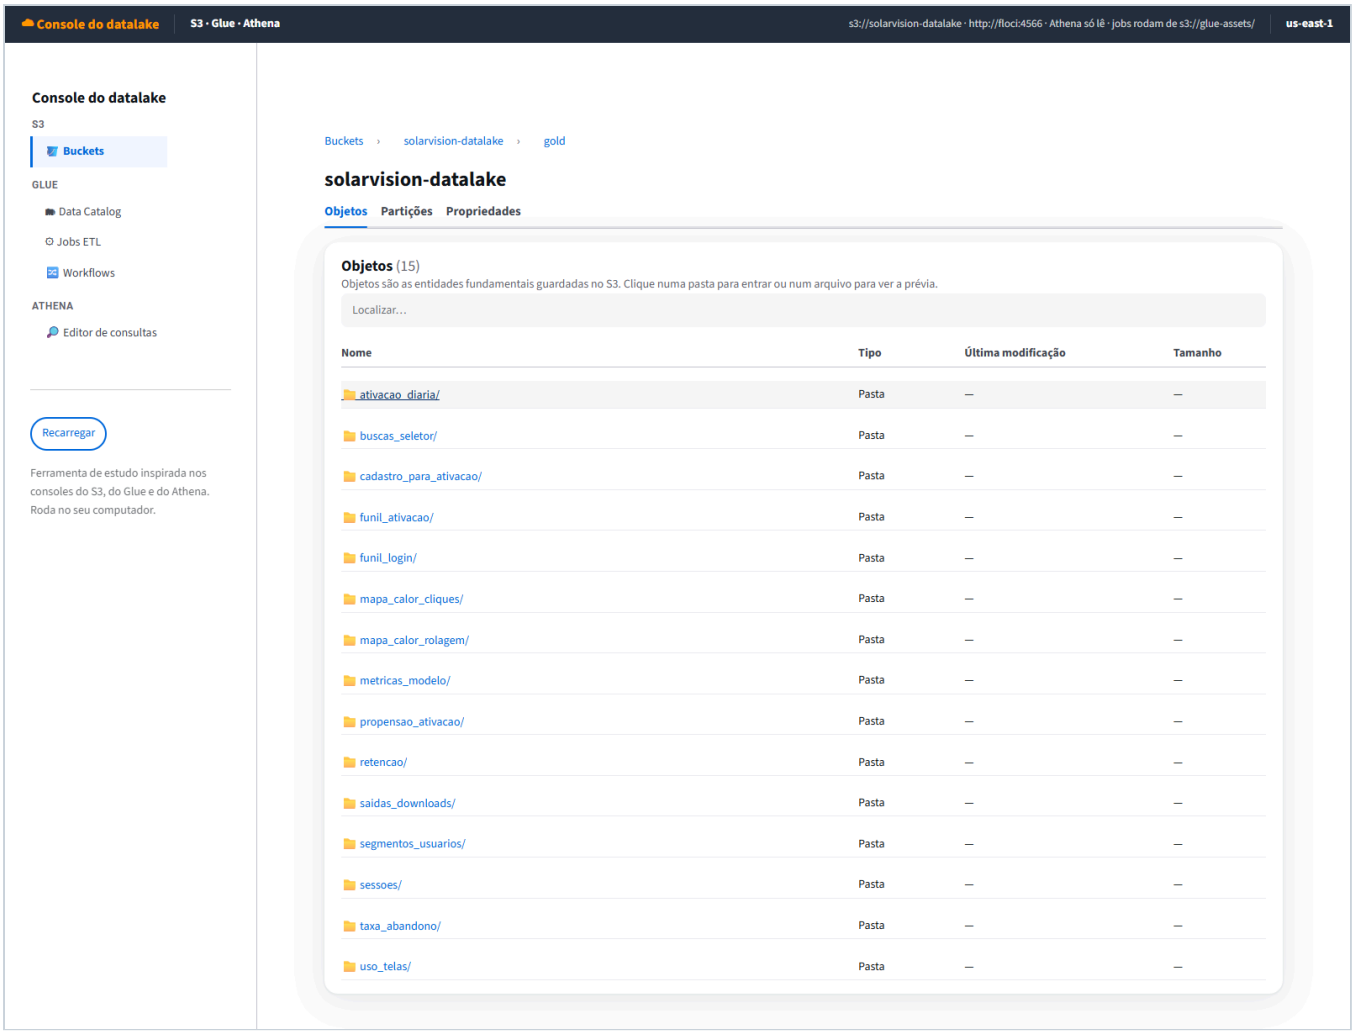


6.450 sessões próprias (pausa de 30 min) contra 8.542 `session_hint`, que não é confiável; 3.468 navegadores para 2.997 pessoas; 6.273 eventos sem `user_id` receberam o user_id da pessoa pelo stitching. Resultado em `sessoes_e_stitching.csv`.

D. Gold

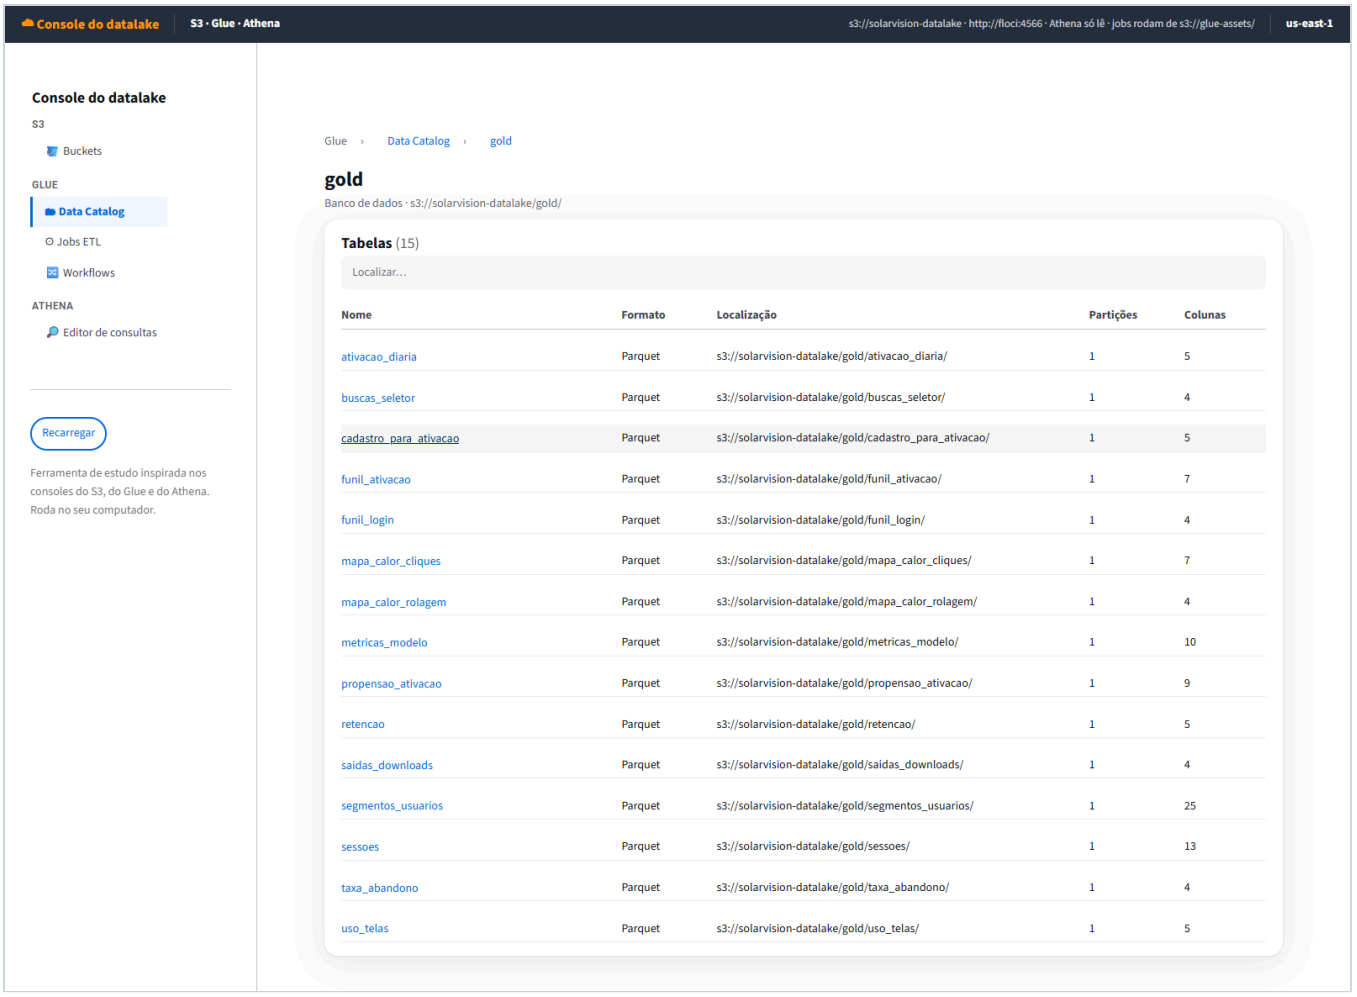
As 15 tabelas do enunciado (5.3), uma pasta por tabela.

14. S3 · gold/



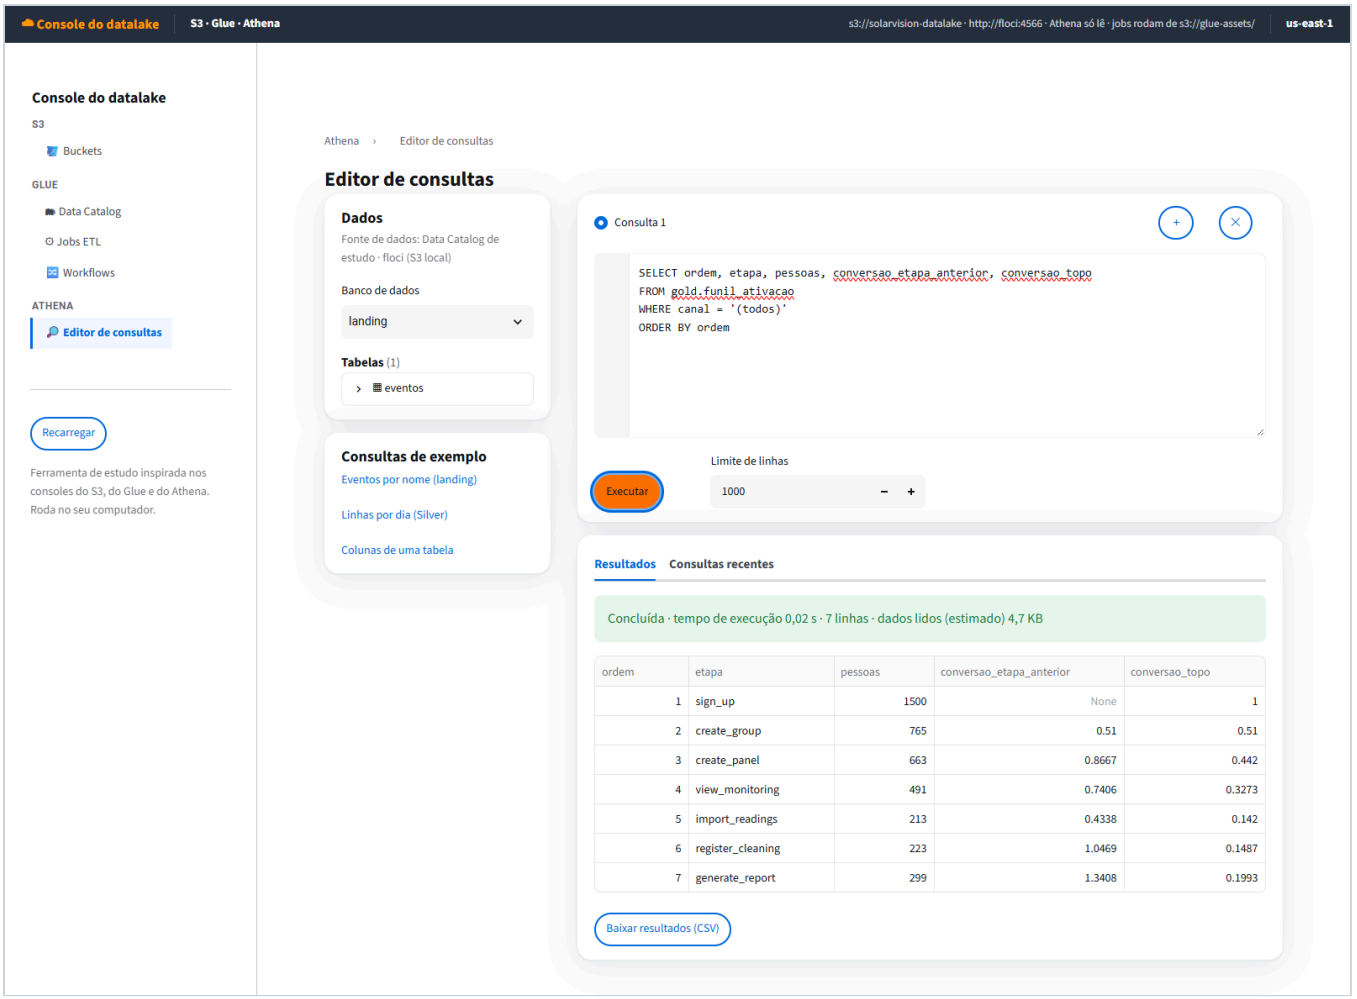
funil_ativacao, funil_login, sessoes, uso_telas, buscas_seletor, saidas_downloads, ativacao_diaria, retencao, taxa_abandono, cadastro_para_ativacao, propensao_ativacao, metricas_modelo, segmentos_usuarios, mapa_calor_cliques e mapa_calor_rolagem.

18. Glue Data Catalog · gold



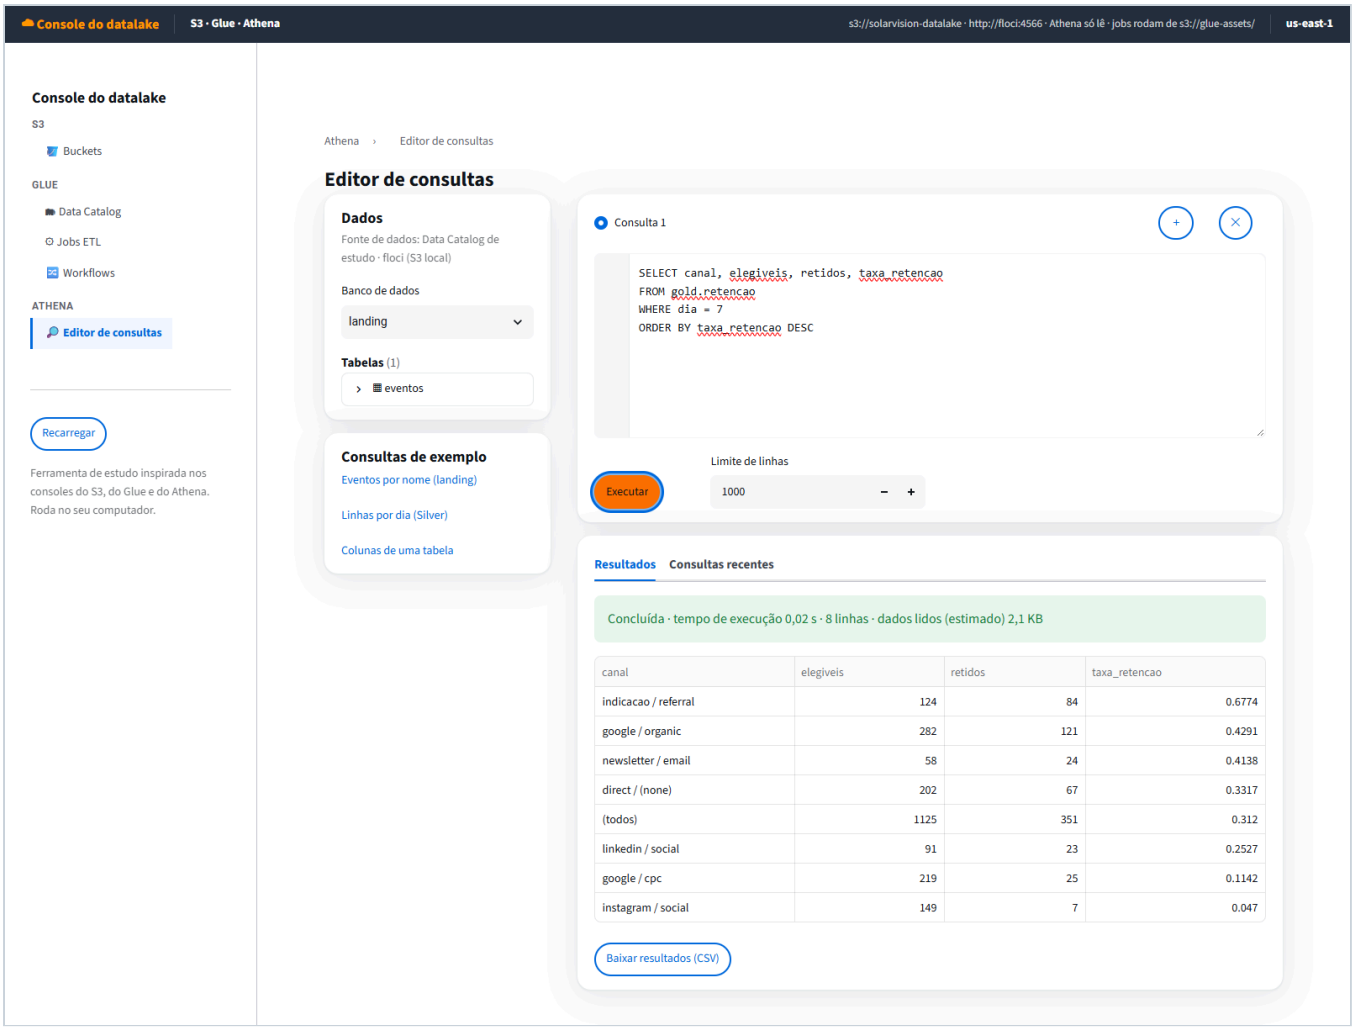
As 15 tabelas Gold em Parquet, com o número de colunas de cada uma.

23. Athena · gold.funil_ativacao



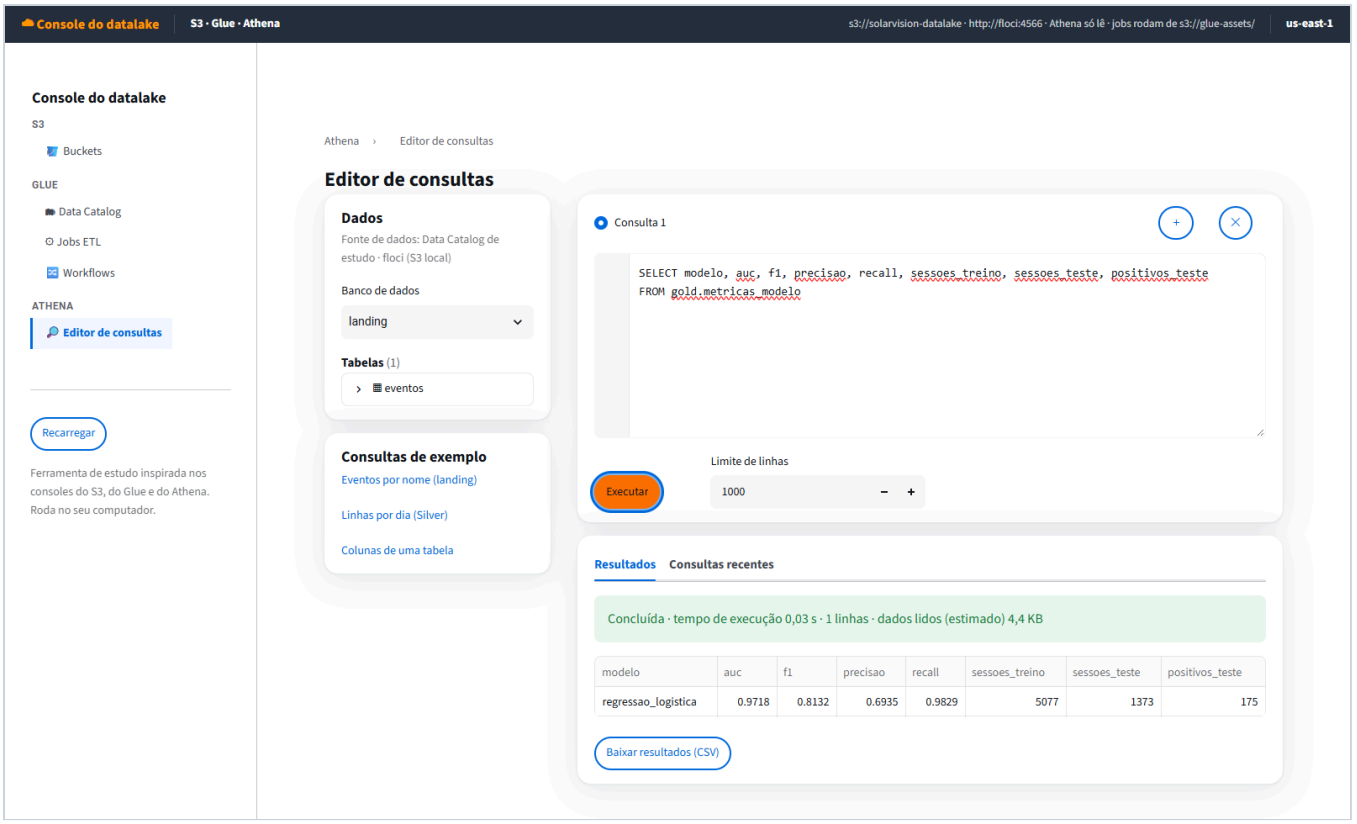
1.500 contas novas → 765 cadastraram a usina (51%) → 663 ativaram (44,2% do topo): o funil vaza mais entre criar a conta e cadastrar a usina. Resultado em `gold_funil_ativacao.csv`.

24. Athena · gold.retencao (D7)



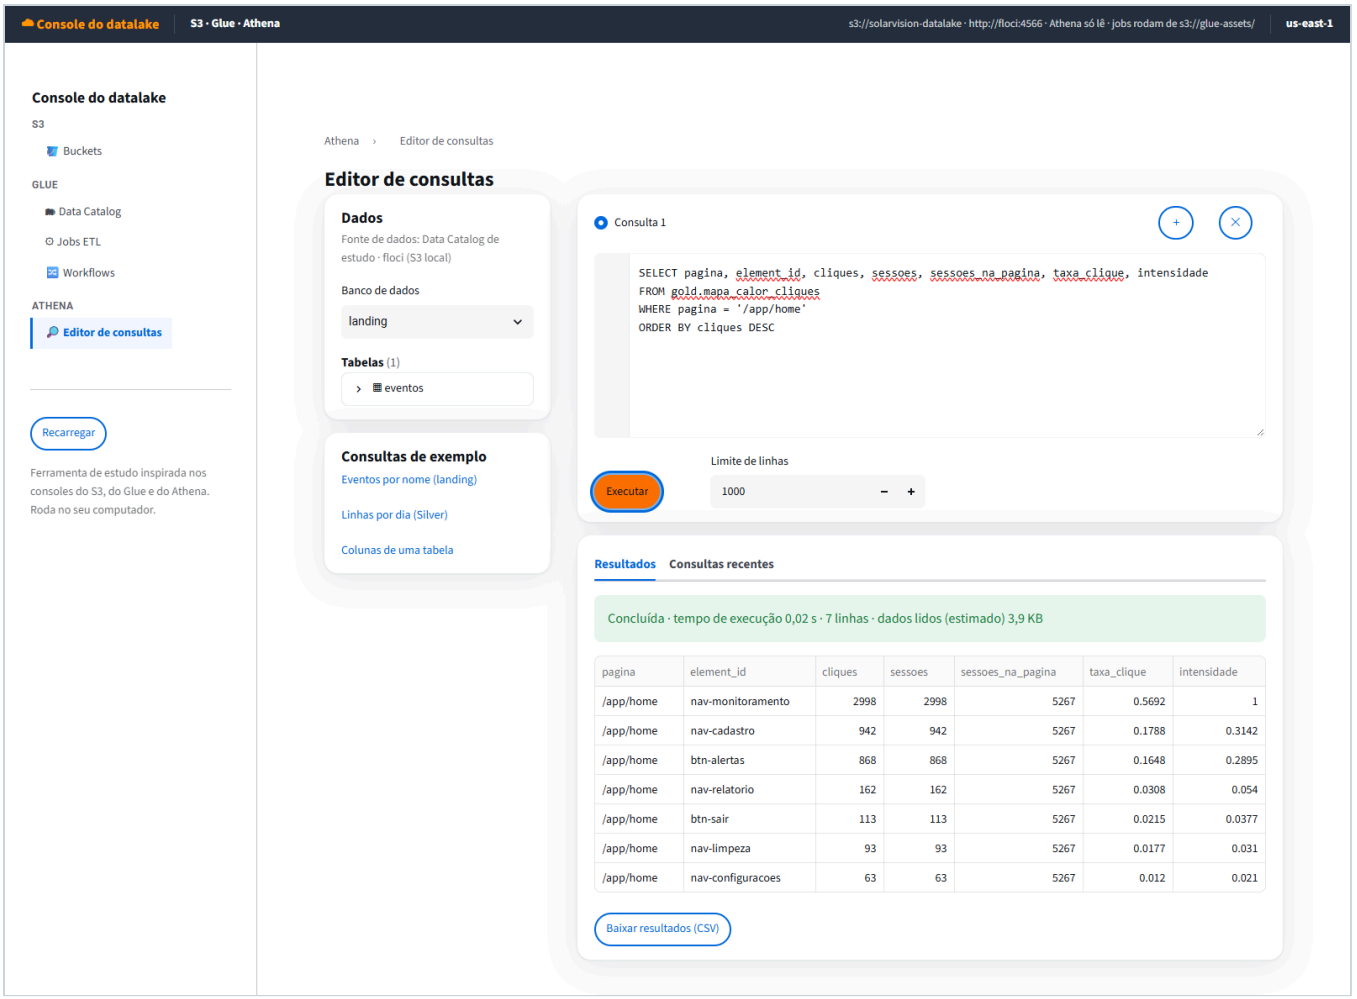
Retenção em 7 dias entre os elegíveis: indicação 67,7%, Google orgânico 42,9%, newsletter 41,4% … Instagram 4,7%. Resultado em `gold_retencao_d7.csv`.

25. Athena · gold.metricas_modelo



AUC 0,9718, F1 0,8132, precisão 0,6935 e recall 0,9829 da classe positiva, no teste separado por pessoa; as features só usam a sessão antes do primeiro evento de cadastro (sem vazamento). Resultado em `gold_metricas_modelo.csv`.

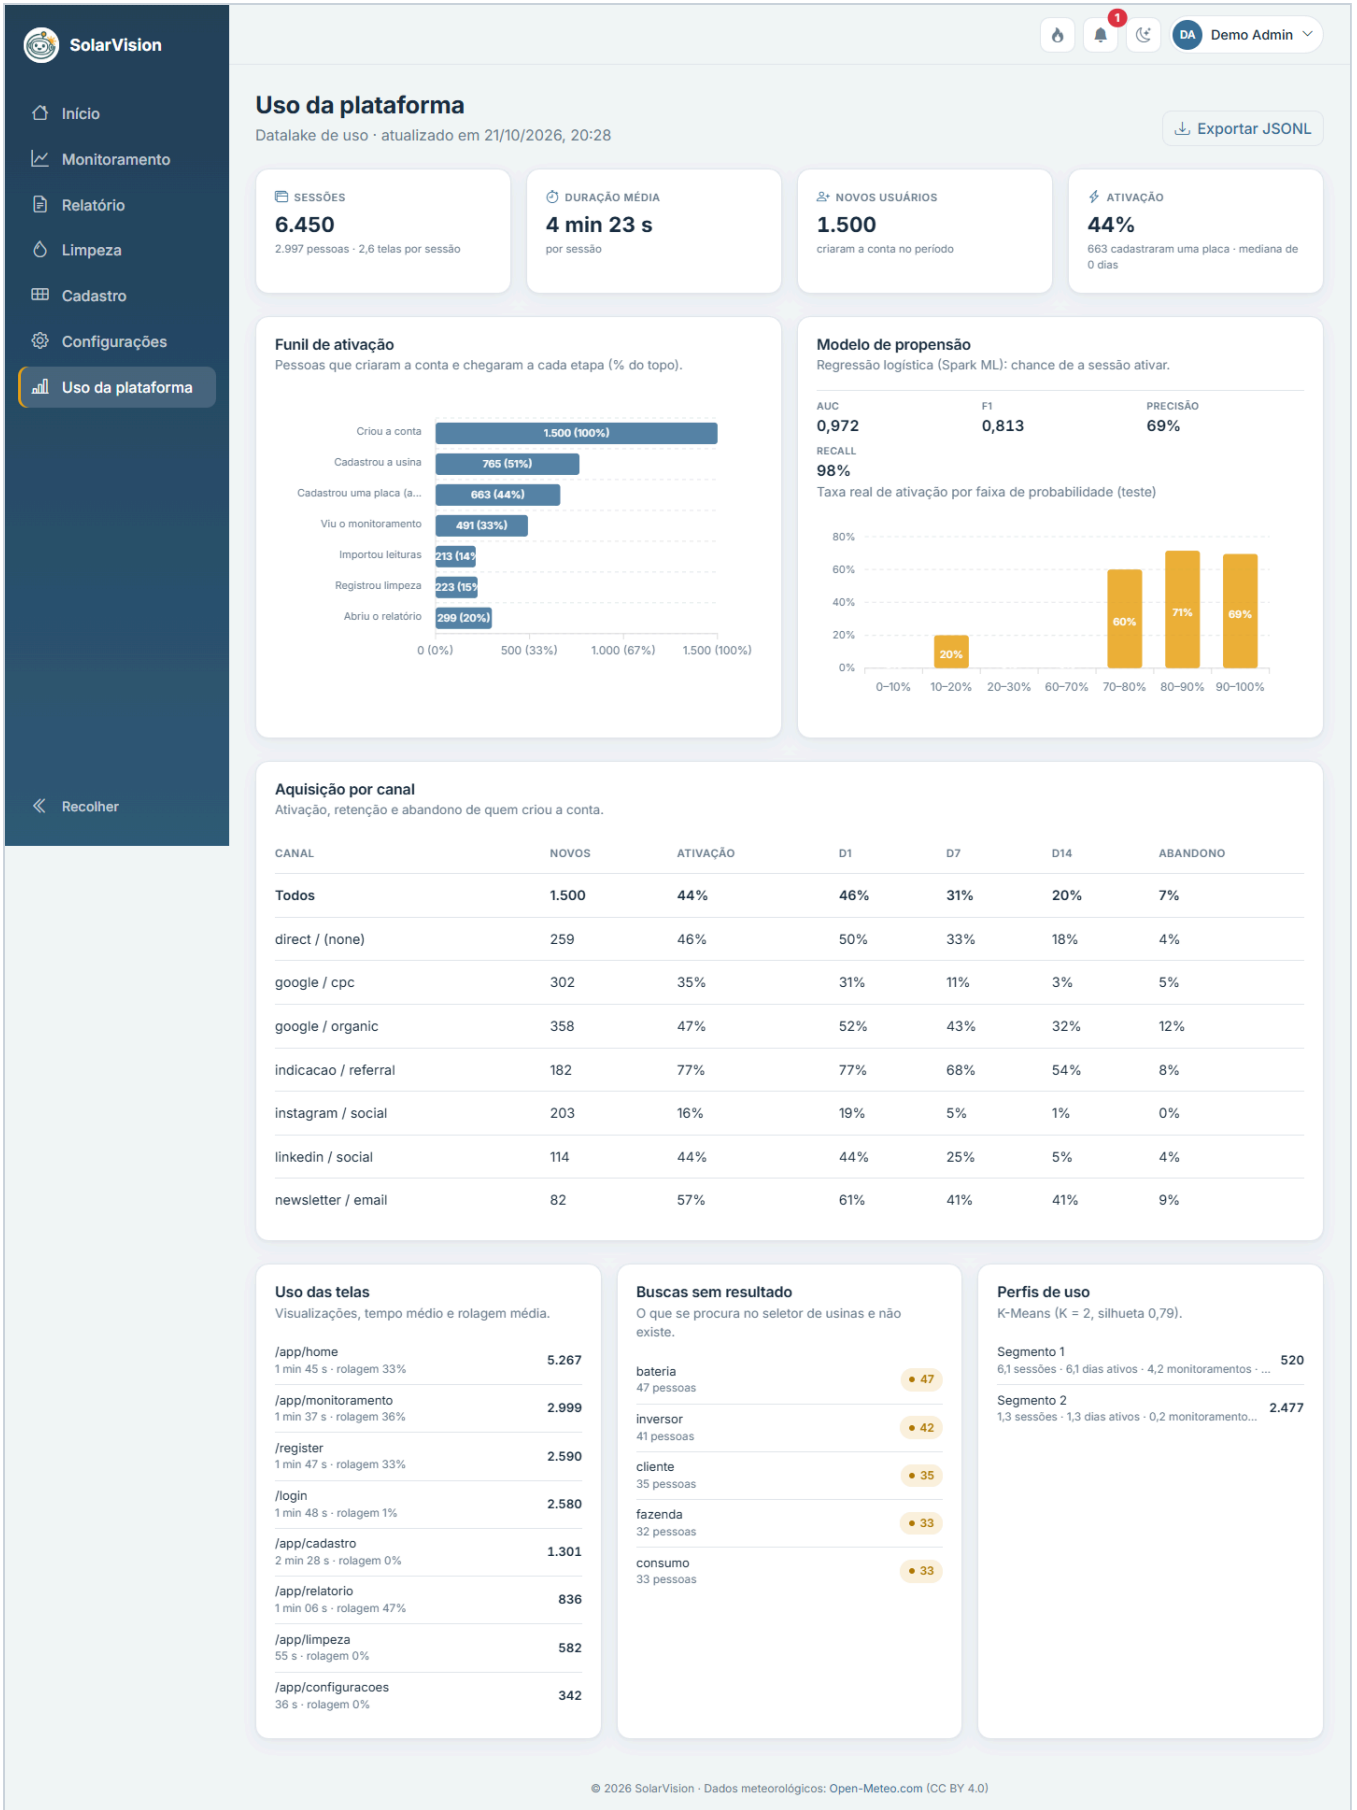
26. Athena · gold.mapa_calor_cliques



Tela Início: o link do Monitoramento tem intensidade 1 (57% das sessões clicam); colunas com os nomes exatos do R11. Resultado em `gold_mapa_calor_home.csv`.

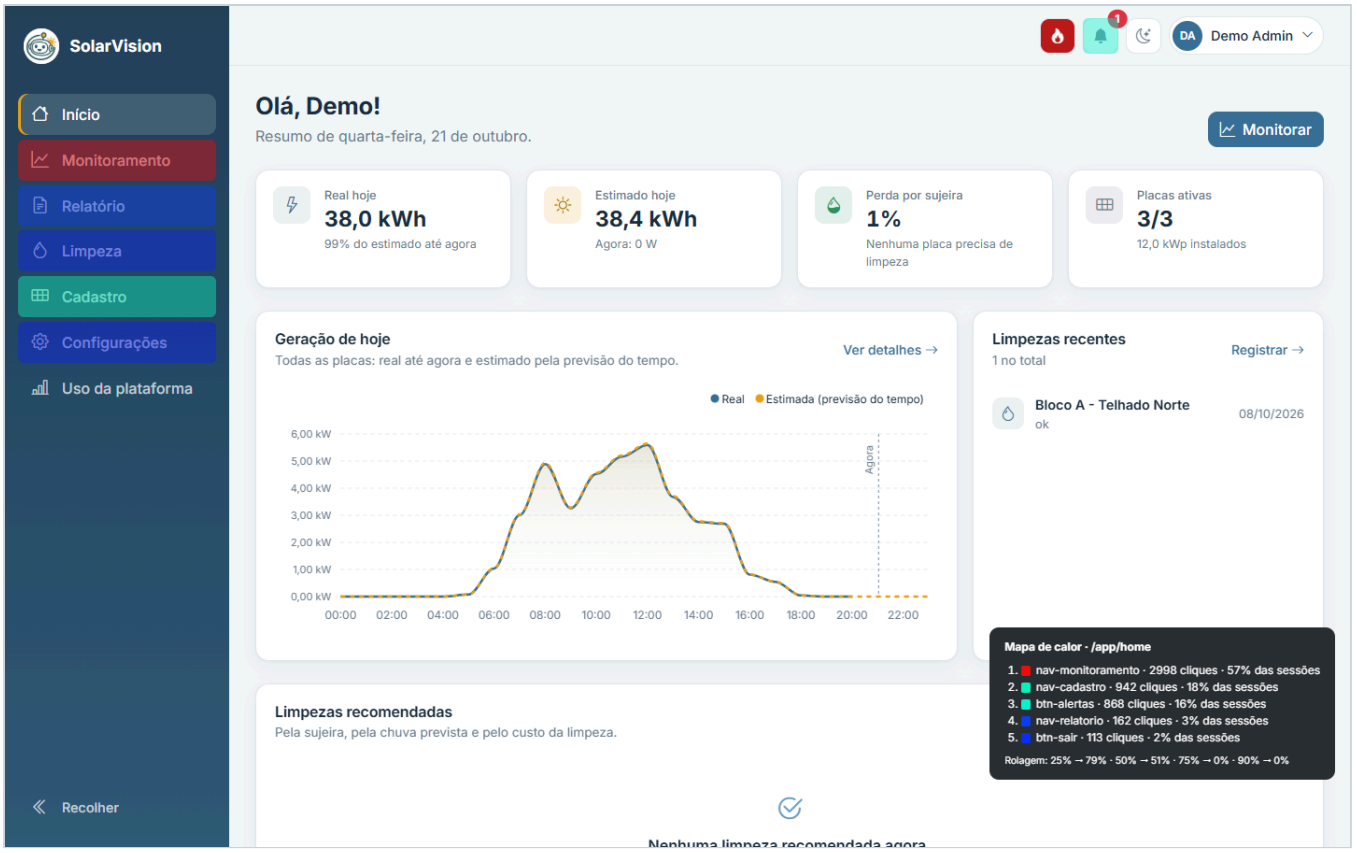
> ### E. O resultado no app (R11)
>
> O BI e o mapa de calor exportados pelo `exportar_bi`, vistos no SolarVision com um usuário ADMIN (http://localhost:5173).

27. Uso da plataforma (/app/uso)



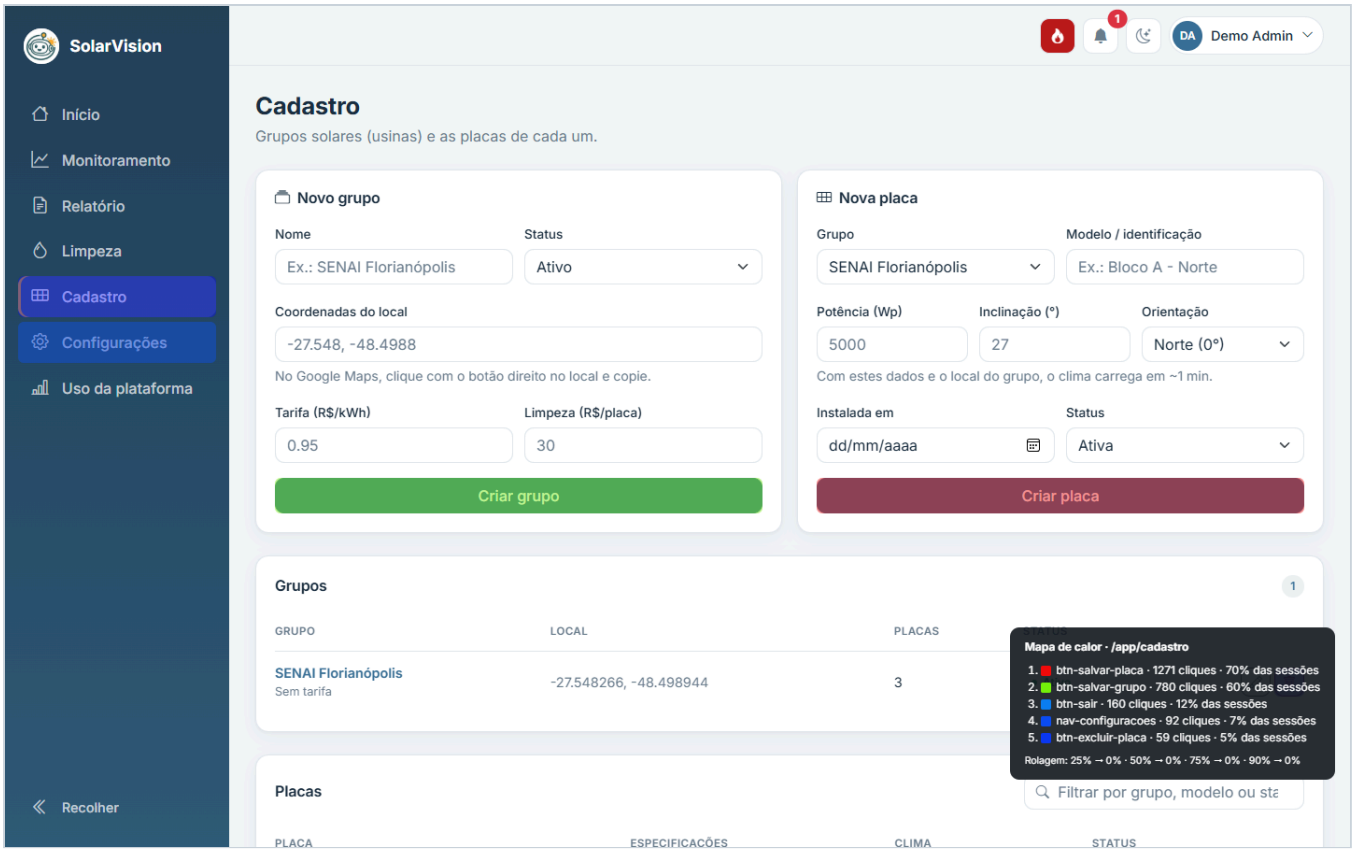
KPIs, funil de ativação, métricas e calibração do modelo, aquisição por canal (ativação, D1/D7/D14, abandono), uso das telas, buscas sem resultado e perfis do K-Means.

28. Mapa de calor · Início



Botão de fogo no cabeçalho: os elementos `data-heat` pintados de azul a vermelho pela intensidade da Gold e o resumo dos cliques e da rolagem da tela.

29. Mapa de calor · Cadastro



"Criar placa" é o botão mais quente (70% das sessões da tela), seguido de "Criar grupo" (60%).

F. Terminal

Proteção entre camadas (R2) e testes.

30. Job sem a camada anterior (R2)

```
$ docker compose run --rm -e AWS_S3_BUCKET=glue-assets app python pipeline/silver.py
s3a://glue-assets/bronze/event_name=* não existe. Rode antes: python pipeline/bronze.py
(código de saída 1)

$ docker compose run --rm -e AWS_S3_BUCKET=glue-assets app python pipeline/gold_ml.py
s3a://glue-assets/silver/event_name=* não existe. Rode antes: python pipeline/silver.py
```

Apontando para um bucket existente sem as camadas, cada job para com a mensagem de `exigir_camada` dizendo o que rodar antes.

31. Testes no contêiner

```
$ docker compose run --rm app pytest
.................................................................... [ 71%]
.................................................................... [ 94%]
.............                                                        [100%]
304 passed in 110.31s (0:01:50)
```

Gerador (jornadas, sujeira, lotes), coletor, funções de cada job (Silver, Golds, ML, exportação), `comum.py` e o explorador.