Evidências: Gold receita e a pasta de workflows

Datalake de uso do SolarVision. A receita da assinatura Pro no medalhão (PySpark sobre S3 emulado), com a etapa `05_gold_receita_aquisicao` no workflow e os workflows reunidos em `datalake/workflows/`.

> **Branch:** feat/datalake-gold-receita (a partir de feat/datalake-funil-engajamento-workflow)
>
> **Link:** https://github.com/danieltanjos/SolarVision/tree/feat/datalake-gold-receita
>
> **Execução:** Docker, 05/11/2026: floci (S3), app (PySpark 4.2) e explorador (console)
>
> **Dados:** gerador sintético padrão (seed 42, 3.000 usuários, 28 dias), agora com a assinatura Pro. São 57.894 eventos na Bronze e 55.572 válidos na Silver, em 6.450 sessões de 2.997 pessoas; 119 compras válidas e 15 reembolsos
>
> **Testes:** 343 testes Python (pytest no contêiner: gerador, coletor, pipeline, workflows e explorador), todos passando

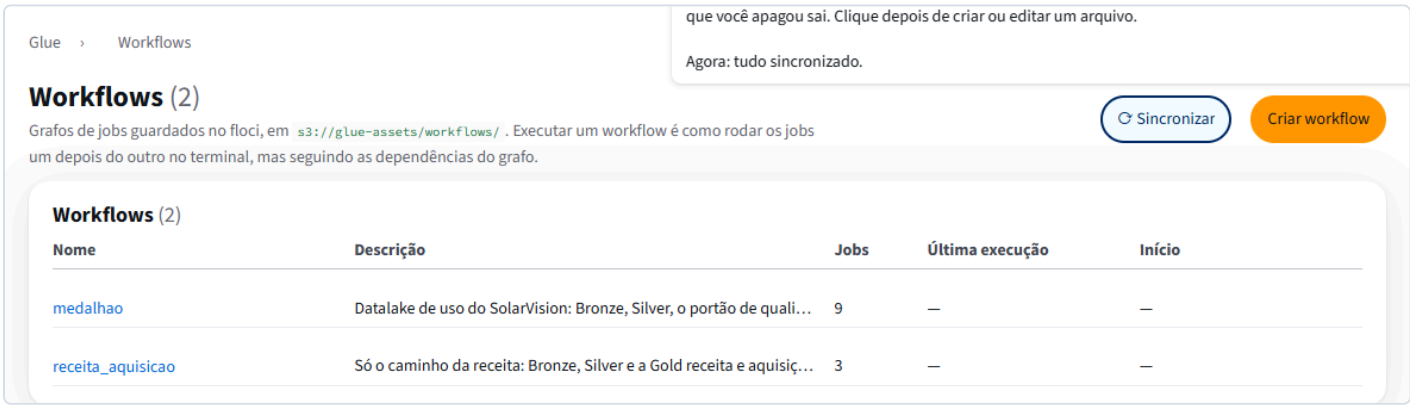
Pedido	O que entrou	Evidências
Gold receita	`pipeline/gold_receita.py`: `receita_diaria`, `taxa_reembolso`, `adesao_plano_anual`, `cadastro_para_compra` e `funil_assinatura`; eventos `begin_checkout`, `purchase` e `refund` no gerador, no contrato e na Silver	seções 3 e 4; os 5 CSVs
Workflow com `05_gold_receita_aquisicao`	`{"job": "05_gold_receita_aquisicao", "depende_de": ["02_silver_eventos"]}` no `medalhao.json`; a etapa roda `gold_aquisicao` e `gold_receita`	seções 1 e 2
Workflows numa pasta	`datalake/workflows/`: as 9 etapas numeradas, `medalhao.json` e `receita_aquisicao.json`; o explorador e o `rodar_tudo.py` leem dali	seções 1 e 2

1. A pasta de workflows

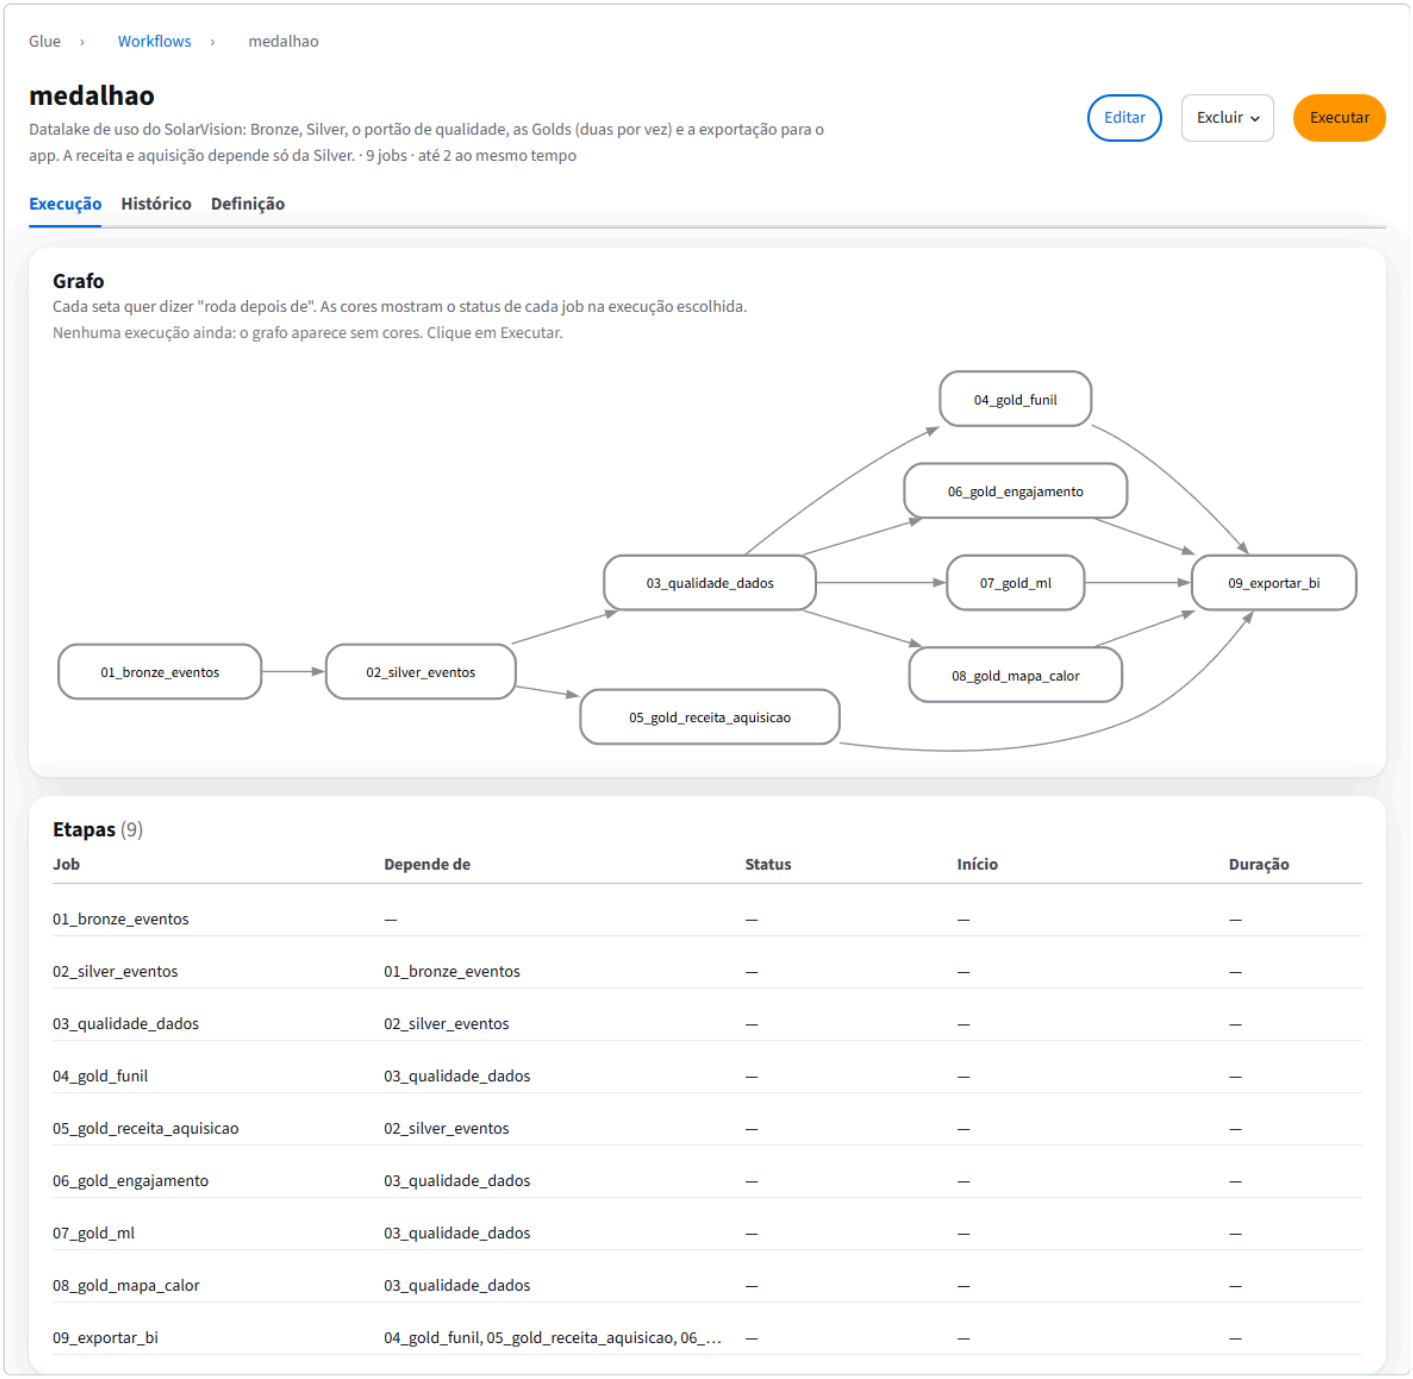
As etapas e os workflows ficam juntos em `datalake/workflows/`. Cada etapa numerada tem três linhas e chama os jobs de `pipeline/`, onde está a lógica e os testes. O explorador aponta a pasta de jobs para lá (`EXPLORADOR_JOBS=workflows`), e o `pipeline/rodar_tudo.py` (R3) segue o mesmo `medalhao.json`.

```
datalake/workflows/
├── 01_bronze_eventos.py          rodar("bronze")
├── 02_silver_eventos.py          rodar("silver")
├── 03_qualidade_dados.py         rodar("qualidade")            portão
├── 04_gold_funil.py              rodar("gold_funil")
├── 05_gold_receita_aquisicao.py  rodar("gold_aquisicao", "gold_receita")
├── 06_gold_engajamento.py        rodar("gold_engajamento")
├── 07_gold_ml.py                 rodar("gold_ml")
├── 08_gold_mapa_calor.py         rodar("gold_mapa_calor")
├── 09_exportar_bi.py             rodar("exportar_bi")
├── _etapa.py                     a ponte (começa com "_": não é job, mas vai para o floci)
├── medalhao.json                 as 9 etapas, duas Golds por vez
├── receita_aquisicao.json        01 → 02 → 05
└── README.md
```

```
workflows/medalhao.json (etapas)
{"job": "01_bronze_eventos", "depende_de": []},
{"job": "02_silver_eventos", "depende_de": ["01_bronze_eventos"]},
{"job": "03_qualidade_dados", "depende_de": ["02_silver_eventos"]},
{"job": "04_gold_funil", "depende_de": ["03_qualidade_dados"]},
{"job": "05_gold_receita_aquisicao", "depende_de": ["02_silver_eventos"]},
{"job": "06_gold_engajamento", "depende_de": ["03_qualidade_dados"]},
{"job": "07_gold_ml", "depende_de": ["03_qualidade_dados"]},
{"job": "08_gold_mapa_calor", "depende_de": ["03_qualidade_dados"]},
{"job": "09_exportar_bi", "depende_de": ["04_gold_funil", "05_gold_receita_aquisicao",
"06_gold_engajamento", "07_gold_ml", "08_gold_mapa_calor"]}
```



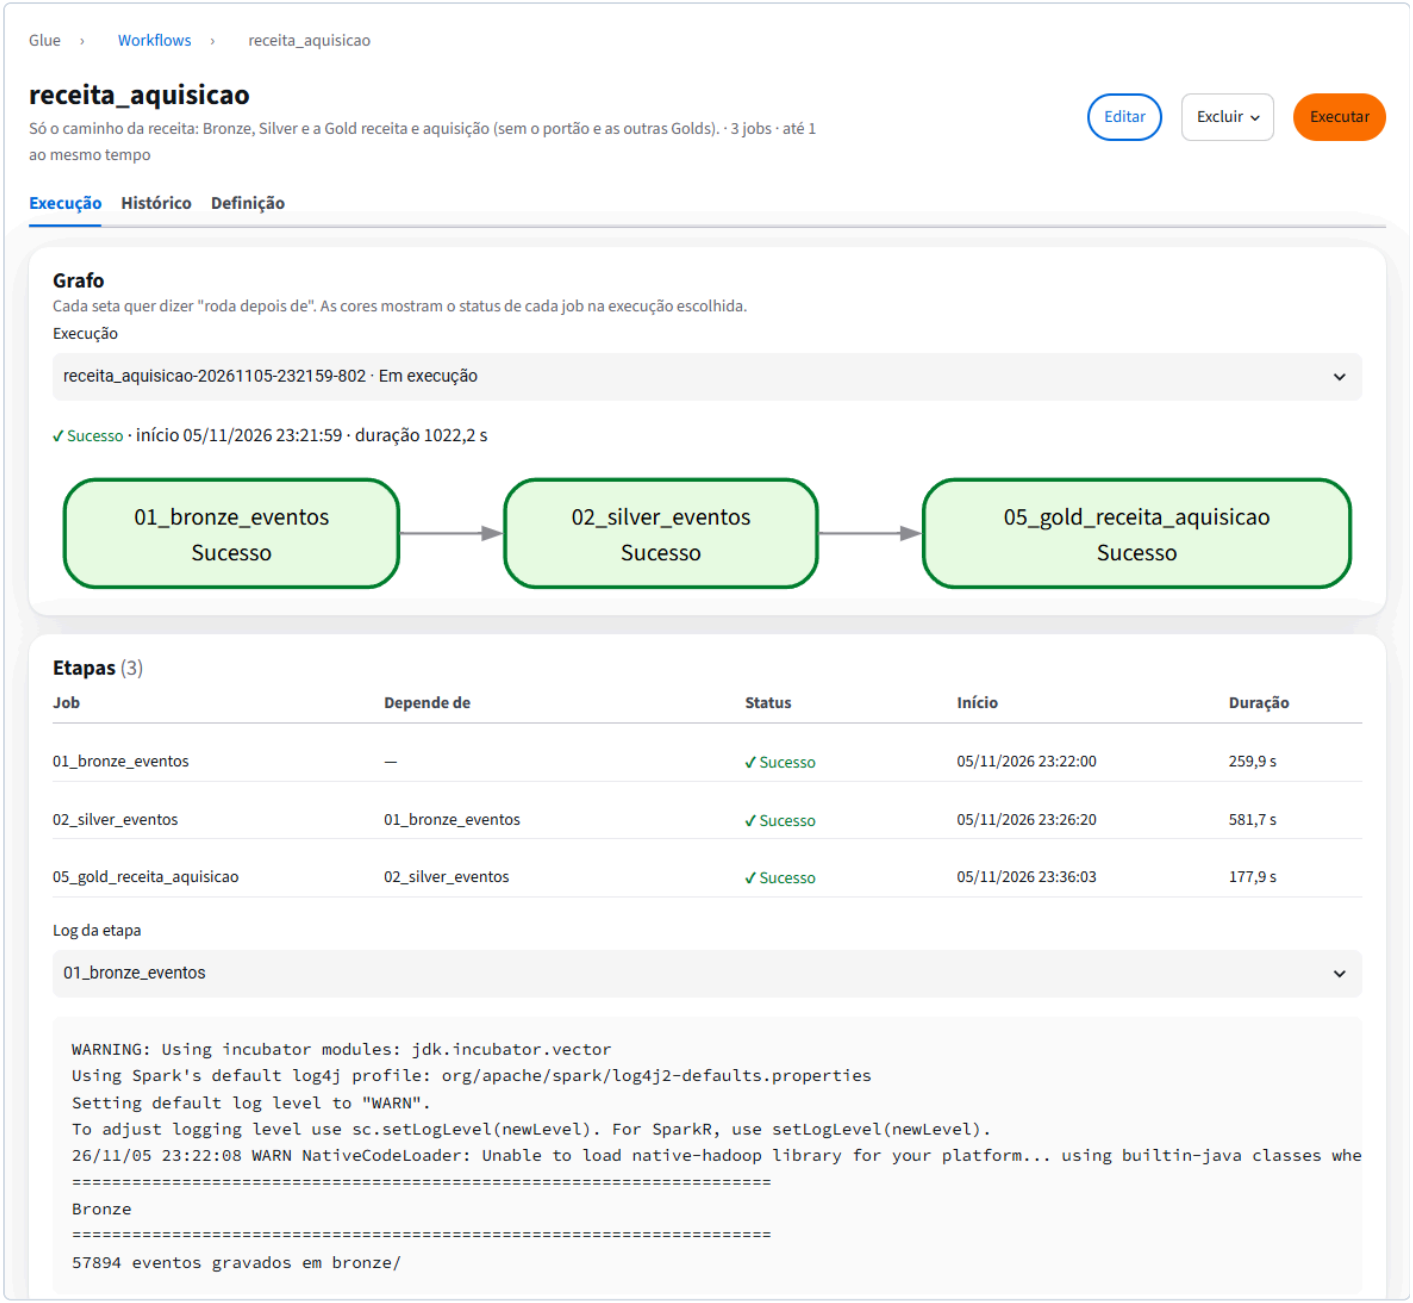
Glue · Workflows: depois do Sincronizar, o console mostra os dois workflows da pasta, `medalhao` e `receita_aquisicao`.



Glue · Workflows · medalhao: as 9 etapas numeradas. A `05_gold_receita_aquisicao` sai direto da `02_silver_eventos`, ao lado do portão `03_qualidade_dados`; as outras Golds esperam o portão, e a `09_exportar_bi` espera as cinco.

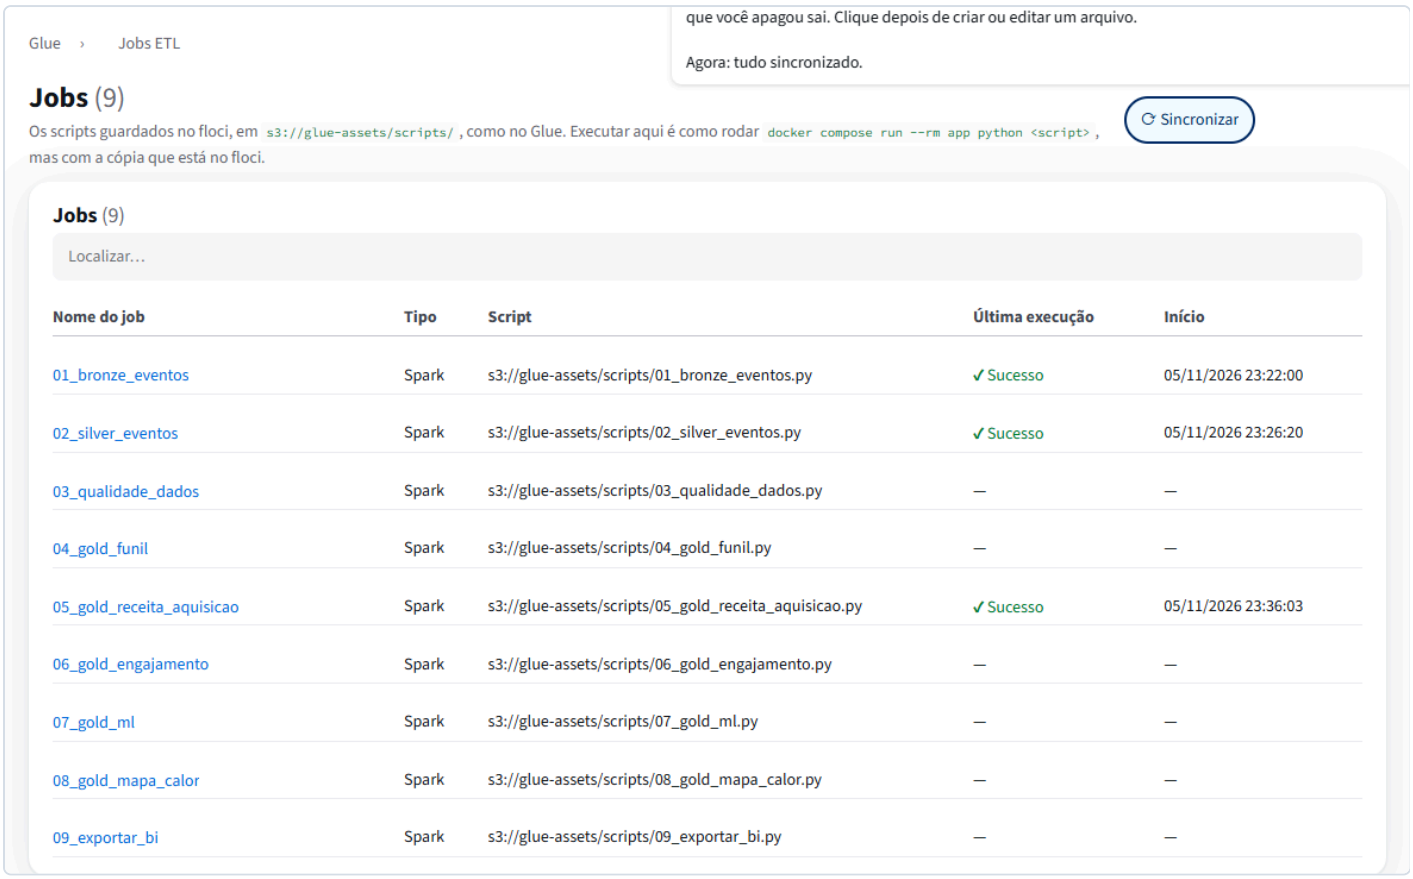
2. Execução

Workflow `receita_aquisicao` no console

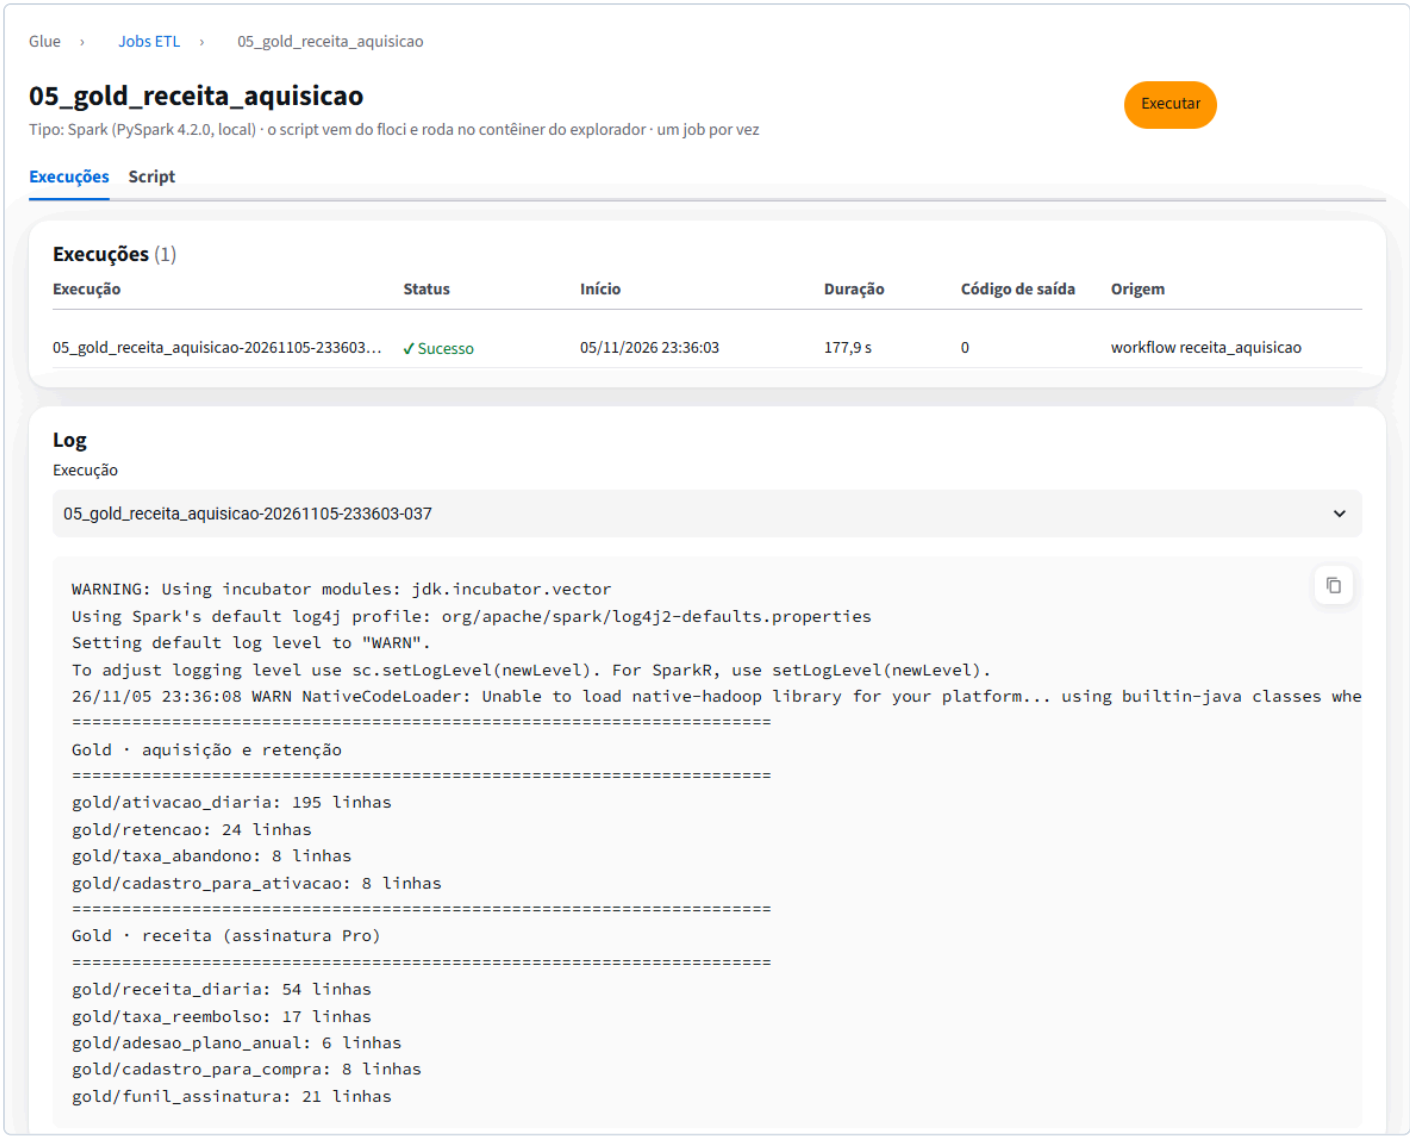


Glue · Workflows · receita_aquisicao: 01 → 02 → 05, todas com sucesso. A Bronze é append-only (R4): rodar de novo acrescenta a landing outra vez, e a Silver descarta as cópias na deduplicação (R5).

As etapas numeradas em Jobs ETL e o log da etapa 05



Glue · Jobs ETL: os jobs no floci são as etapas numeradas de `datalake/workflows/`.



Glue · Jobs ETL · 05_gold_receita_aquisicao: a execução que veio do workflow (origem `workflow receita_aquisicao`) e o log, com as 4 tabelas de aquisição e as 5 de receita.

Pipeline completo pelo script de sequência (R3), do zero

```
$ docker compose run --rm app python gerador/gerar_eventos.py
  begin_checkout           205
  purchase                 133
  refund                    17
  compra_sem_transacao       7        defeitos da receita (5% das compras)
  valor_zerado               7
  reembolso_orfao            7

$ docker compose run --rm app python pipeline/rodar_tudo.py --limpar
[ok] 01_bronze_eventos (115 s)
bronze: 57894 linhas · duplicatas descartadas: 568
silver: 55572 eventos válidos em 6450 sessões de 2997 pessoas
  reembolso órfão                      9
[ok] 02_silver_eventos (271 s)
[  ok  ] taxa de rejeição                                        0.0306  (limite <= 0.1)
[  ok  ] taxa de duplicatas                                      0.0098  (limite <= 0.05)
[ok] 03_qualidade_dados (63 s)
Gold · aquisição e retenção
gold/ativacao_diaria: 195 linhas · gold/retencao: 24 · gold/taxa_abandono: 8 ·
gold/cadastro_para_ativacao: 8
Gold · receita (assinatura Pro)
gold/receita_diaria: 54 linhas
gold/taxa_reembolso: 17 linhas
gold/adesao_plano_anual: 6 linhas
gold/cadastro_para_compra: 8 linhas
gold/funil_assinatura: 21 linhas
[ok] 05_gold_receita_aquisicao (110 s)
[ok] 04_gold_funil (82 s)
[ok] 06_gold_engajamento (72 s)
[ok] 07_gold_ml (83 s)
[ok] 08_gold_mapa_calor (60 s)
[ok] 09_exportar_bi (25 s)
9 jobs concluídos: 01_bronze_eventos, 02_silver_eventos, 03_qualidade_dados, 05_gold_receita_aquisicao,
04_gold_funil, 06_gold_engajamento, 07_gold_ml, 08_gold_mapa_calor, 09_exportar_bi.
```

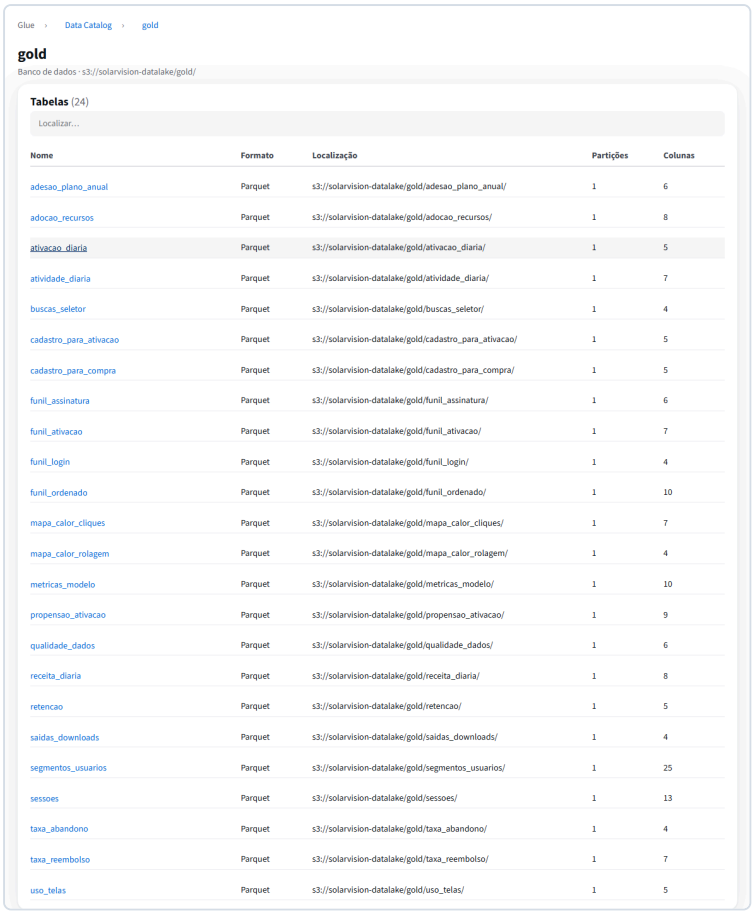
A 05 roda logo depois do portão, no mesmo nível dele no grafo, porque só depende da Silver. As sessões (6.450) e as pessoas (2.997) são as mesmas da entrega anterior: a receita só continua sessões que já existiam e tem rng próprio no gerador.

Reprocessamento parcial a partir da etapa 05

Mudou só a receita? `--a-partir-de` roda a etapa e as que dependem dela, sem refazer Bronze, Silver e portão.

```
$ docker compose run --rm app python pipeline/rodar_tudo.py --a-partir-de 05_gold_receita_aquisicao
[ok] 05_gold_receita_aquisicao (108 s)
[ok] 09_exportar_bi (21 s)
2 jobs concluídos: 05_gold_receita_aquisicao, 09_exportar_bi.
```

3. Gold receita



Glue › Data Catalog › gold

gold

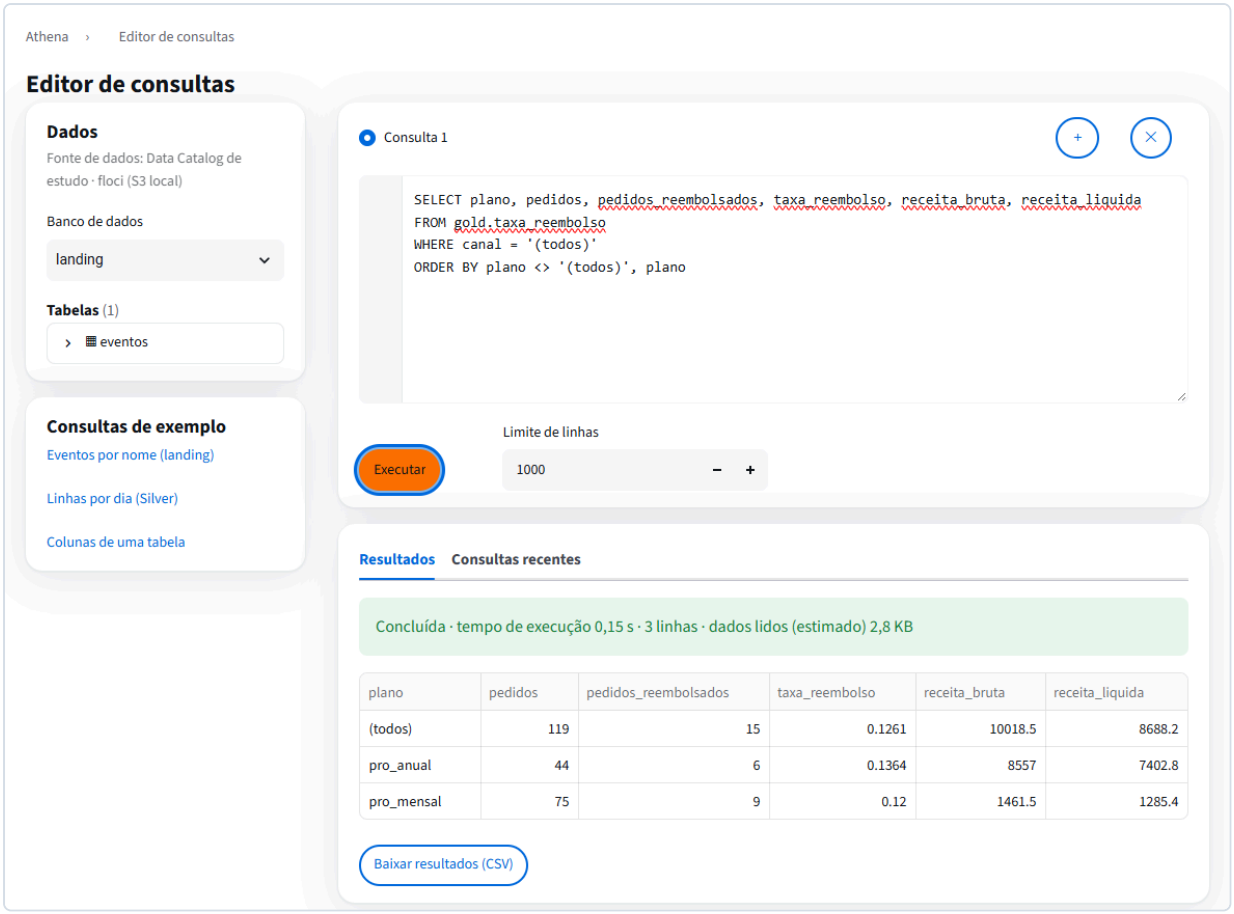
Banco de dados · s3://solarvision-datalake/gold/

Tabelas (24)

Localizar...

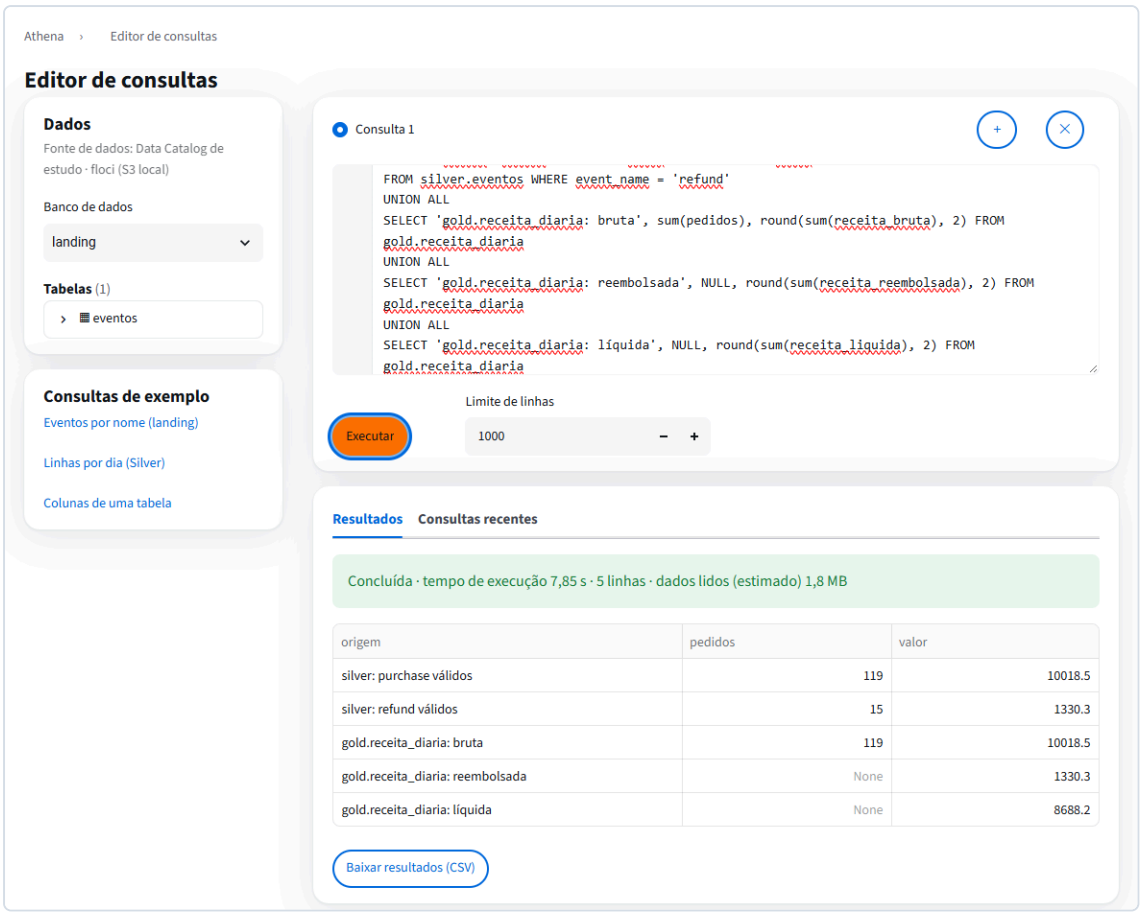
Nome	Formato	Localização	Partições	Colunas
adesao_plano_anual	Parquet	s3://solarvision-datalake/gold/adesao_plano_anual/	1	6
adocao_recursos	Parquet	s3://solarvision-datalake/gold/adocao_recursos/	1	8
ativacao_diaria	Parquet	s3://solarvision-datalake/gold/ativacao_diaria/	1	5
atividade_diaria	Parquet	s3://solarvision-datalake/gold/atividade_diaria/	1	7
buscas_seletor	Parquet	s3://solarvision-datalake/gold/buscas_seletor/	1	4
cadastro_para_ativacao	Parquet	s3://solarvision-datalake/gold/cadastro_para_ativacao/	1	5
cadastro_para_compra	Parquet	s3://solarvision-datalake/gold/cadastro_para_compra/	1	5
funil_assinatura	Parquet	s3://solarvision-datalake/gold/funil_assinatura/	1	6
funil_ativacao	Parquet	s3://solarvision-datalake/gold/funil_ativacao/	1	7
funil_login	Parquet	s3://solarvision-datalake/gold/funil_login/	1	4
funil_ordenado	Parquet	s3://solarvision-datalake/gold/funil_ordenado/	1	10
mapa_calor_cliques	Parquet	s3://solarvision-datalake/gold/mapa_calor_cliques/	1	7
mapa_calor_rolagem	Parquet	s3://solarvision-datalake/gold/mapa_calor_rolagem/	1	4
metricas_modelo	Parquet	s3://solarvision-datalake/gold/metricas_modelo/	1	10
propensao_ativacao	Parquet	s3://solarvision-datalake/gold/propensao_ativacao/	1	9
qualidade_dados	Parquet	s3://solarvision-datalake/gold/qualidade_dados/	1	6
receita_diaria	Parquet	s3://solarvision-datalake/gold/receita_diaria/	1	8
retencao	Parquet	s3://solarvision-datalake/gold/retencao/	1	5
saidas_downloads	Parquet	s3://solarvision-datalake/gold/saidas_downloads/	1	4
segmentos_usuarios	Parquet	s3://solarvision-datalake/gold/segmentos_usuarios/	1	25
sessoes	Parquet	s3://solarvision-datalake/gold/sessoes/	1	13
taxa_abandono	Parquet	s3://solarvision-datalake/gold/taxa_abandono/	1	4
taxa_reembolso	Parquet	s3://solarvision-datalake/gold/taxa_reembolso/	1	7
uso_telas	Parquet	s3://solarvision-datalake/gold/uso_telas/	1	5

Glue · Data Catalog · gold: 24 tabelas, com as 5 novas da receita (`receita_diaria`, `taxa_reembolso`, `adesao_plano_anual`, `cadastro_para_compra`, `funil_assinatura`).

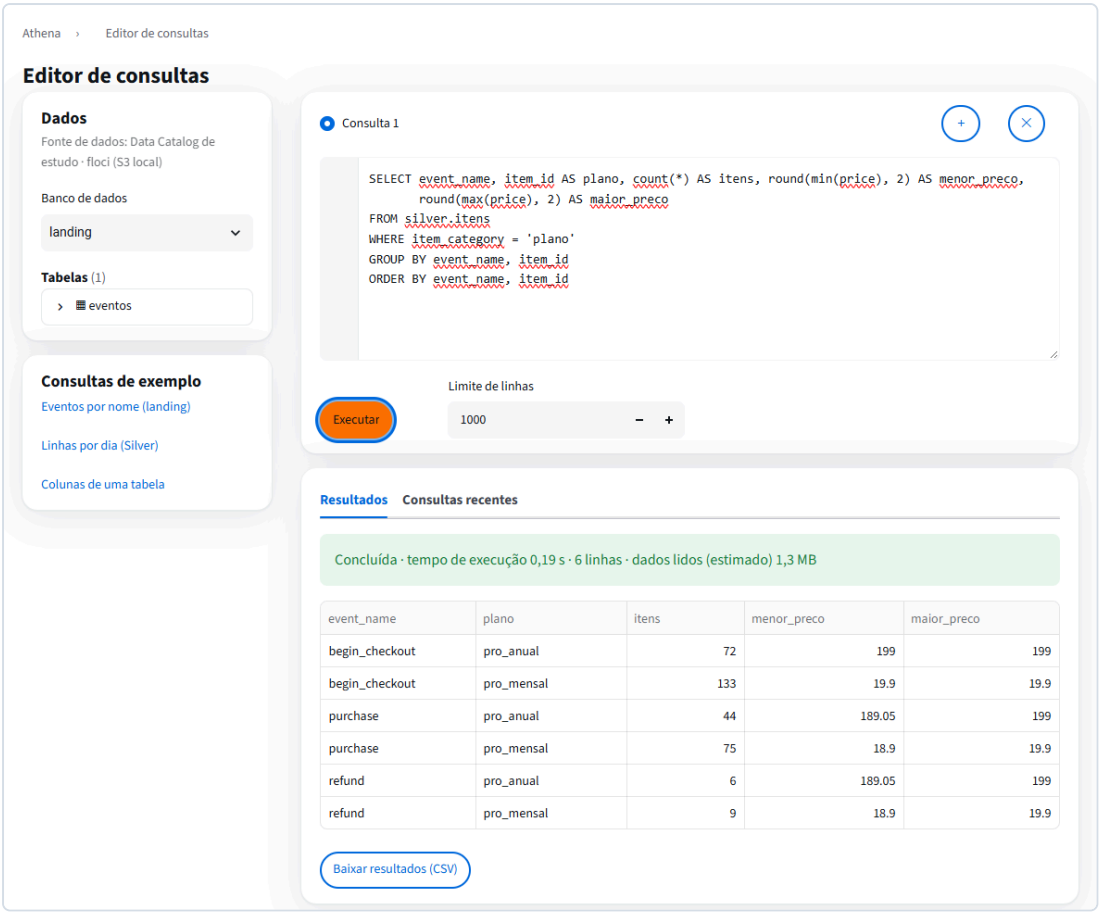


Receita por plano (`gold.taxa_reembolso`, canal = todos): 119 pedidos, R$ 10.018,50 de receita bruta e R$ 8.688,20 de líquida; 12,6% dos pedidos reembolsados. O anual é 37% dos pedidos e 85% da receita.

Reconciliação: a Gold fecha com a Silver

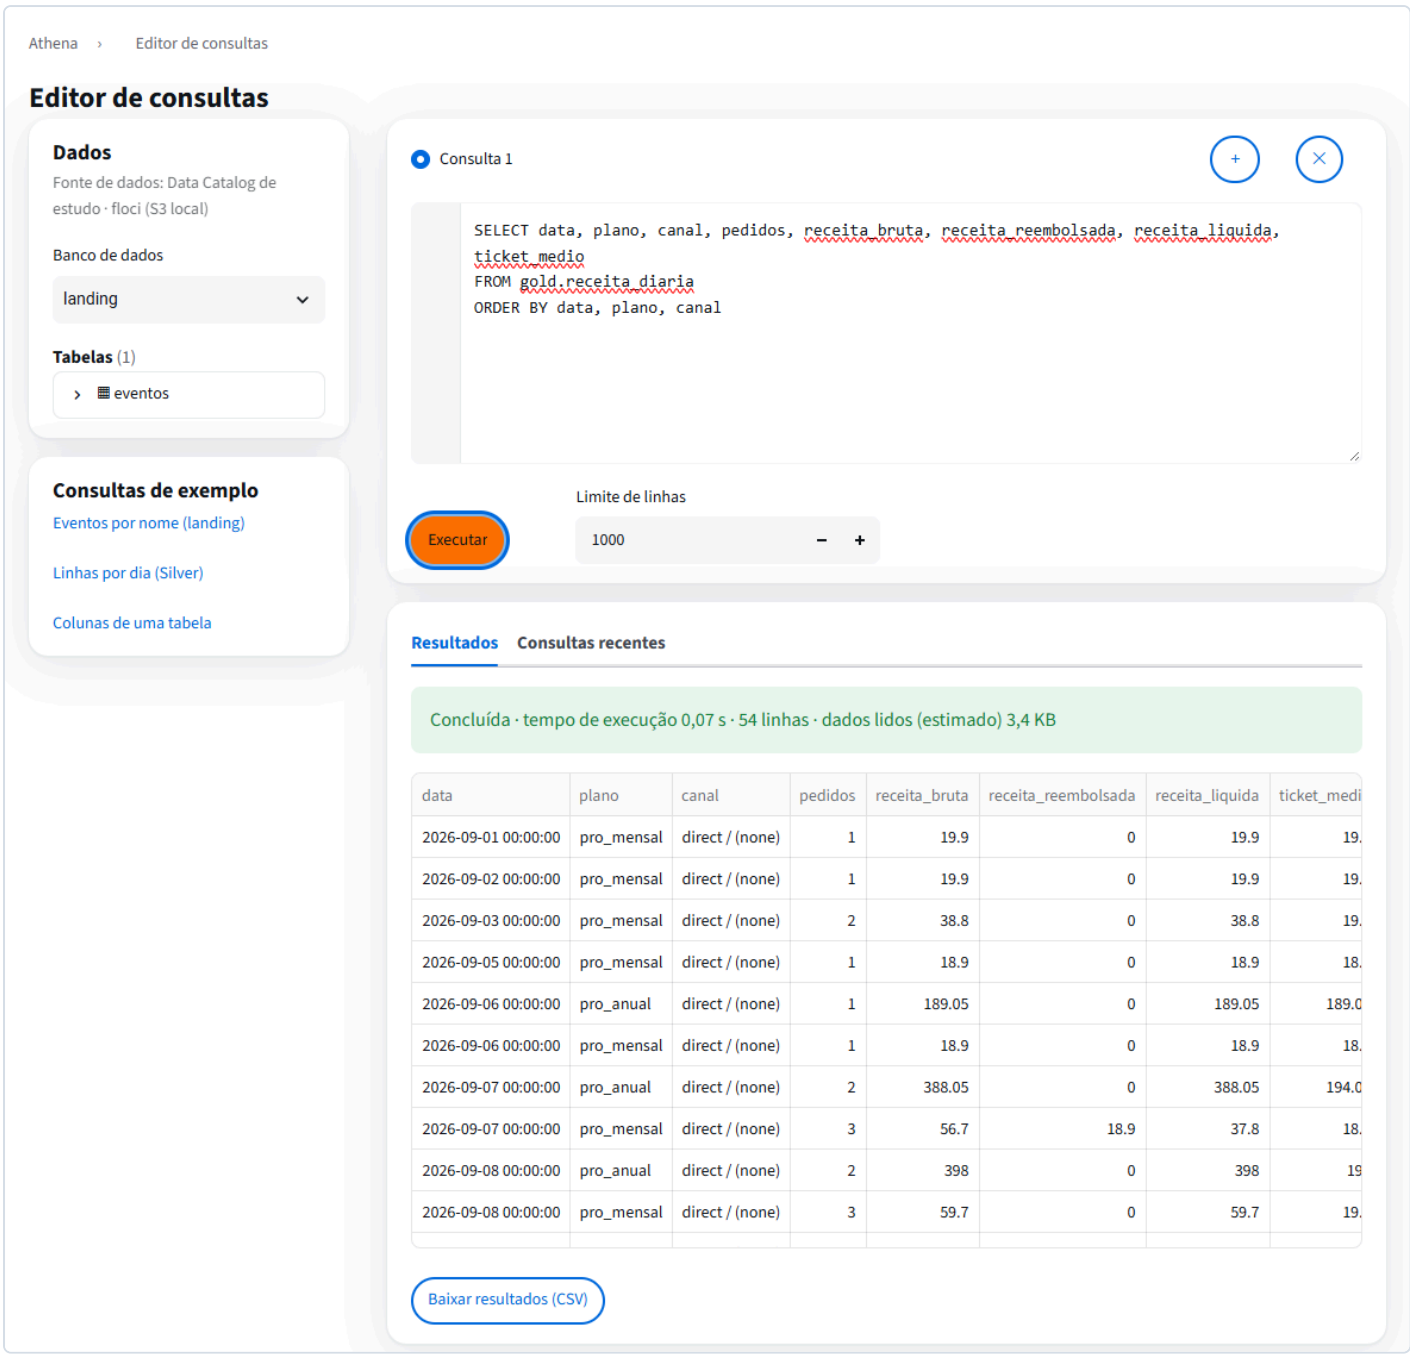


As 119 compras válidas da Silver somam R$ 10.018,50, a mesma receita bruta da `gold.receita_diaria`; os 15 reembolsos válidos somam R$ 1.330,30, a reembolsada; a líquida é a diferença (R$ 8.688,20).



`silver.itens` (R10): o plano entra como item de categoria `plano`, com o preço pago (R$ 18,90 e R$ 189,05 no Pix).

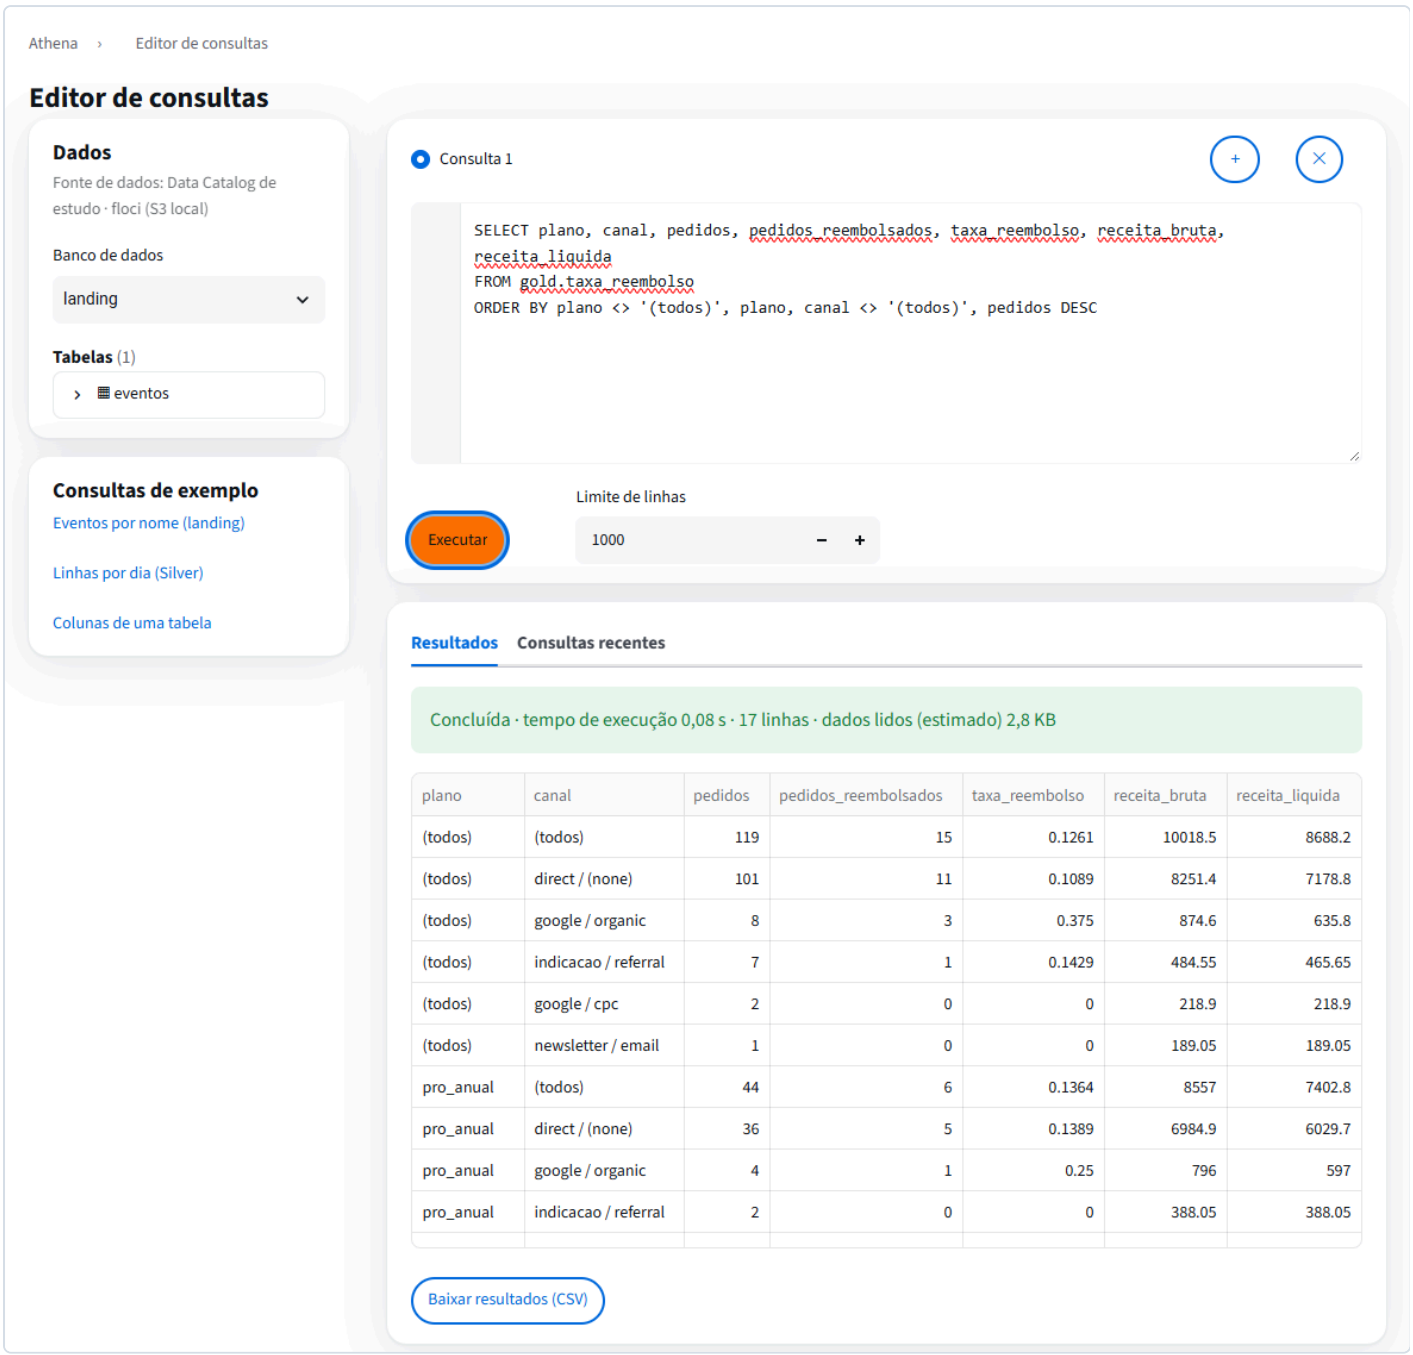
Receita por dia, plano e canal (receita_diaria.csv)



data	plano	canal	pedidos	receita_bruta	receita_reembolsada	receita_liquida	ticket_medi
2026-09-01 00:00:00	pro_mensal	direct / (none)	1	19.9	0	19.9	19.
2026-09-02 00:00:00	pro_mensal	direct / (none)	1	19.9	0	19.9	19.
2026-09-03 00:00:00	pro_mensal	direct / (none)	2	38.8	0	38.8	19.
2026-09-05 00:00:00	pro_mensal	direct / (none)	1	18.9	0	18.9	18.
2026-09-06 00:00:00	pro_anual	direct / (none)	1	189.05	0	189.05	189.0
2026-09-06 00:00:00	pro_mensal	direct / (none)	1	18.9	0	18.9	18.
2026-09-07 00:00:00	pro_anual	direct / (none)	2	388.05	0	388.05	194.0
2026-09-07 00:00:00	pro_mensal	direct / (none)	3	56.7	18.9	37.8	18.
2026-09-08 00:00:00	pro_anual	direct / (none)	2	398	0	398	19
2026-09-08 00:00:00	pro_mensal	direct / (none)	3	59.7	0	59.7	19.

`gold.receita_diaria`: 54 linhas. O reembolso fica na data da compra (atribuído pelo `transaction_id`).

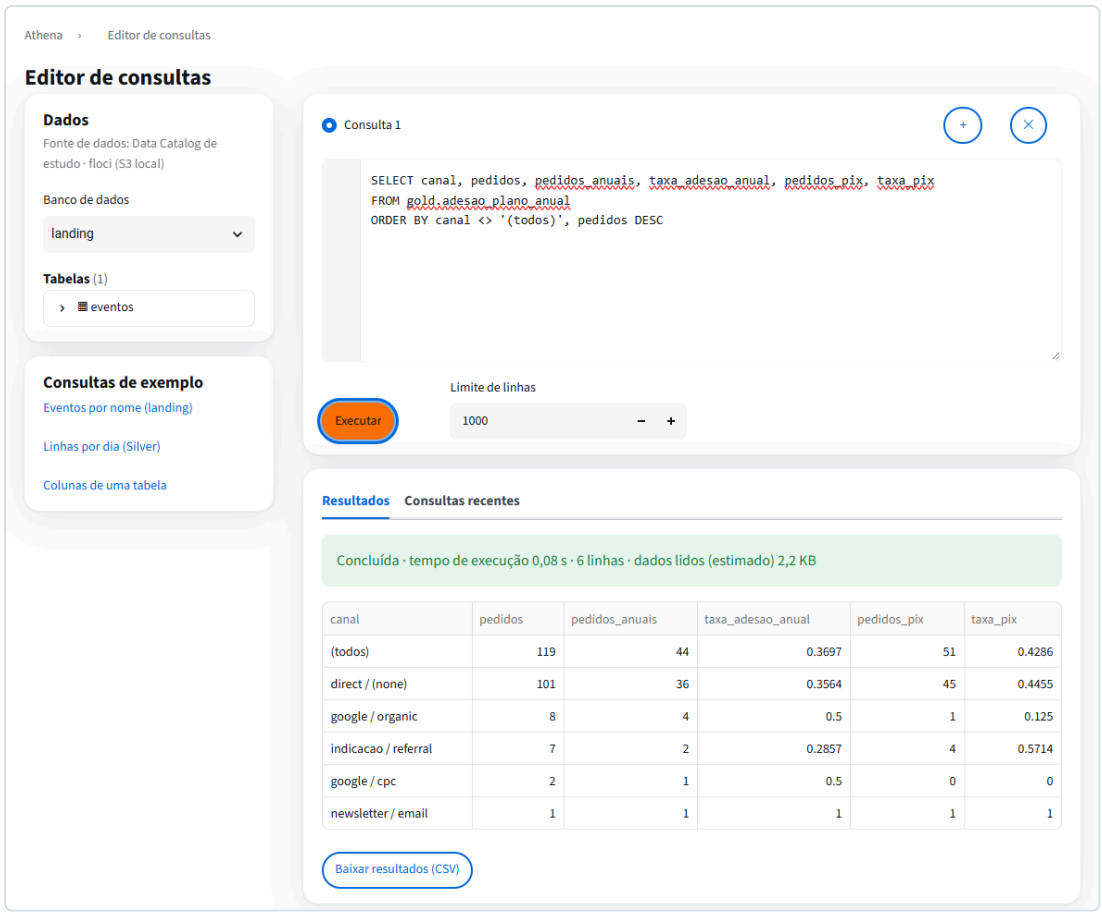
Reembolso por plano e canal (taxa_reembolso.csv)



plano	canal	pedidos	pedidos_reembolsados	taxa_reembolso	receita_bruta	receita_liquida
(todos)	(todos)	119	15	0.1261	10018.5	8688.2
(todos)	direct / (none)	101	11	0.1089	8251.4	7178.8
(todos)	google / organic	8	3	0.375	874.6	635.8
(todos)	indicacao / referral	7	1	0.1429	484.55	465.65
(todos)	google / cpc	2	0	0	218.9	218.9
(todos)	newsletter / email	1	0	0	189.05	189.05
pro_anual	(todos)	44	6	0.1364	8557	7402.8
pro_anual	direct / (none)	36	5	0.1389	6984.9	6029.7
pro_anual	google / organic	4	1	0.25	796	597
pro_anual	indicacao / referral	2	0	0	388.05	388.05

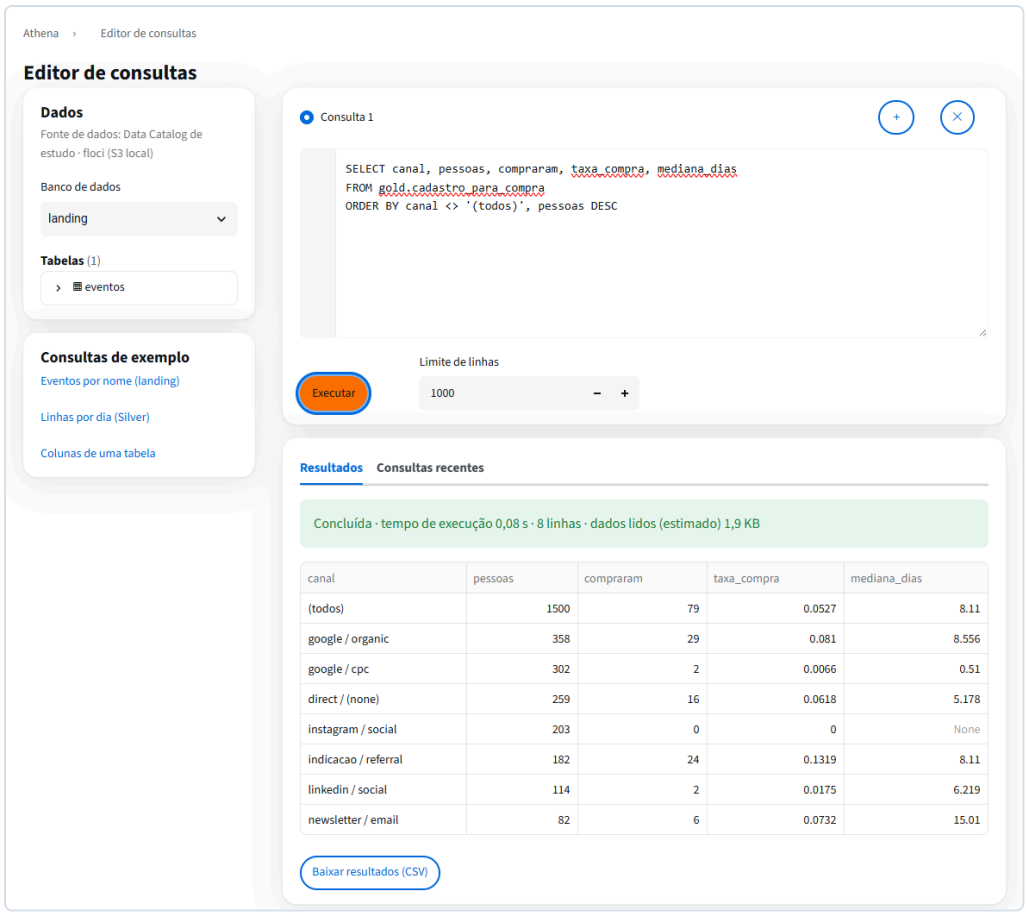
`gold.taxa_reembolso`: plano × canal, cada plano, cada canal e o total (cube). 85% das compras vêm de `direct / (none)`: quem assina já é usuário e volta pelo favorito.

Plano anual e Pix (adesao_plano_anual.csv)



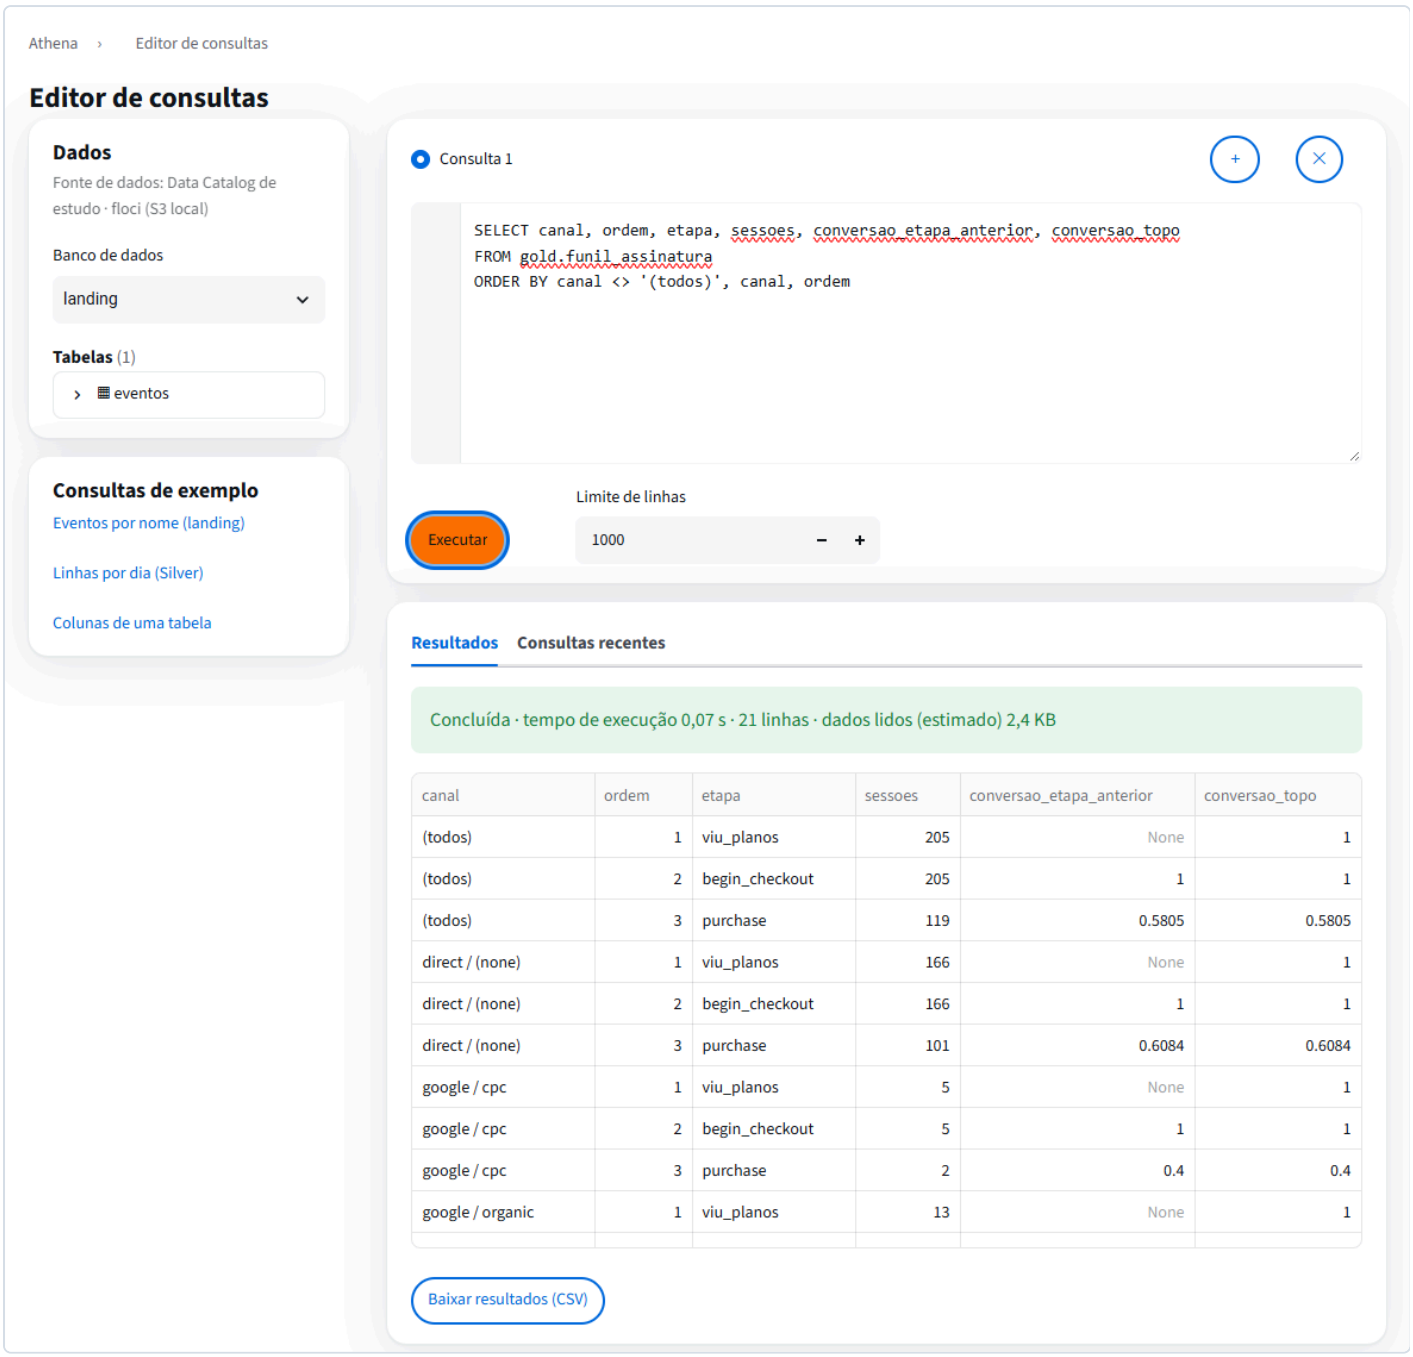
`gold.adesao_plano_anual`: 37,0% dos pedidos no anual e 42,9% pagos no Pix.

Do cadastro à compra (cadastro_para_compra.csv)



`gold.cadastro_para_compra`, pelo canal do cadastro: 79 das 1.500 contas novas compraram (5,3%), com mediana de 8,1 dias. A indicação converte 13,2%; o Google pago, 0,7%; o Instagram, nada.

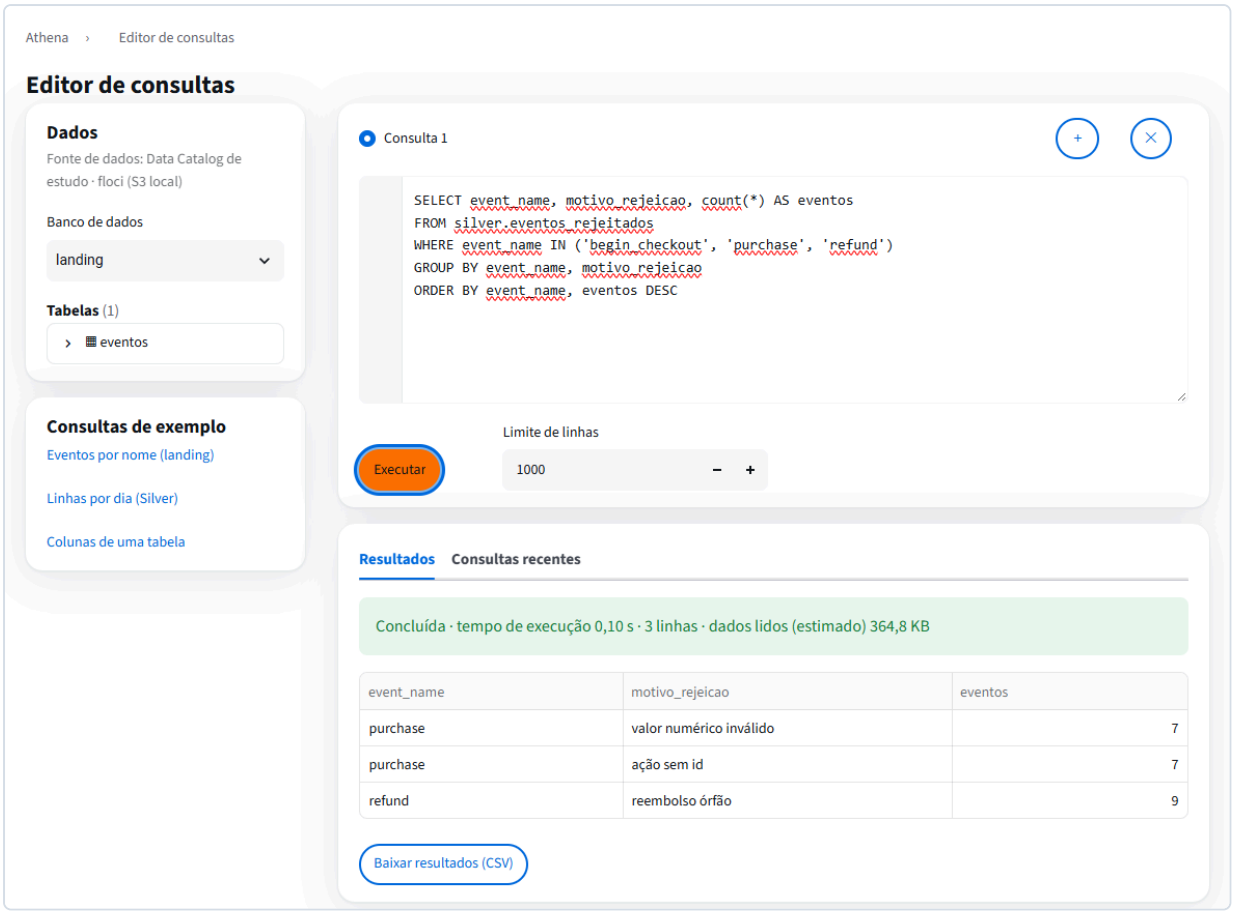
Funil da assinatura (funil_assinatura.csv)



canal	ordem	etapa	sessoes	conversao_etapa_anterior	conversao_topo
(todos)	1	viu_planos	205	None	1
(todos)	2	begin_checkout	205	1	1
(todos)	3	purchase	119	0.5805	0.5805
direct / (none)	1	viu_planos	166	None	1
direct / (none)	2	begin_checkout	166	1	1
direct / (none)	3	purchase	101	0.6084	0.6084
google / cpc	1	viu_planos	5	None	1
google / cpc	2	begin_checkout	5	1	1
google / cpc	3	purchase	2	0.4	0.4
google / organic	1	viu_planos	13	None	1

`gold.funil_assinatura`, por sessão e em qualquer momento: 205 sessões viram os planos e começaram o checkout; 119 pagaram (58,0%).

4. Qualidade do dado da receita (Silver, R7)



`silver.eventos_rejeitados` da receita: as compras sem `transaction_id` (ação sem id), com valor zerado (valor numérico inválido) e os reembolsos órfãos. São 9 órfãos: os 7 injetados e 2 em cascata, reembolsos de compras que a própria Silver rejeitou.

Regra nova	Condição	Defeito do gerador
ação sem id	`purchase`/`refund` sem `transaction_id`	`compra_sem_transacao` (7)
valor numérico inválido	`value` nulo ou ≤ 0 em `begin_checkout`, `purchase` ou `refund`	`valor_zerado` (7)
reembolso órfão	`refund` sem `purchase` válido do mesmo `transaction_id`	`reembolso_orfao` (7) + 2 em cascata

As contagens fecham: 57.326 eventos únicos = 55.572 válidos + 1.754 rejeitados, e o portão passou (rejeição 3,06%, duplicatas 0,98%).

5. Leitura e arquivos

- **Quanto rende:** R$ 8.688,20 líquidos em 28 dias; os reembolsos levaram 13,3% da bruta.
- **Qual canal traz quem paga:** pelo canal do cadastro, a indicação (13,2%) converte 20 vezes mais que o Google pago (0,7%), e o Instagram não trouxe pagante. É a mesma conclusão da retenção, agora em reais.
- **Quando oferecer:** a compra vem cerca de 8 dias depois do cadastro, quando a pessoa já acompanha a usina: a oferta do Pro deve ir no Monitoramento e no Relatório a partir da segunda semana.

> A assinatura Pro é uma hipótese de monetização do MVP: o app ainda não cobra. Os eventos vêm do gerador sintético, com o formato fixado no contrato (`datalake/docs/CONTRATO_EVENTO.md`), para o checkout real emitir os mesmos campos.

Código, testes e estes arquivos na branch: https://github.com/danieltanjos/SolarVision/tree/feat/datalake-gold-receita. Os CSVs e este PDF estão em `datalake/evidencias/gold-receita/`: `receita_diaria.csv`, `taxa_reembolso.csv`, `adesao_plano_anual.csv`, `cadastro_para_compra.csv` e `funil_assinatura.csv`.