Evidências: funil, engajamento e workflow

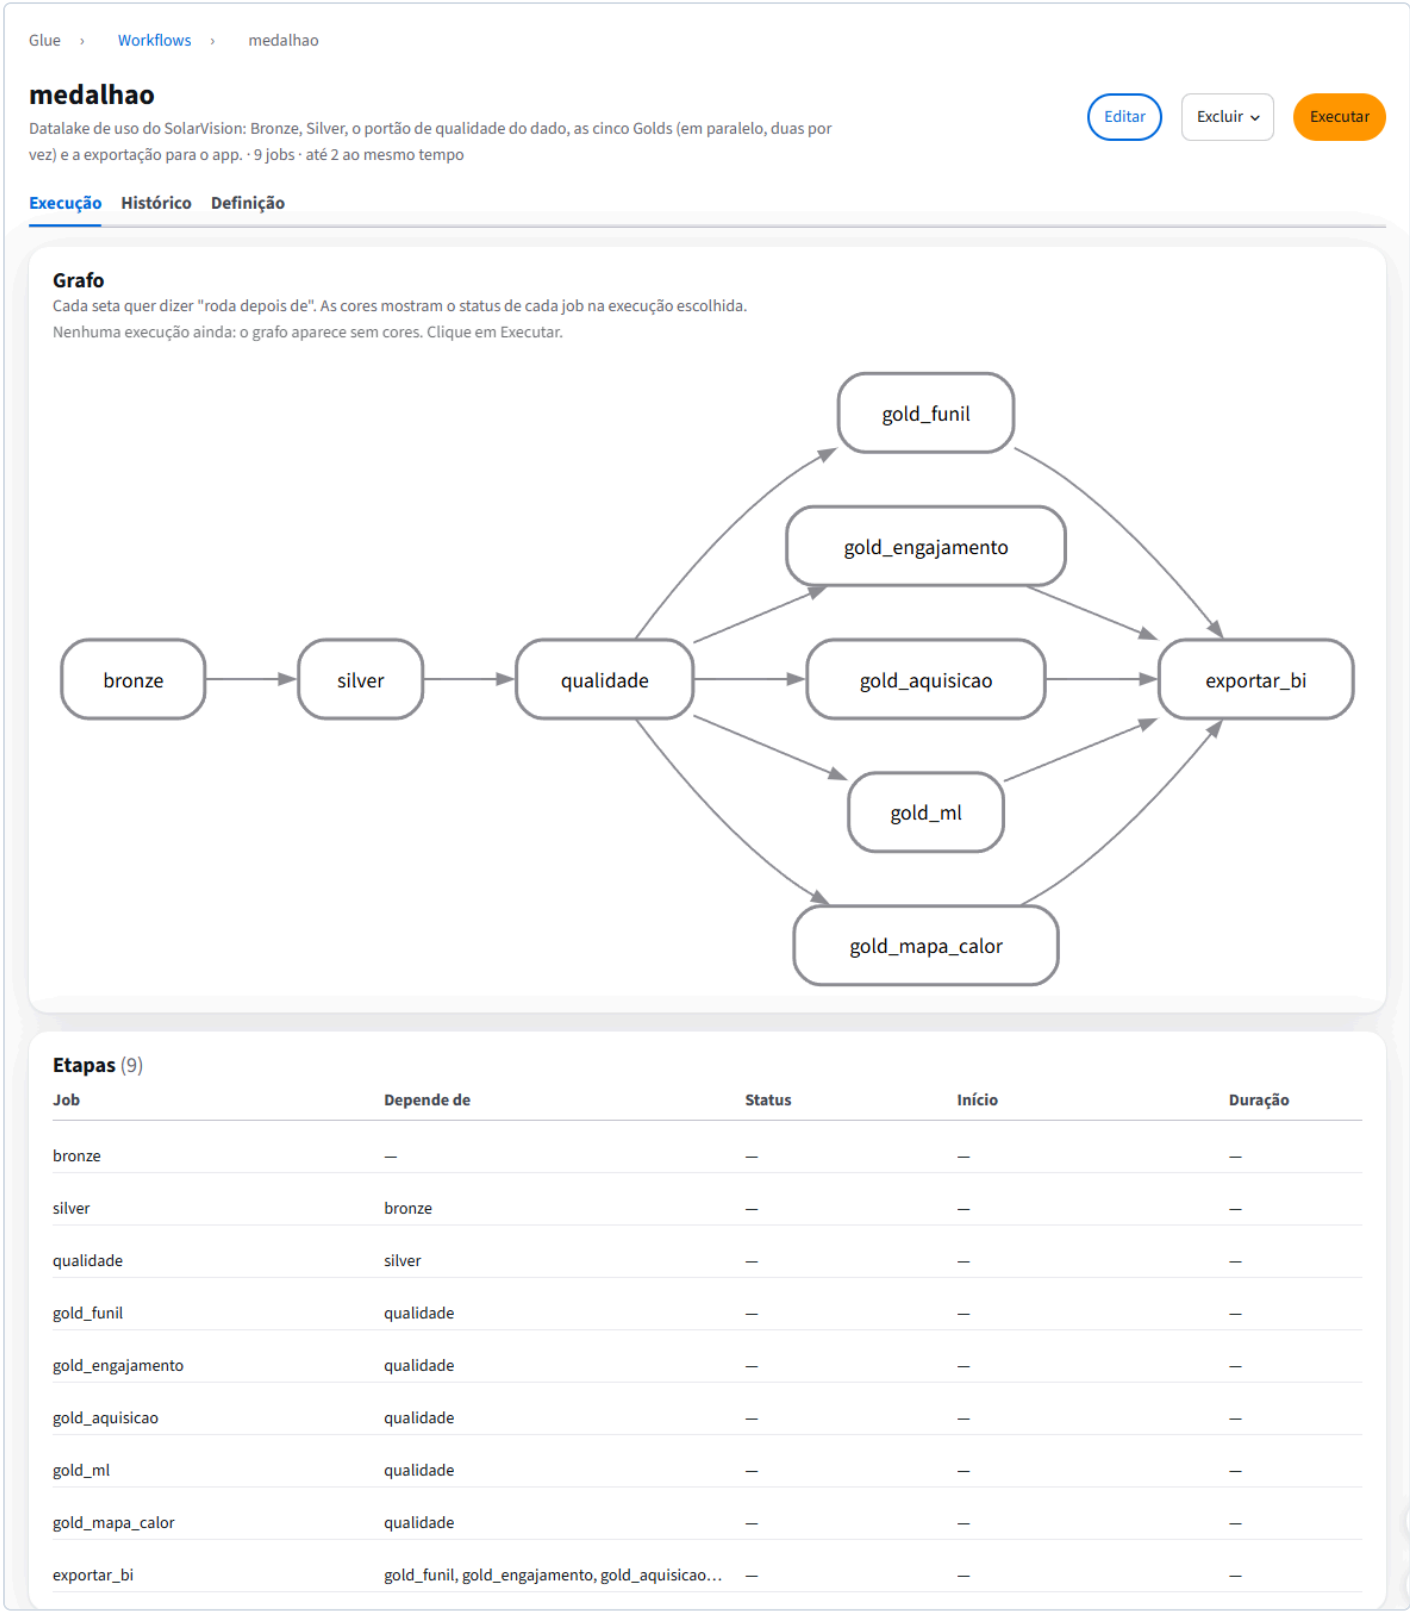
Datalake de uso do SolarVision. Conceitos das aulas de Big Data aplicados ao pipeline medalhão (PySpark sobre S3 emulado).

> **Branch:** feat/datalake-funil-engajamento-workflow (a partir de feat/datalake-uso)
> **Link:** https://github.com/danieltanjos/SolarVision/tree/feat/datalake-funil-engajamento-workflow
> **Execução:** Docker, 04 e 05/11/2026: floci (S3), app (PySpark 4.2) e explorador (console)
> **Dados:** gerador sintético padrão, com 3.000 usuários e 28 dias. São 57.094 eventos na Bronze e 54.789 válidos na Silver, em 6.450 sessões de 2.997 pessoas
> **Testes:** 321 testes Python (pytest no contêiner) e 76 do frontend, todos passando

Conceito	O que entrou	Evidências
Workflow	job `qualidade` como portão entre a Silver e as Golds; `rodar_tudo.py` guiado pelo grafo do `medalhao.json`; reprocessamento parcial com `--a-partir-de`	seção 1, CSV `qualidade_dados.csv`
Funil	`gold/funil_ordenado`: etapas na ordem, pessoas perdidas, tempo desde a etapa anterior e maior vazamento	seção 2, CSV `funil_ordenado.csv`
Engajamento	`gold/adocao_recursos` e `gold/atividade_diaria` (DAU, WAU, MAU e aderência)	seção 3, CSVs `adocao_recursos.csv` e `atividade_diaria.csv`
Data Storytelling	painel `/app/uso` com os novos cartões	seção 4

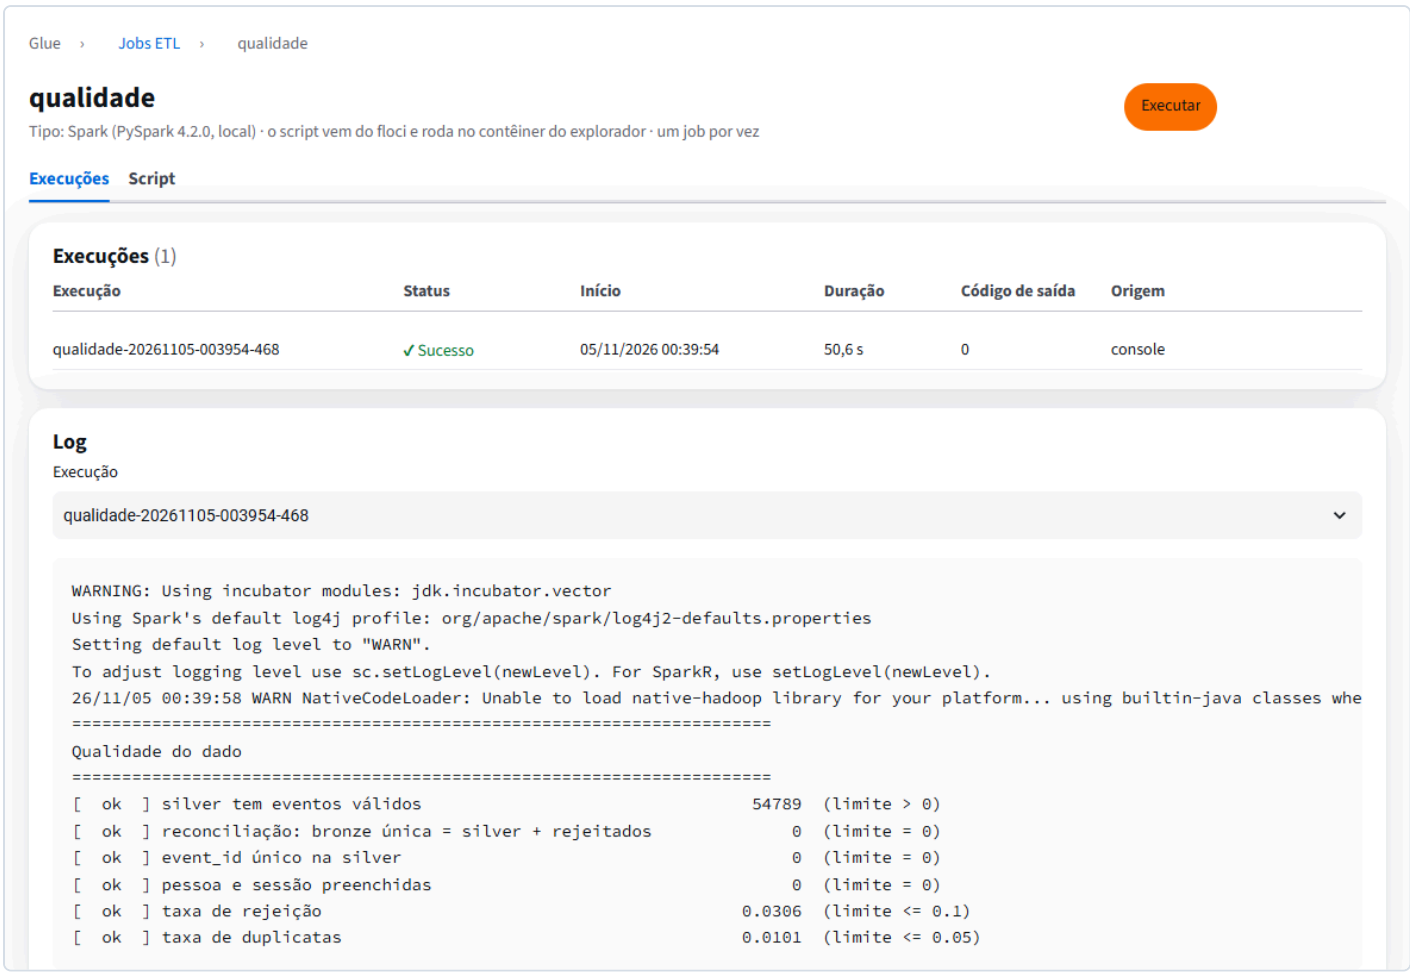
1. Workflow

O workflow é o grafo de dependências entre os jobs: um job só roda quando os de que depende terminaram com sucesso, e se uma etapa falha nada depois dela roda. Entre a Silver e as cinco Golds entrou o portão de qualidade.



Console do datalake, Glue · Workflows · medalhao: 9 jobs, com o `qualidade` entre a `silver` e as cinco Golds, e o `exportar_bi` depois de todas.

Execução do portão no console



Glue · Jobs ETL · qualidade: o job roda no console, termina com sucesso (código 0) e o log mostra as 6 regras.

Pipeline completo pelo script de sequência (R3), na ordem do grafo

```
$ docker compose run --rm app python pipeline/rodar_tudo.py
[ok] bronze (88 s)
[ok] silver (237 s)
[  ok  ] silver tem eventos válidos                              54789  (limite > 0)
[  ok  ] reconciliação: bronze única = silver + rejeitados           0  (limite = 0)
[  ok  ] event_id único na silver                                    0  (limite = 0)
[  ok  ] pessoa e sessão preenchidas                                 0  (limite = 0)
[  ok  ] taxa de rejeição                                       0.0306  (limite <= 0.1)
[  ok  ] taxa de duplicatas                                     0.0101  (limite <= 0.05)
[ok] qualidade (44 s)
[ok] gold_funil (60 s)
[ok] gold_engajamento (57 s)
[ok] gold_aquisicao (53 s)
[ok] gold_ml (67 s)
[ok] gold_mapa_calor (46 s)
[ok] exportar_bi (21 s)
9 jobs concluídos: bronze, silver, qualidade, gold_funil, gold_engajamento, gold_aquisicao, gold_ml,
gold_mapa_calor, exportar_bi.
```

O portão bloqueia dado ruim

O mesmo job rodou com o limite de rejeição em 1 % (a taxa real é 3,06 %). A regra bloqueante falhou, o processo saiu com código 1 e as Golds não foram recalculadas.

```
$ python -c "import qualidade; qualidade.TAXA_REJEICAO_MAXIMA = 0.01; qualidade.main()"
[  ok  ] silver tem eventos válidos                                54789  (limite > 0)
[  ok  ] reconciliação: bronze única = silver + rejeitados             0  (limite = 0)
[  ok  ] event_id único na silver                                      0  (limite = 0)
[  ok  ] pessoa e sessão preenchidas                                   0  (limite = 0)
[FALHOU] taxa de rejeição                                         0.0306  (limite <= 0.01)
[  ok  ] taxa de duplicatas                                       0.0101  (limite <= 0.05)
1 regra(s) bloqueante(s) falharam: as Golds não foram recalculadas.
código de saída: 1
```

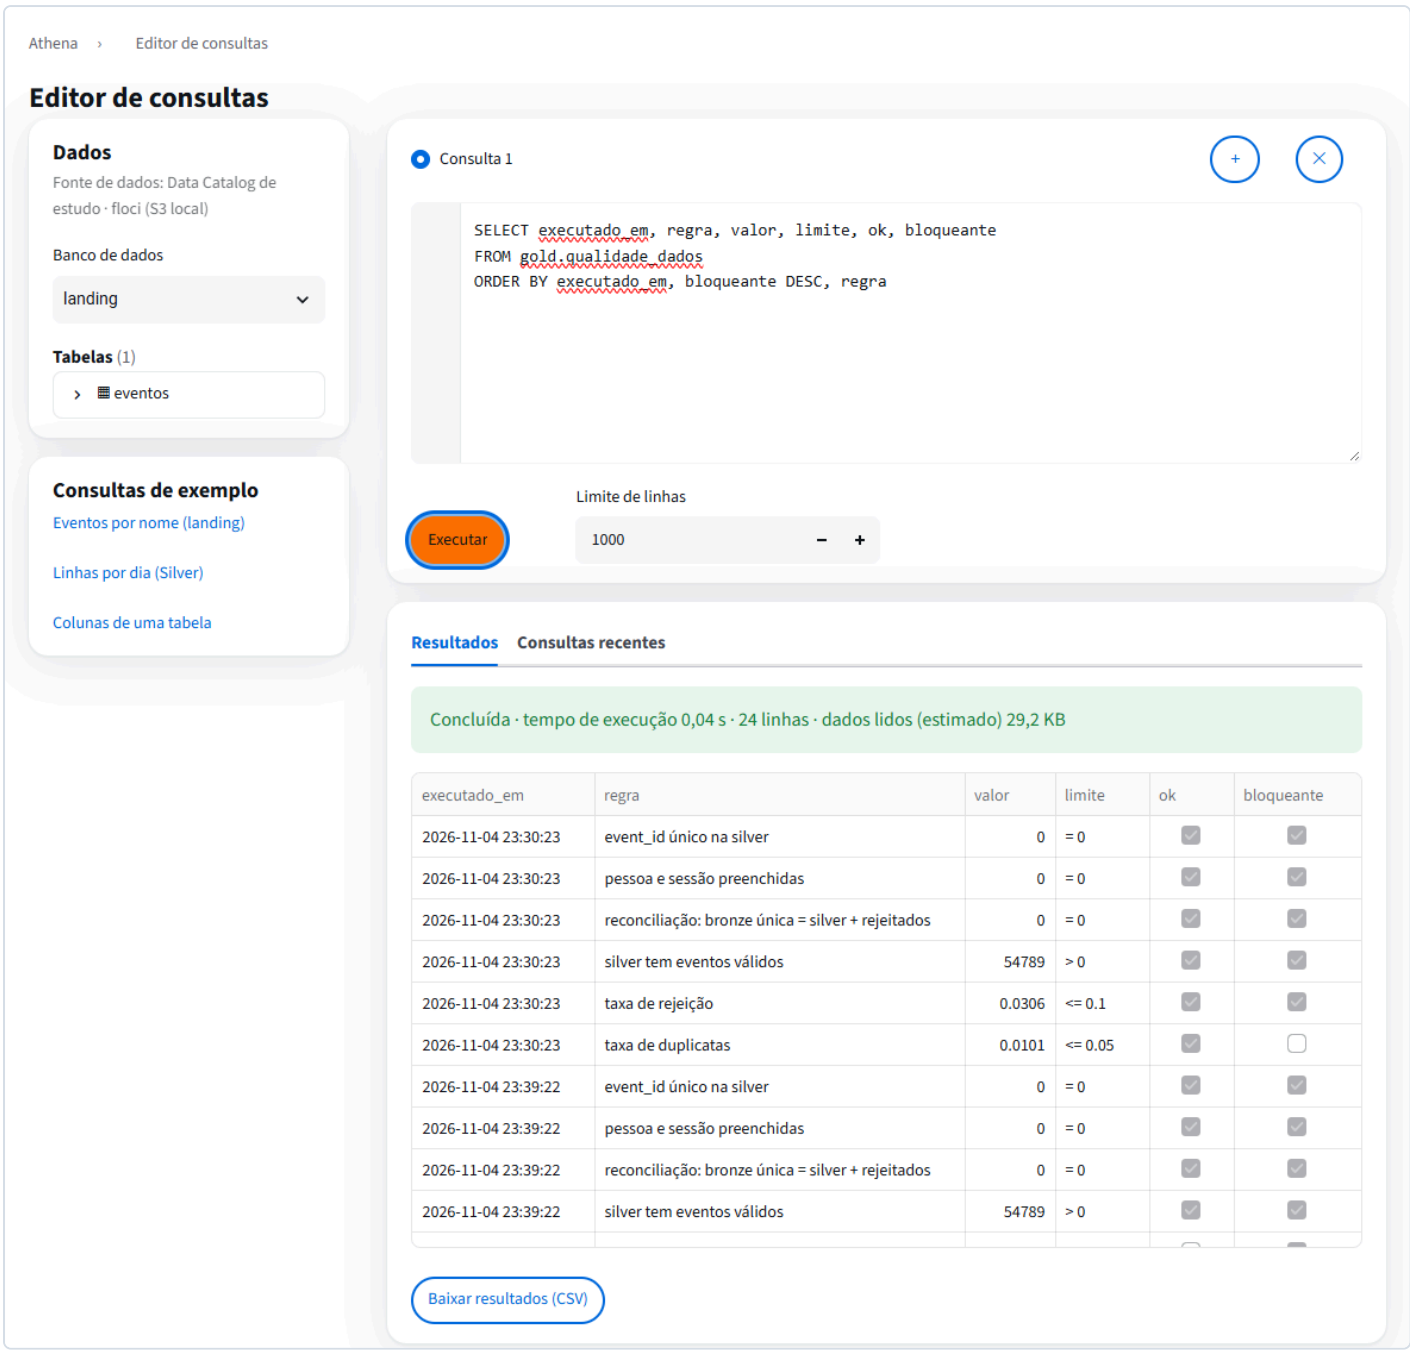
Reprocessamento parcial (`--a-partir-de`)

Roda só o job pedido e os que dependem dele, sem refazer a Bronze e a Silver.

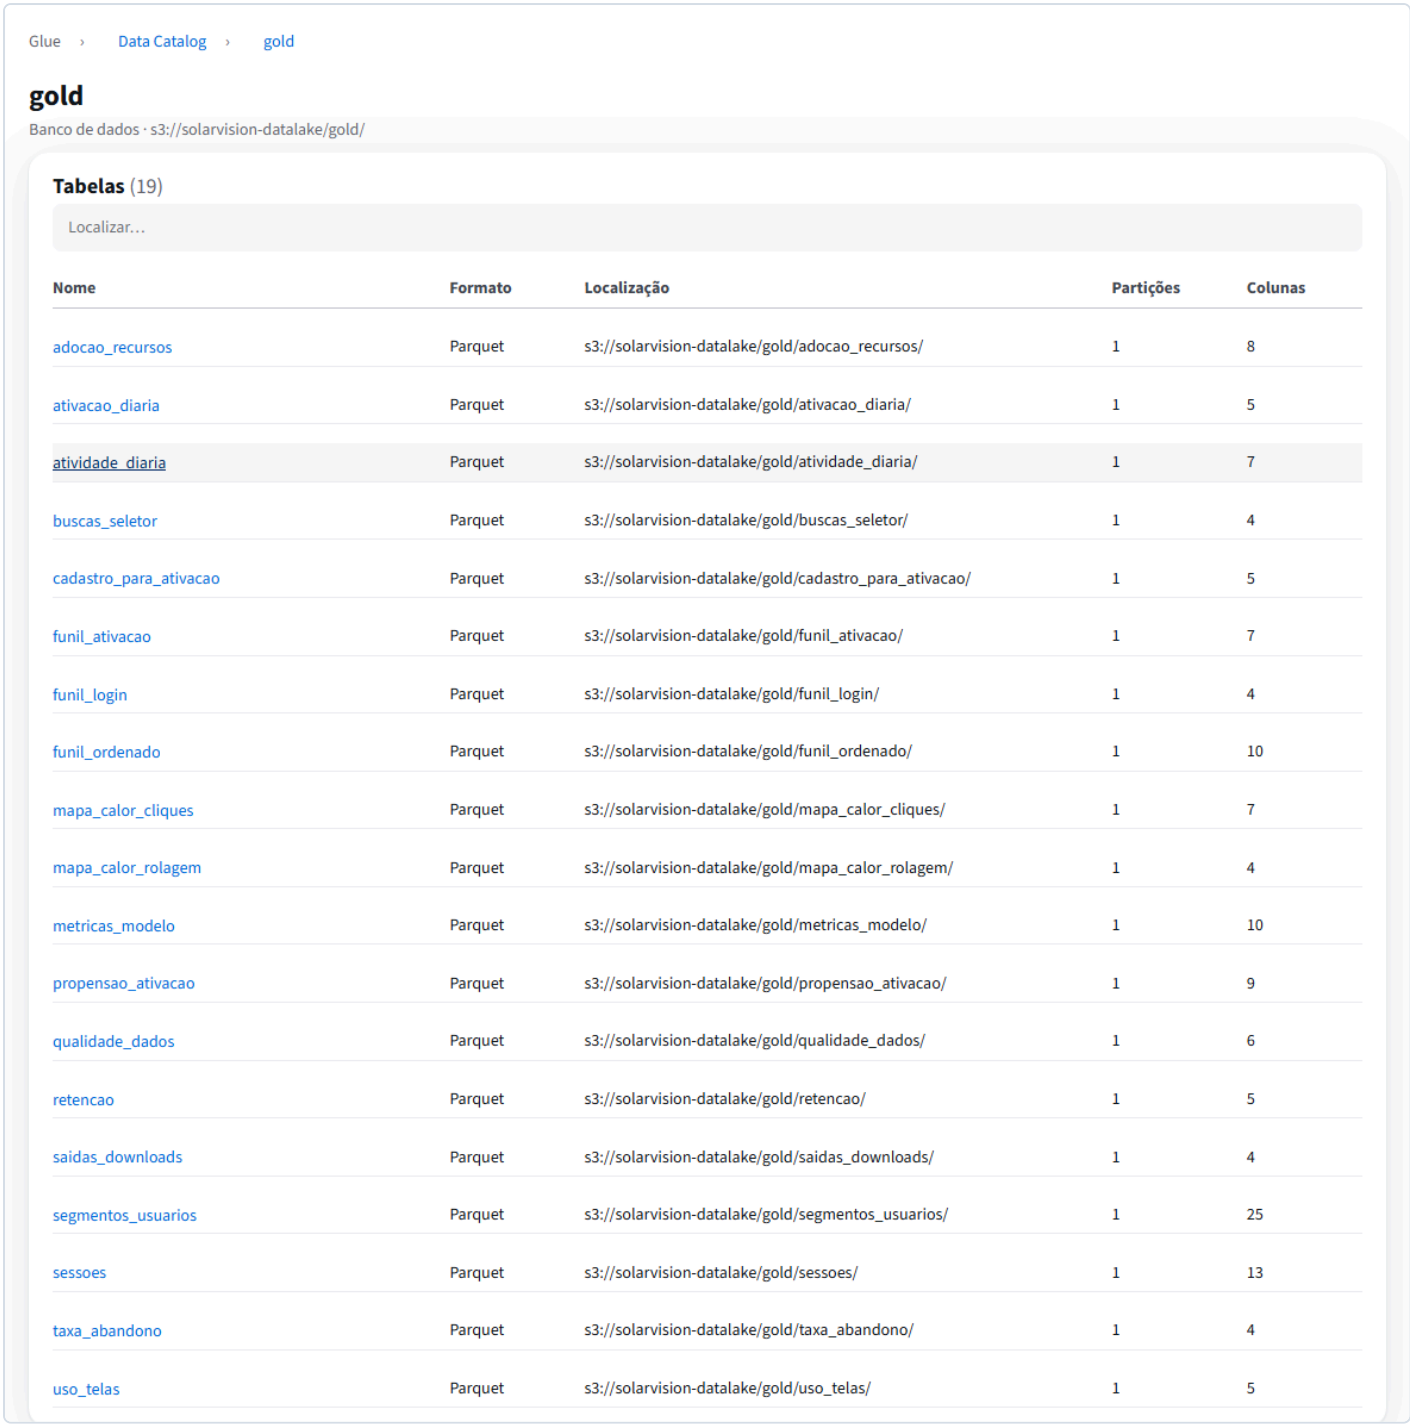
```
$ docker compose run --rm app python pipeline/rodar_tudo.py --a-partir-de gold_engajamento
[ok] gold_engajamento (58 s)
[ok] exportar_bi (21 s)
2 jobs concluídos: gold_engajamento, exportar_bi.

$ docker compose run --rm app python pipeline/rodar_tudo.py --a-partir-de qualidade
[ok] qualidade (47 s)
[ok] gold_funil (62 s)
[ok] gold_engajamento (60 s)
[ok] gold_aquisicao (56 s)
[ok] gold_ml (72 s)
[ok] gold_mapa_calor (49 s)
[ok] exportar_bi (22 s)
7 jobs concluídos: qualidade, gold_funil, gold_engajamento, gold_aquisicao, gold_ml, gold_mapa_calor,
exportar_bi.
```

Histórico do portão (gold/qualidade_dados, carga incremental em append)



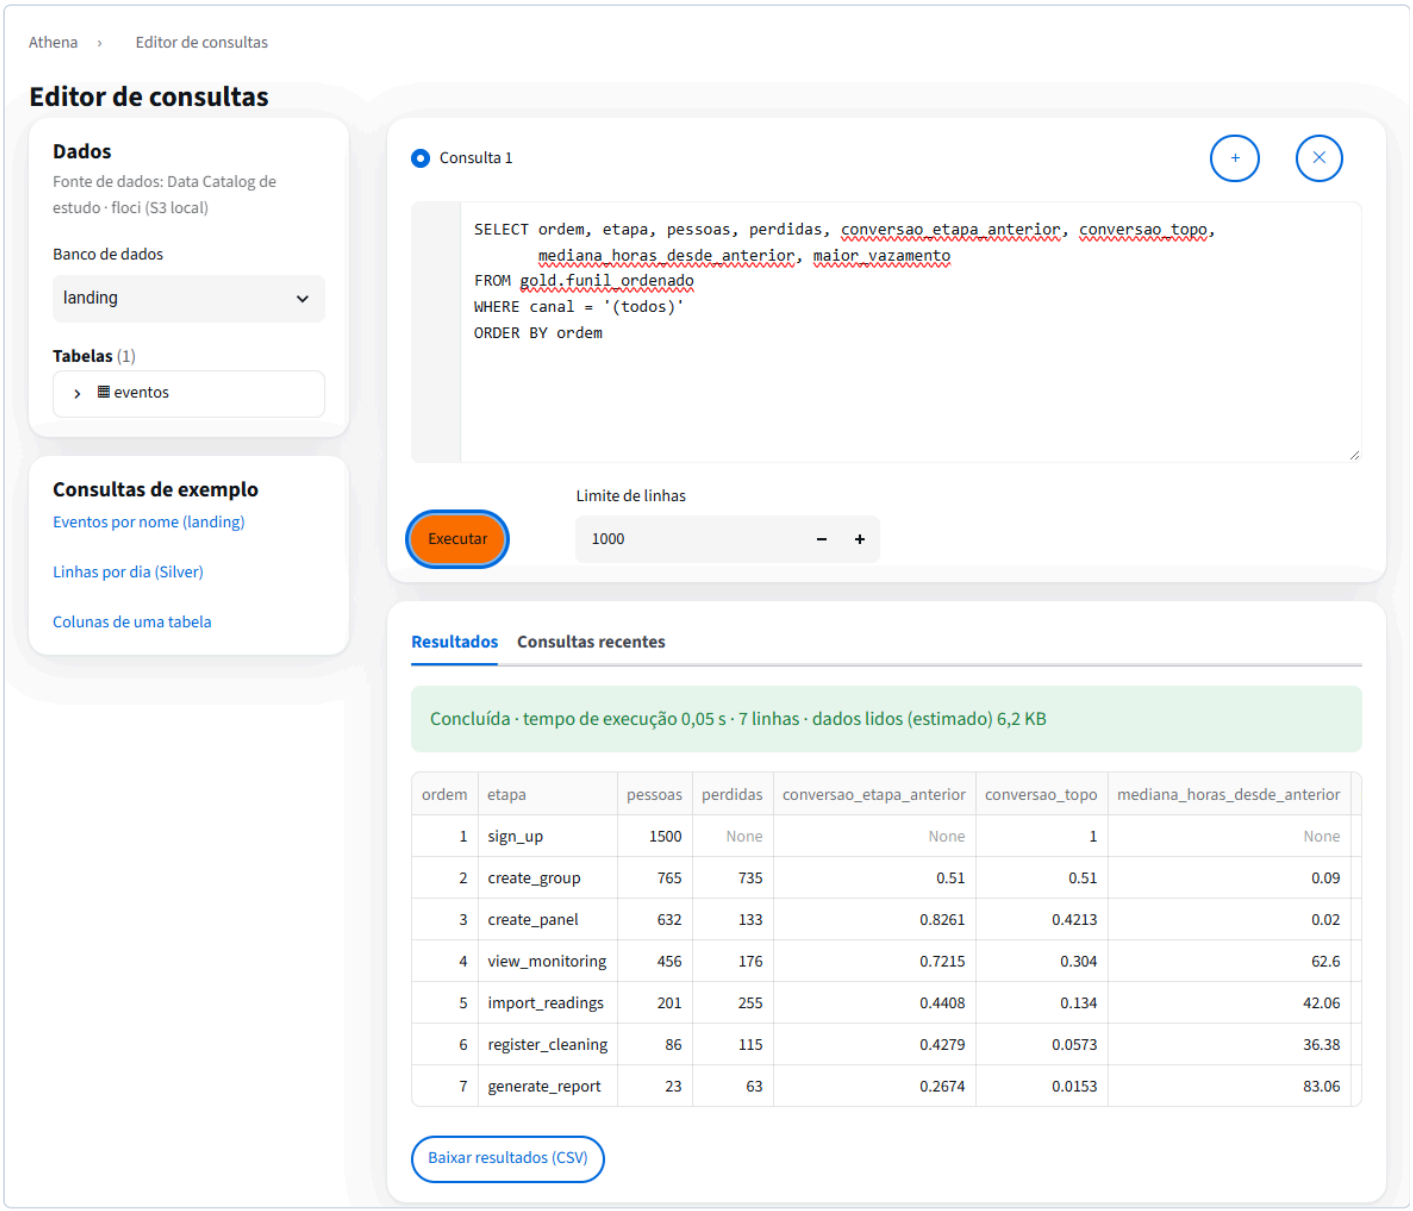
Athena · Editor de consultas: 4 execuções × 6 regras. A execução das 23:39:22 é a do teste de bloqueio (`ok = false` na taxa de rejeição); as seguintes voltaram ao normal. Exportado em `qualidade_dados.csv`.



Glue · Data Catalog · gold: as 19 tabelas, incluindo as novas `funil_ordenado`, `adocao_recursos`, `atividade_diaria` e `qualidade_dados`.

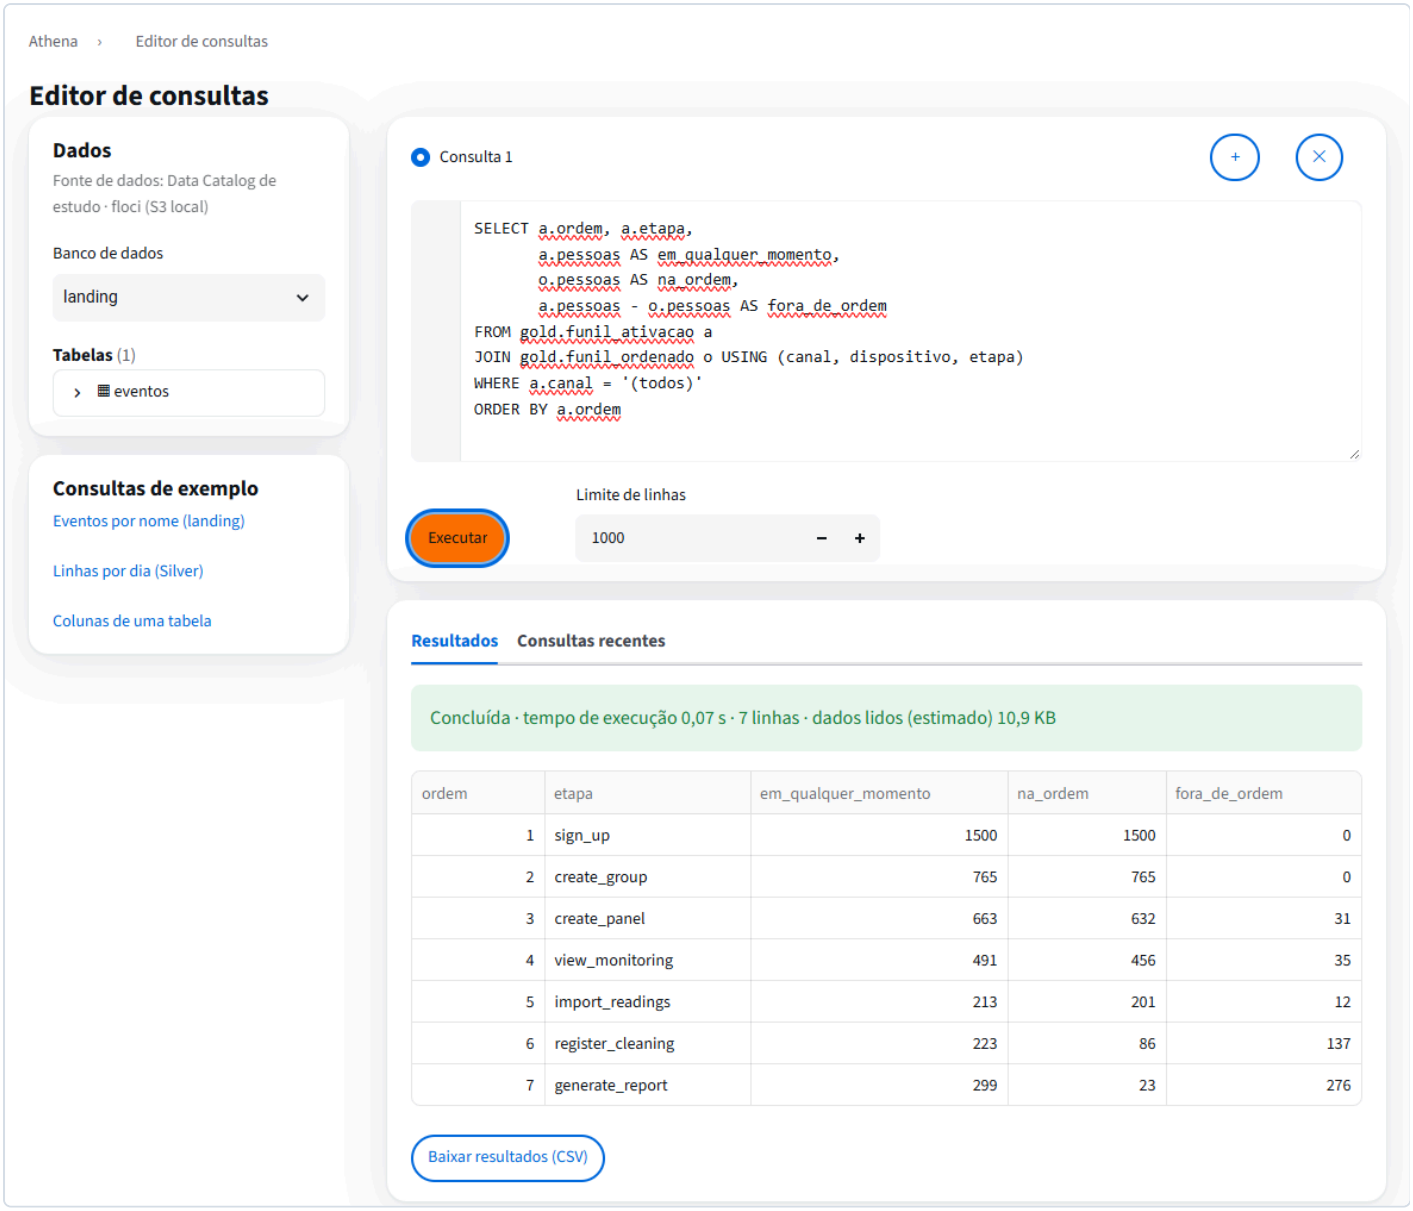
2. Funil

O funil de ativação tem 7 etapas: conta → usina → placa → monitoramento → importação → limpeza → relatório. Na nova tabela `funil_ordenado`, a pessoa só conta numa etapa se passou pelas anteriores nessa ordem. O cálculo é uma passada por pessoa com `aggregate` sobre os eventos ordenados.

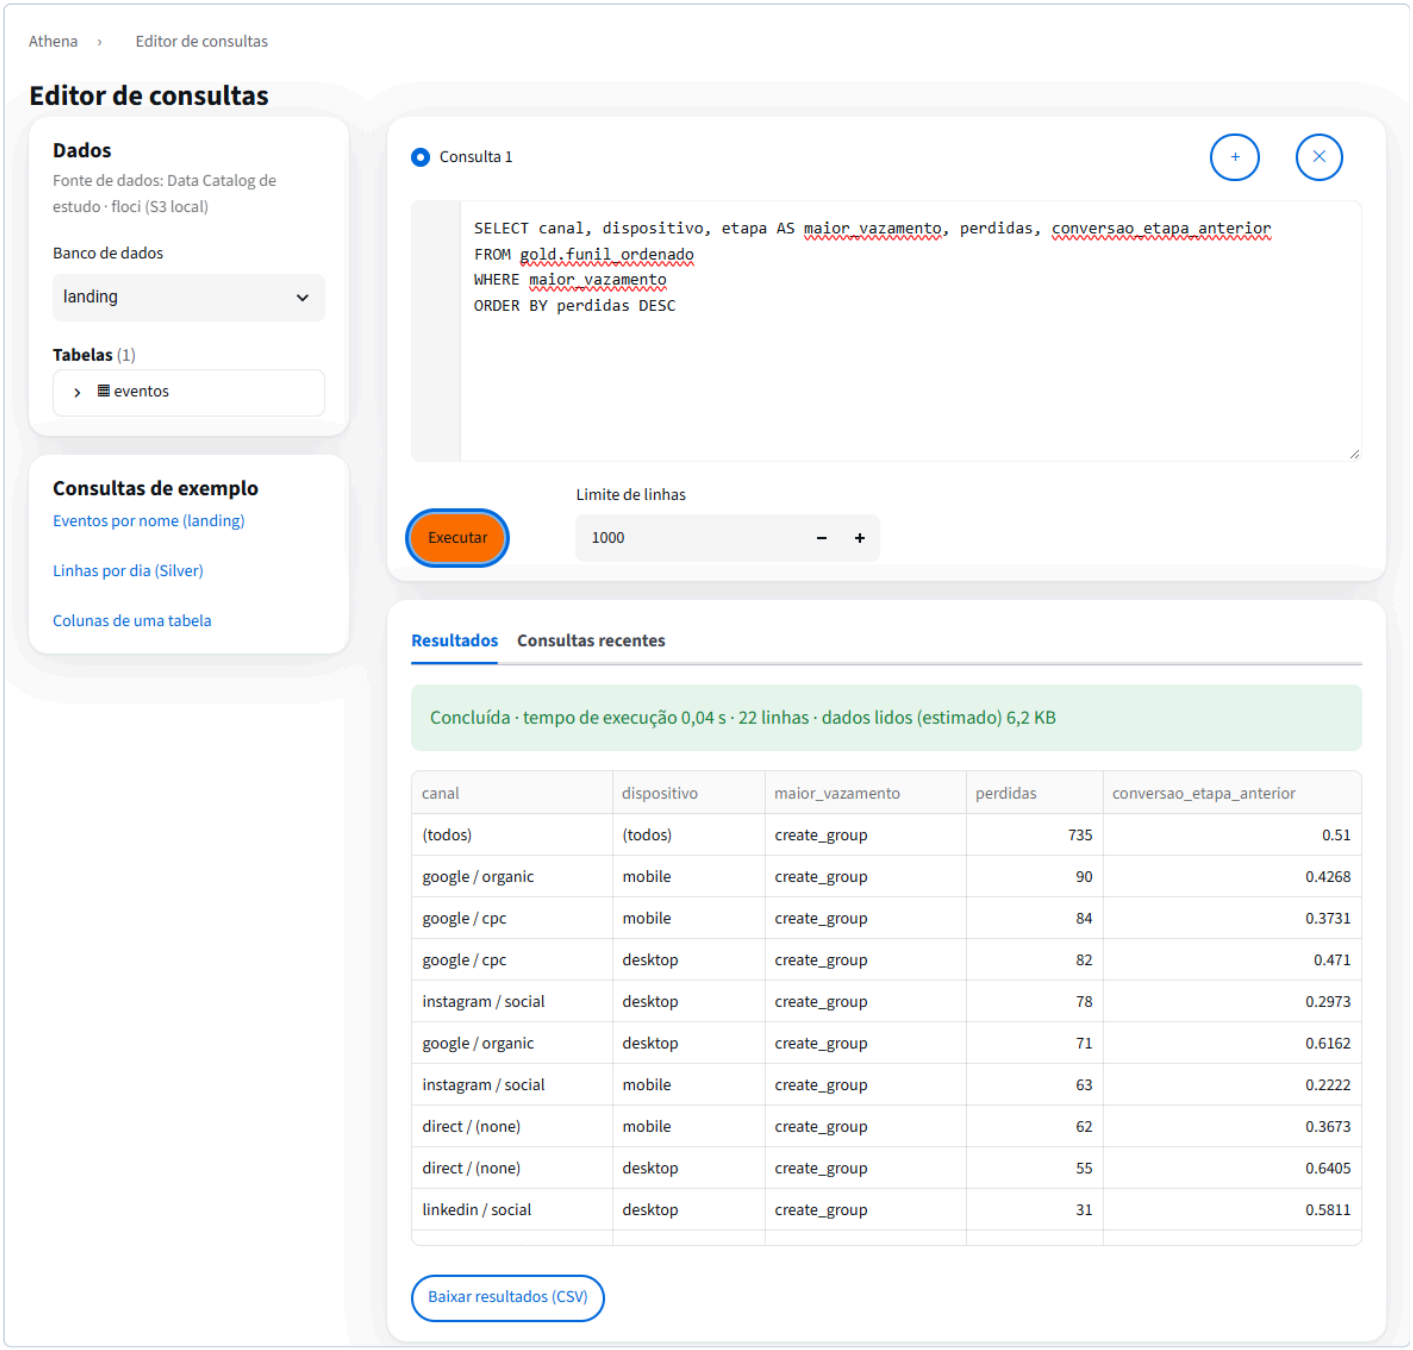


ordem	etapa	pessoas	perdidas	conversao_etapa_anterior	conversao_topo	mediana_horas_desde_anterior
1	sign_up	1500	None	None	1	None
2	create_group	765	735	0.51	0.51	0.09
3	create_panel	632	133	0.8261	0.4213	0.02
4	view_monitoring	456	176	0.7215	0.304	62.6
5	import_readings	201	255	0.4408	0.134	42.06
6	register_cleaning	86	115	0.4279	0.0573	36.38
7	generate_report	23	63	0.2674	0.0153	83.06

Total: o maior vazamento (`maior_vazamento = true`) é conta → usina, com 735 pessoas perdidas e conversão de 51 %. Quem segue leva 0,09 h, cerca de 5 minutos (mediana).



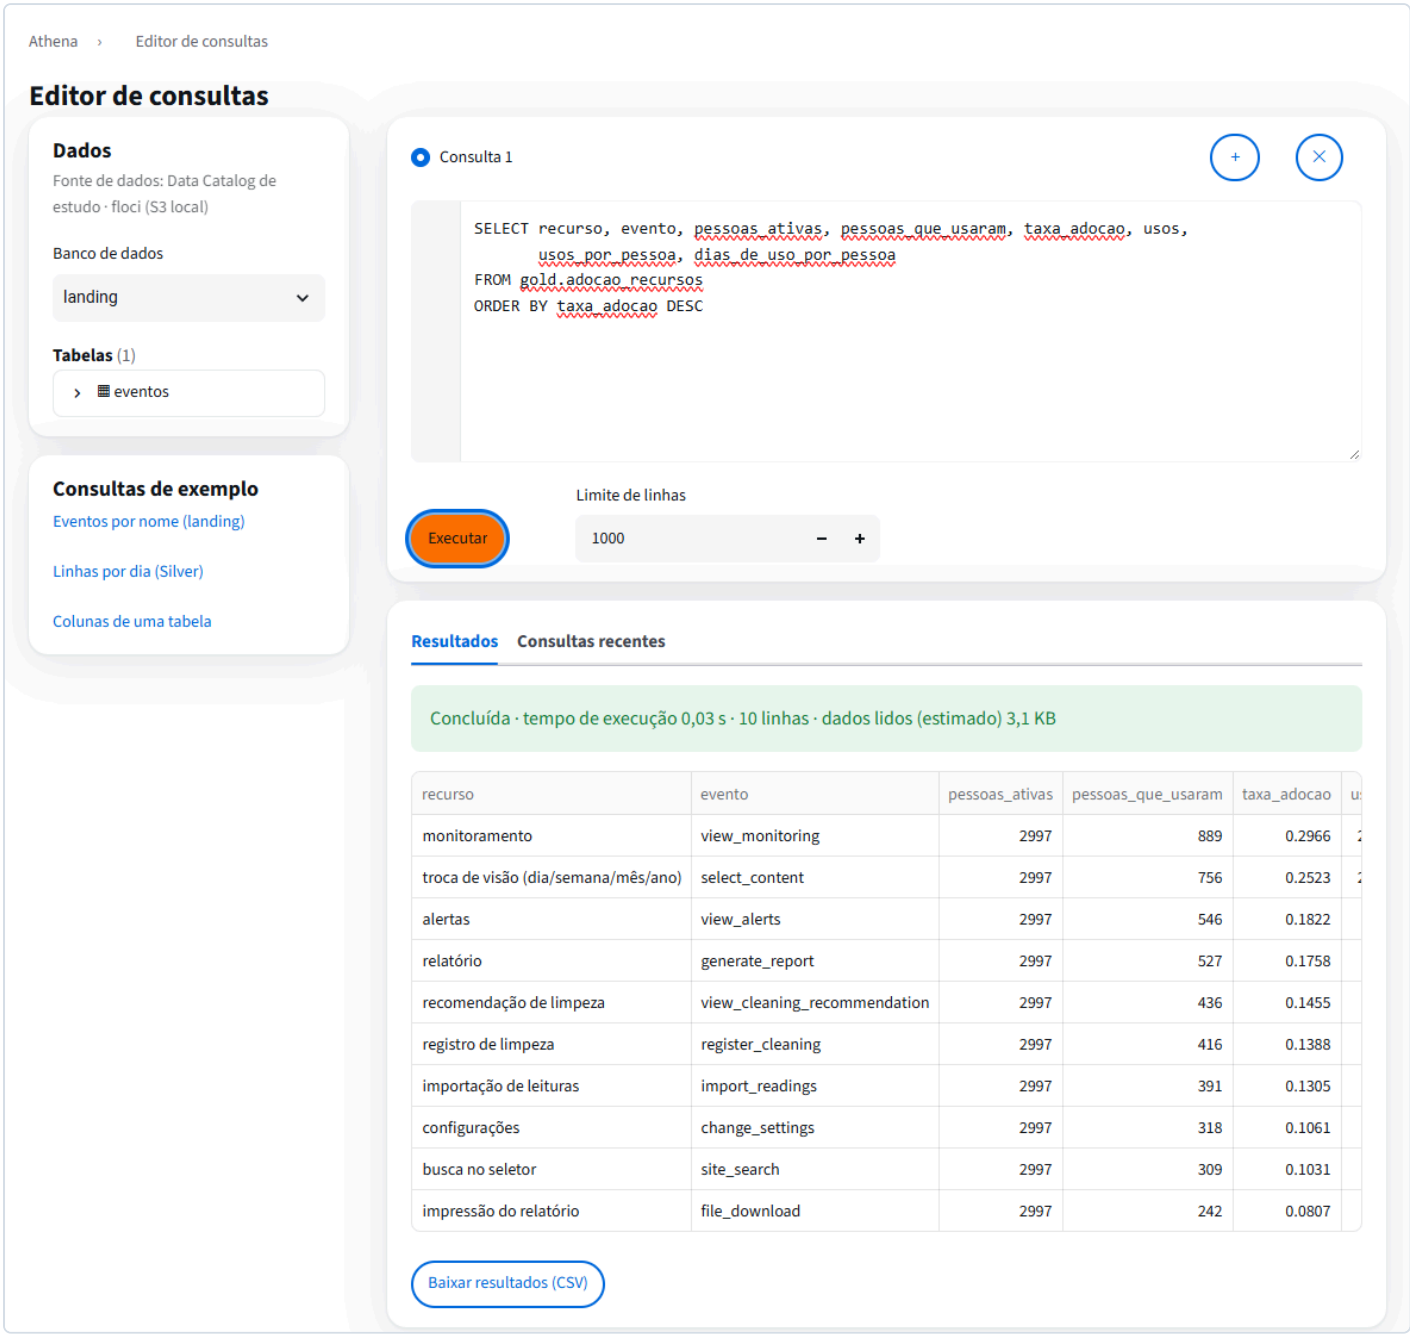
As duas leituras lado a lado. 299 pessoas abrem o relatório "em qualquer momento", mas só 23 passaram por todas as etapas antes. Depois da ativação a jornada deixa de ser linear, e a pergunta certa passa a ser a adoção dos recursos (seção 3).



Maior vazamento por canal × dispositivo: conta → usina na maioria dos recortes; em indicação e newsletter no desktop, o maior vazamento é a importação de leituras.

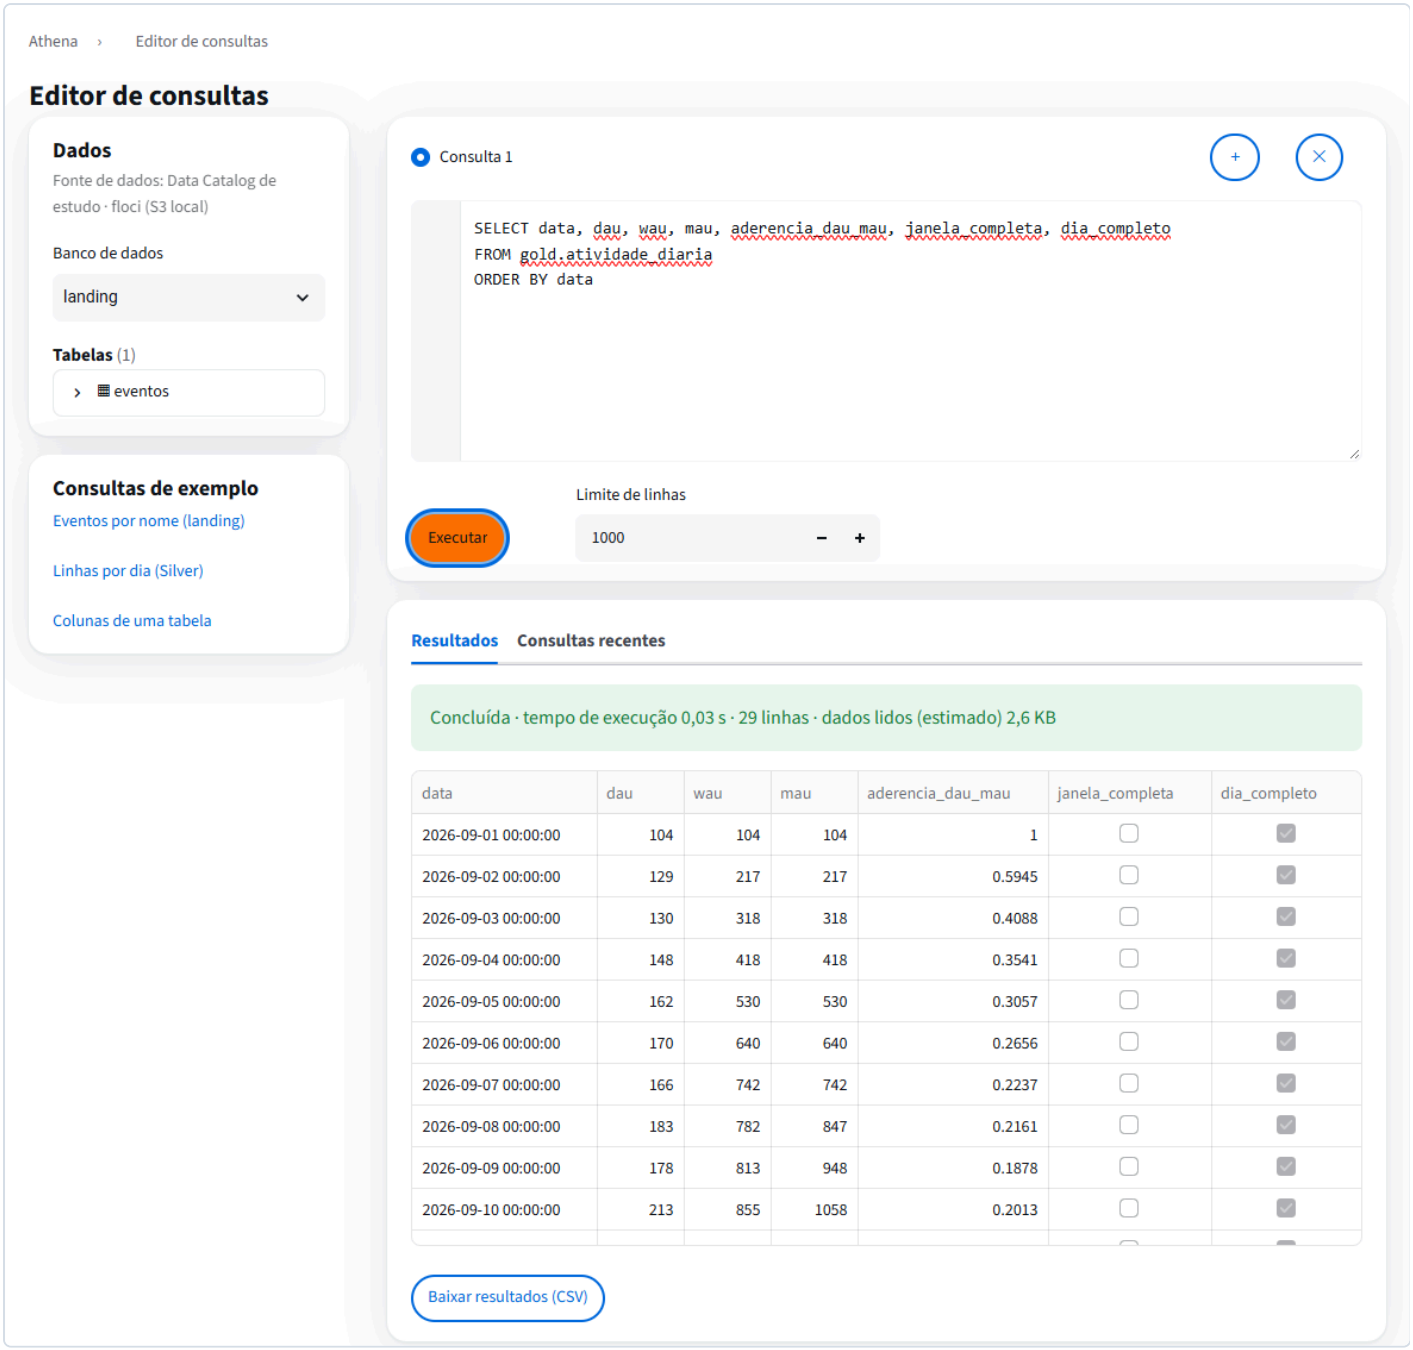
3. Engajamento

O projeto do professor mede a retenção do vídeo. O SolarVision é um produto de uso recorrente, então o equivalente é quem adota cada recurso e quem volta a usar.



recurso	evento	pessoas_ativas	pessoas_que_usaram	taxa_adocao
monitoramento	view_monitoring	2997	889	0.2966
troca de visão (dia/semana/mês/ano)	select_content	2997	756	0.2523
alertas	view_alerts	2997	546	0.1822
relatório	generate_report	2997	527	0.1758
recomendação de limpeza	view_cleaning_recommendation	2997	436	0.1455
registro de limpeza	register_cleaning	2997	416	0.1388
importação de leituras	import_readings	2997	391	0.1305
configurações	change_settings	2997	318	0.1061
busca no seletor	site_search	2997	309	0.1031
impressão do relatório	file_download	2997	242	0.0807

`gold/adocao_recursos`: o monitoramento é usado por 29,7 % das pessoas ativas, em 3,1 dias diferentes por pessoa. A importação de leituras é usada por 13 %, quase sempre uma vez só. Exportado em `adocao_recursos.csv`.

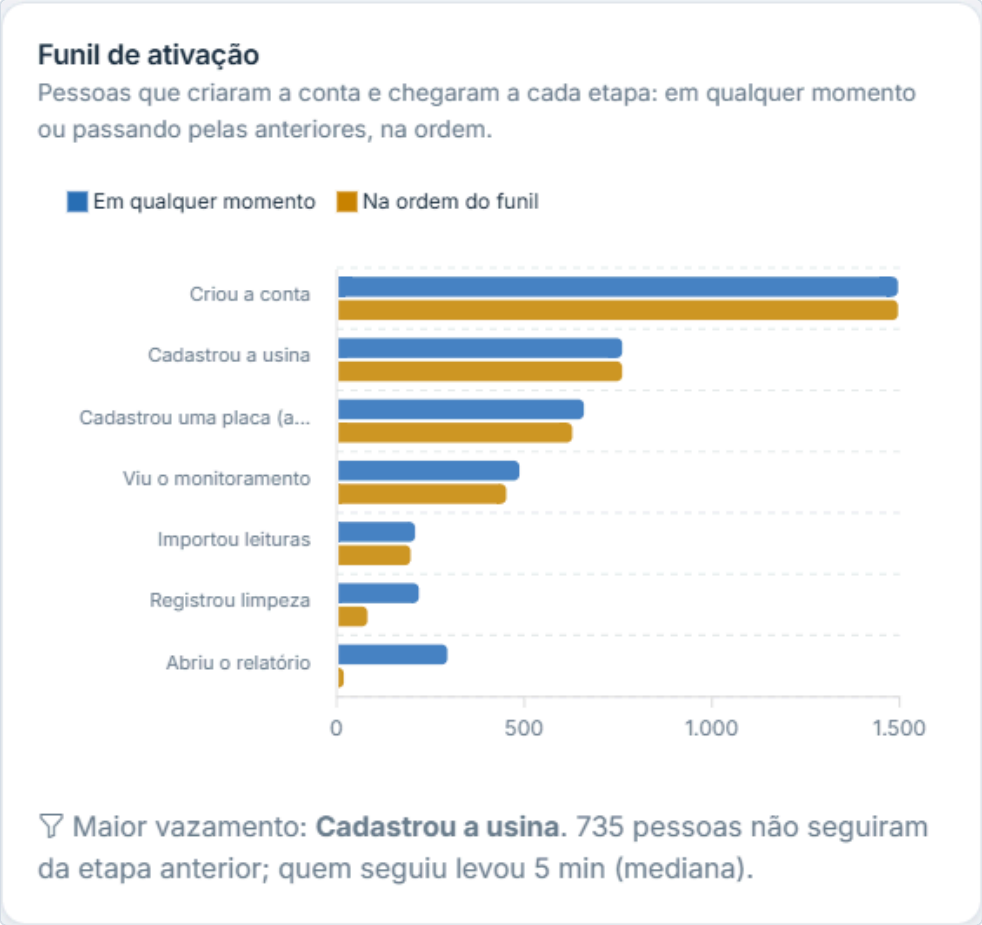


data	dau	wau	mau	aderencia_dau_mau	janela_completa	dia_completo
2026-09-01 00:00:00	104	104	104	1	☐	☑
2026-09-02 00:00:00	129	217	217	0.5945	☐	☑
2026-09-03 00:00:00	130	318	318	0.4088	☐	☑
2026-09-04 00:00:00	148	418	418	0.3541	☐	☑
2026-09-05 00:00:00	162	530	530	0.3057	☐	☑
2026-09-06 00:00:00	170	640	640	0.2656	☐	☑
2026-09-07 00:00:00	166	742	742	0.2237	☐	☑
2026-09-08 00:00:00	183	782	847	0.2161	☐	☑
2026-09-09 00:00:00	178	813	948	0.1878	☐	☑
2026-09-10 00:00:00	213	855	1058	0.2013	☐	☑

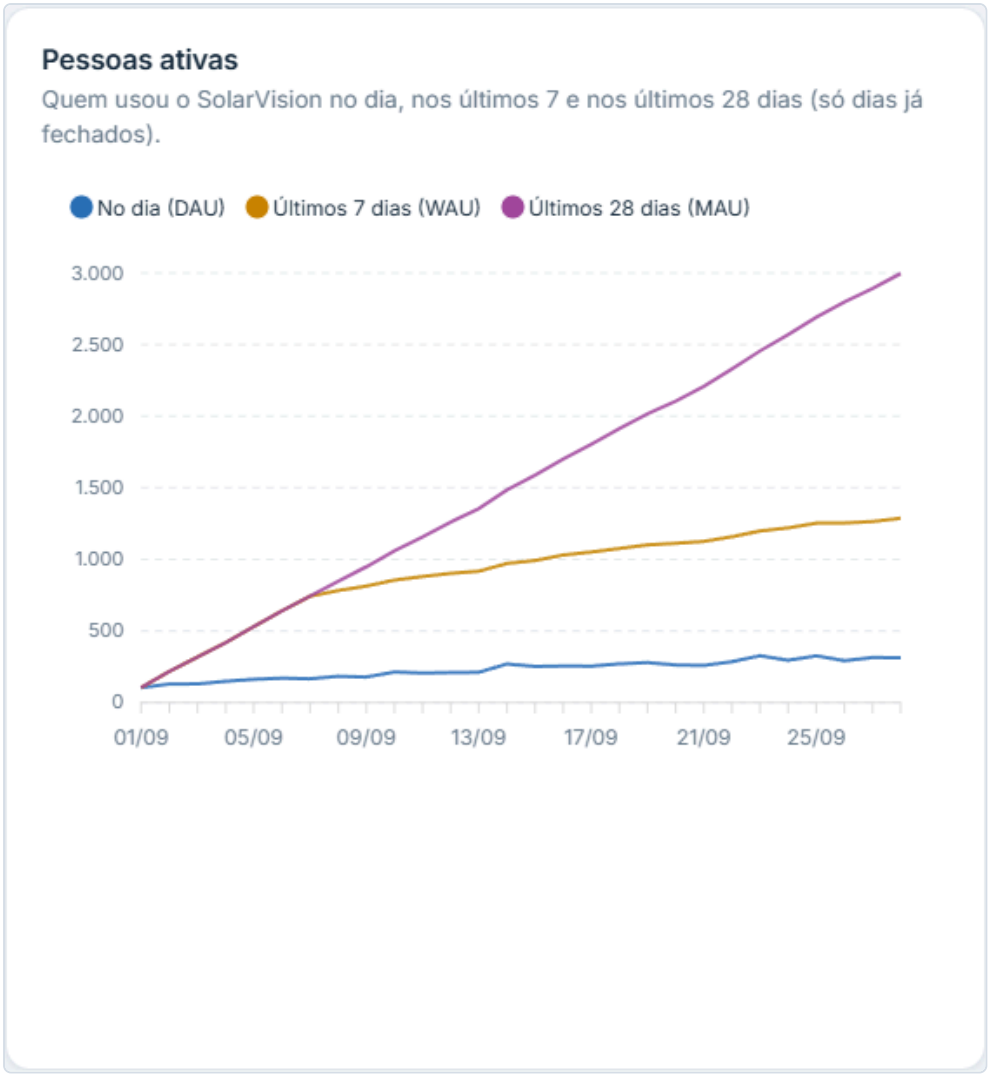
`gold/atividade_diaria`: DAU, WAU (7 dias), MAU (28 dias) e aderência DAU/MAU. `janela_completa` marca quando o mês já fechou, e `dia_completo` marca o último dia, ainda em andamento: ele tem 3 pessoas e derrubaria o KPI. Exportado em `atividade_diaria.csv`.

4. Painel no app (Data Storytelling)

A página **Uso da plataforma** (`/app/uso`, só ADMIN) lê o `bi.js` que o job `exportar_bi` gera a partir da Gold.



Funil com as duas leituras e a frase do maior vazamento.



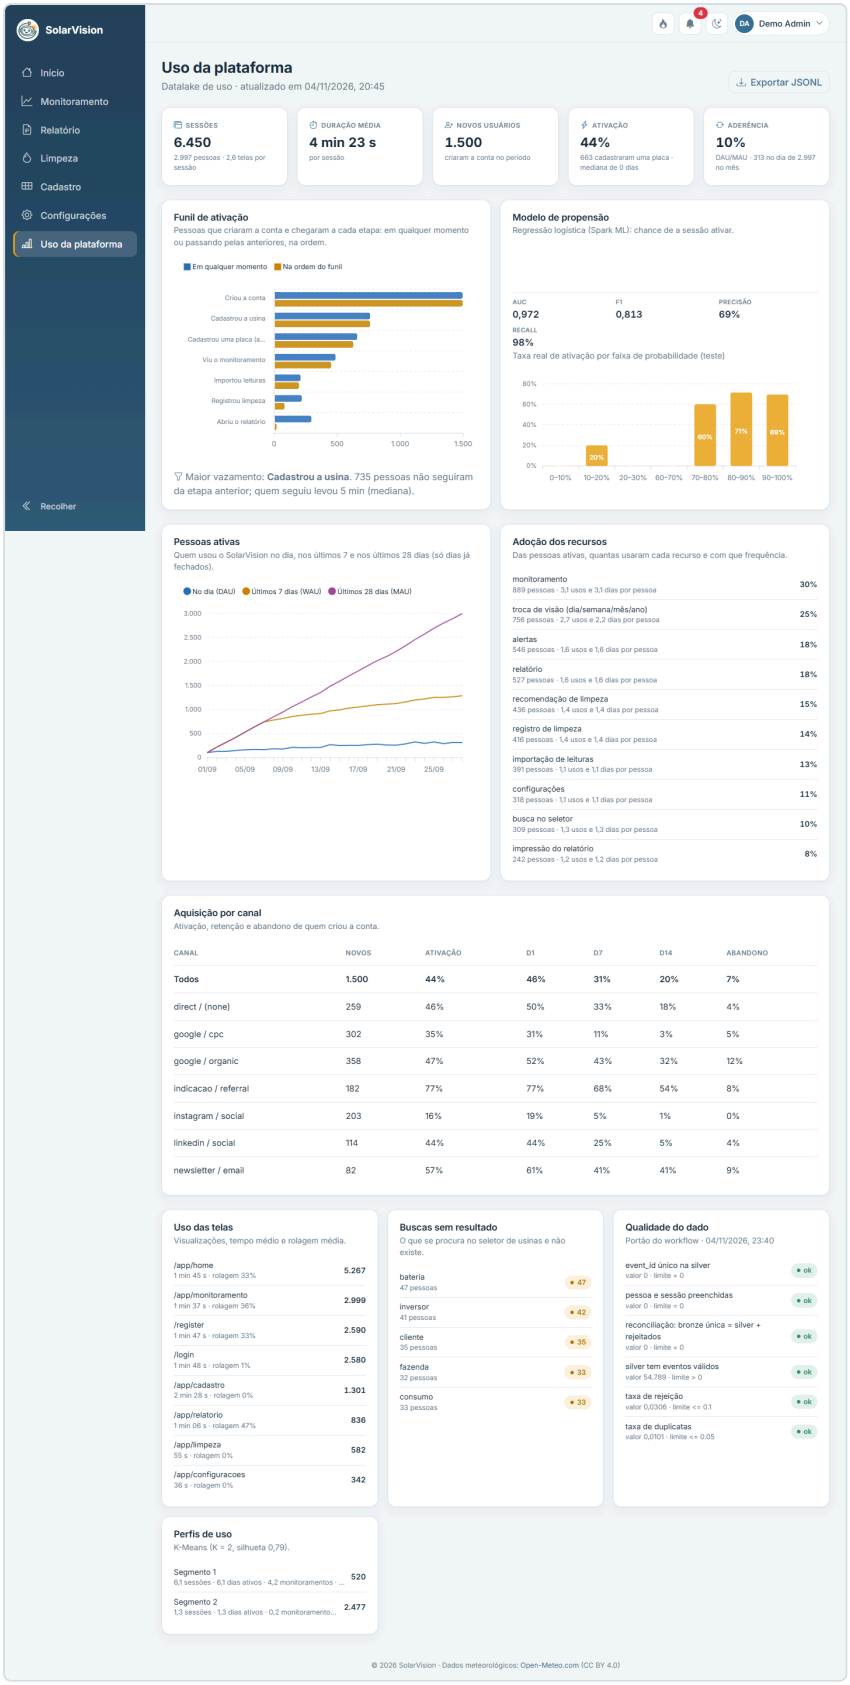
Pessoas ativas por dia, semana e mês (só dias fechados).



Adoção dos recursos.



Resultado do portão de qualidade na última execução.



Página inteira: cinco KPIs (incluindo a aderência DAU/MAU) e todos os cartões.

5. Os 4 CSVs

Exportados pelo botão "Baixar resultados (CSV)" do Athena · Editor de consultas do console, cada um a partir de uma tabela Gold inteira.

Arquivo	Conceito	Linhas	Colunas
`funil_ordenado.csv`	Funil	154 (7 etapas × 22 recortes)	canal, dispositivo, ordem, etapa, pessoas, perdidas, conversao_etapa_anterior, conversao_topo, mediana_horas_desde_anterior, maior_vazamento
`adocao_recursos.csv`	Engajamento	10 (um por recurso)	recurso, evento, pessoas_ativas, pessoas_que_usaram, taxa_adocao, usos, usos_por_pessoa, dias_de_uso_por_pessoa
`atividade_diaria.csv`	Engajamento	29 (01 a 29/09/2026)	data, dau, wau, mau, aderencia_dau_mau, janela_completa, dia_completo
`qualidade_dados.csv`	Workflow	24 (4 execuções × 6 regras)	executado_em, regra, valor, limite, ok, bloqueante

Código, testes e estes arquivos na branch: https://github.com/danieltanjos/SolarVision/tree/feat/datalake-funil-engajamento-workflow. Os CSVs e este PDF estão em `datalake/evidencias/funil-engajamento-workflow/`.

> **Sobre os dados:** os eventos vêm do gerador sintético. Os números mostram que as tabelas respondem às perguntas; as conclusões sobre o produto são hipóteses a confirmar quando chegarem dados reais de uso pelo coletor do Supabase.