Job Gold ML — evidências

Projeto final SolarVision · Luiz Gustavo · `pipeline/gold_ml.py` (etapa `07_gold_ml`) rodando no console do datalake sobre o floci.

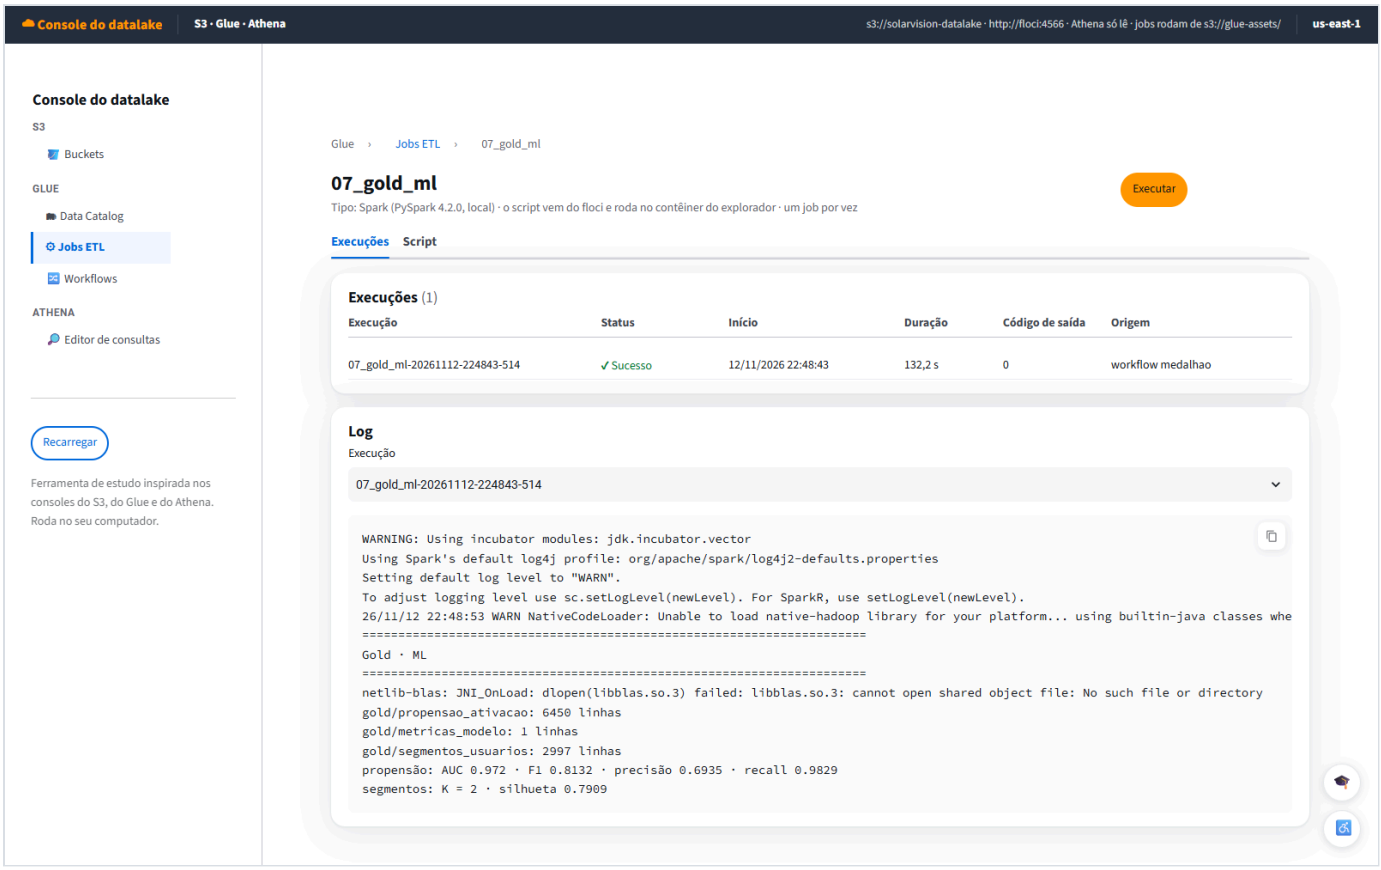
- `propensao_ativacao`: regressão logística do Spark ML, uma linha por sessão, com features só de antes do primeiro `create_group` (sem vazamento).
- `metricas_modelo`: AUC, F1, precisão e recall da classe positiva no teste e a lista de features; treino e teste separados por pessoa.
- `segmentos_usuarios`: K-Means com o K escolhido pela silhueta e o perfil médio de cada grupo.

Resultado: AUC 0,972, F1 0,813, precisão 69,4% e recall 98,3% no teste (1.373 sessões); K = 2 com silhueta 0,79 (2.485 exploradores e 512 operadores).

CSV exportado: `evidencias/gold_metricas_modelo.csv` (print 4), `evidencias/gold_segmentos.csv` (print 5).

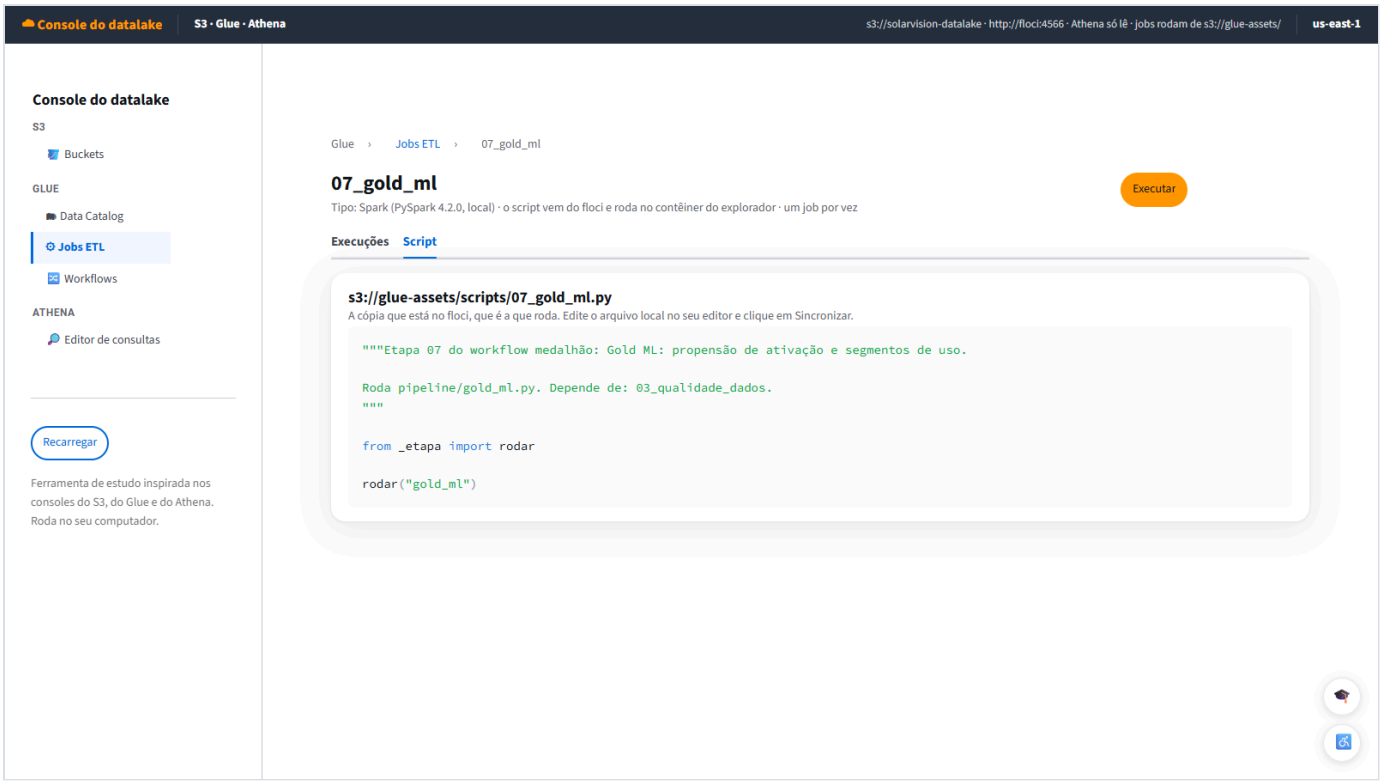
Branch: https://github.com/danieltanjos/SolarVision/tree/feat/datalake-entrega-final

1. Execução do job



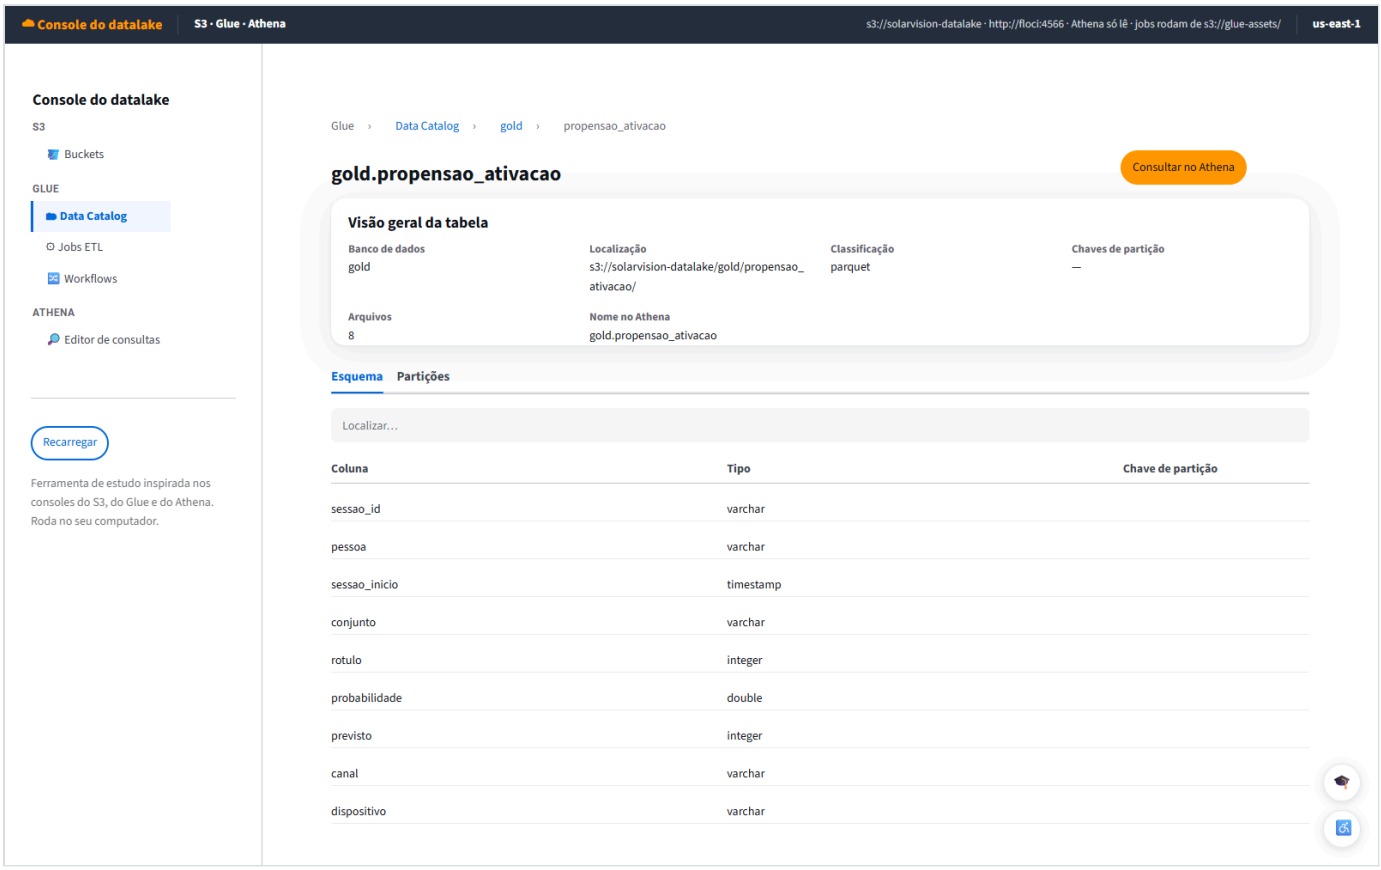
Rodado pelo workflow `medalhao`: Sucesso, com as métricas no log.

2. Script do job



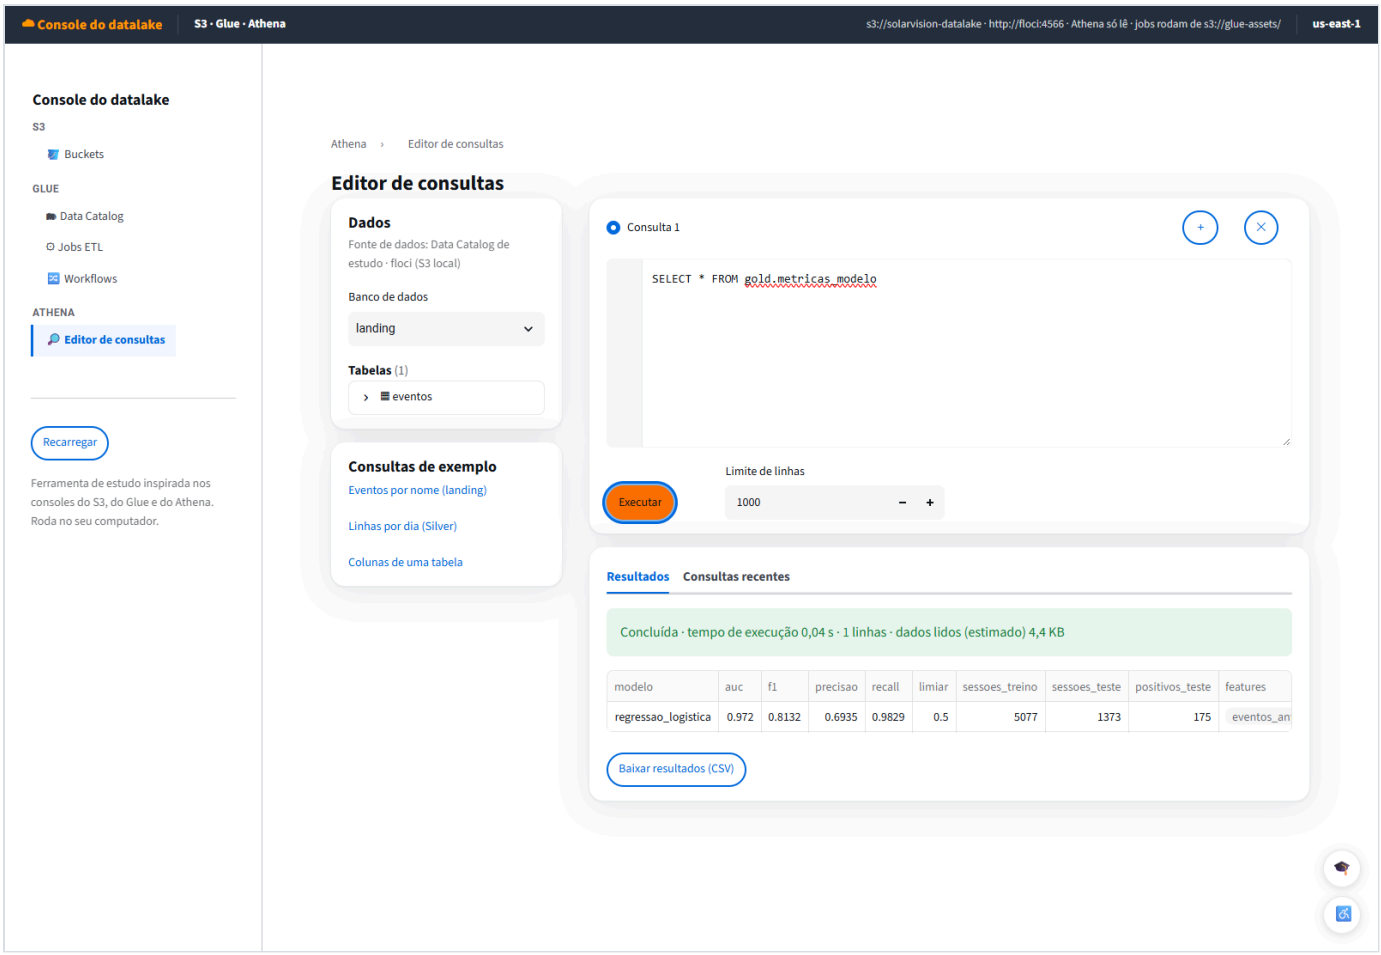
A etapa `07_gold_ml` chama `pipeline/gold_ml.py`.

3. Glue Data Catalog · gold.propensao_ativacao



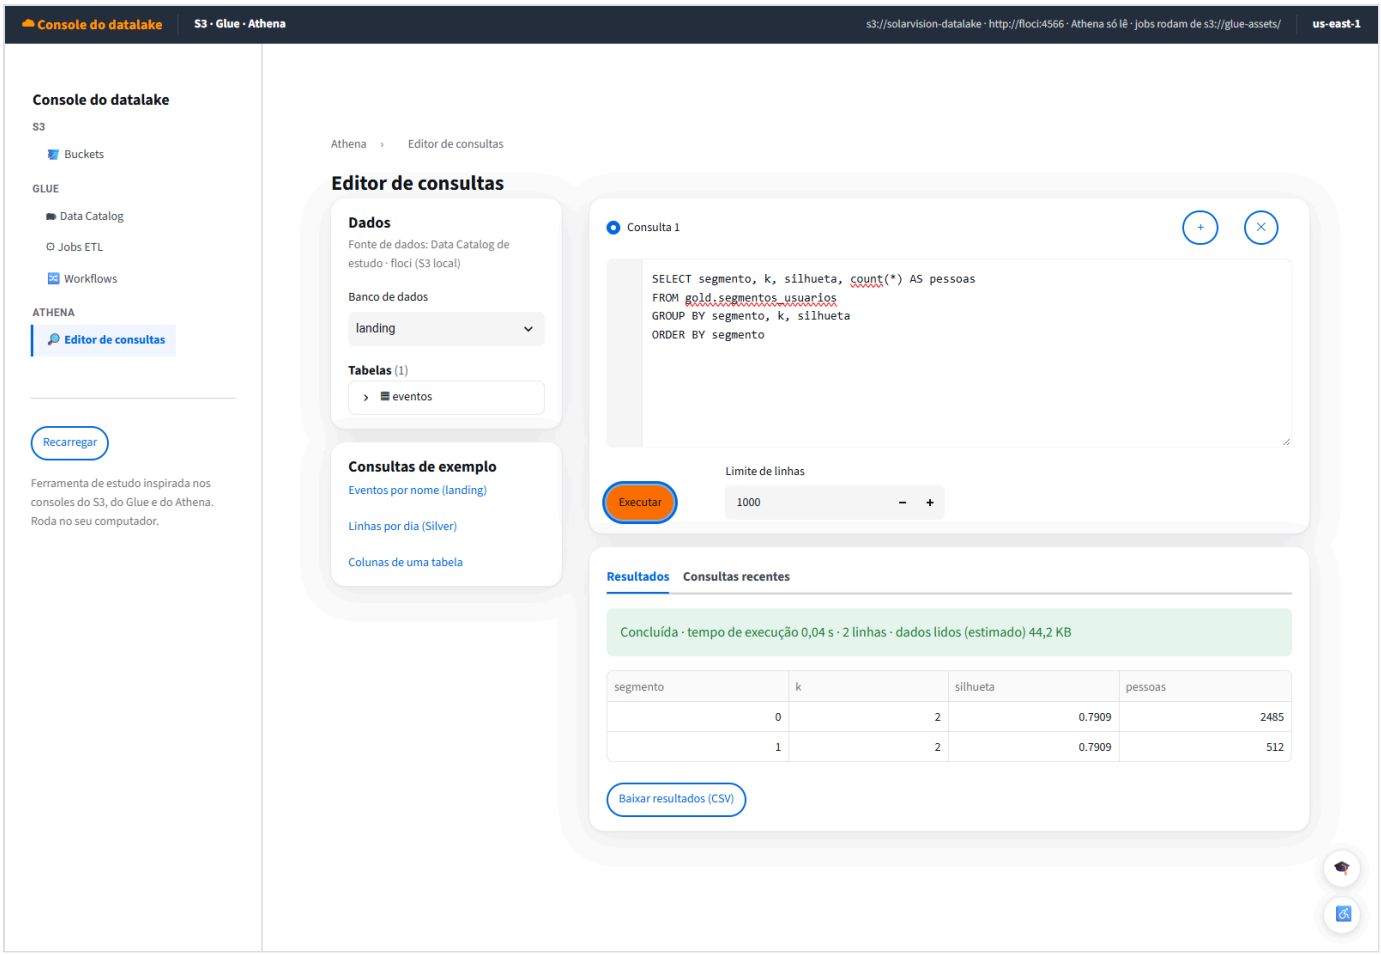
Sessão, conjunto (treino ou teste), rótulo e probabilidade.

4. Athena · métricas do modelo



AUC, F1, precisão, recall e as 15 features, nenhuma de cadastro.

5. Athena · segmentos



Os dois grupos do K-Means e a silhueta.