Job Silver — evidências

Projeto final SolarVision · Luiz Gustavo · `pipeline/silver.py` (etapa `02_silver_eventos`) rodando no console do datalake sobre o floci.

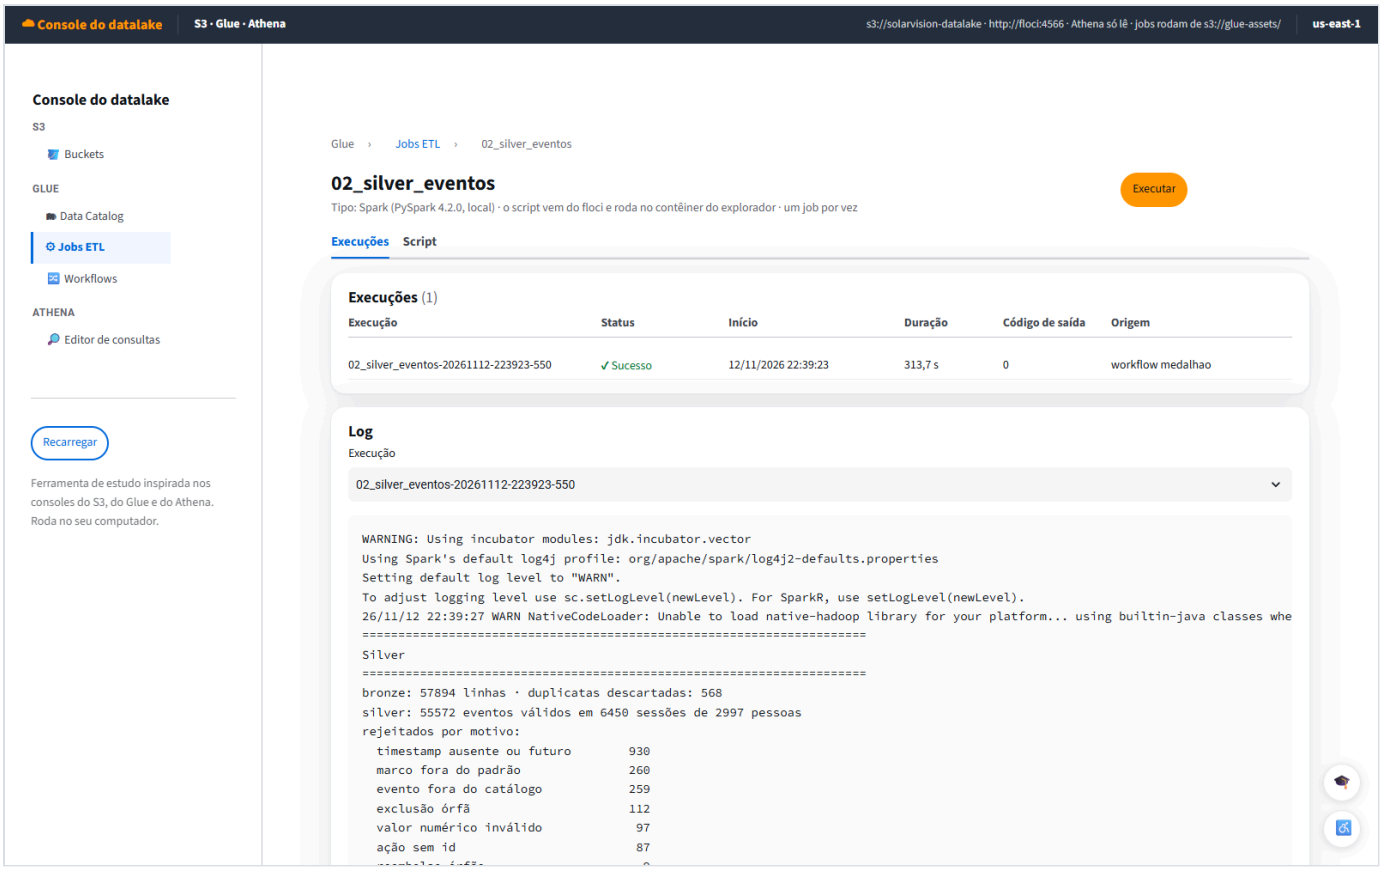
- **R5** — deduplicação por `event_id`, ficando com a primeira ingestão.
- **R6** — `params` extraídos para colunas tipadas, incluindo `element_id`.
- **R7** — validação com motivo de rejeição em `silver/eventos_rejeitados/`: fora do catálogo, timestamp ausente ou futuro, ação sem id, valor numérico inválido, marco fora do padrão, exclusão órfã e reembolso órfão.
- **R8** — sessões próprias: sessão nova após 30 min sem evento do mesmo `user_pseudo_id`; o `session_hint` não é usado.
- **R9** — identity stitching: o `user_id` vai para todos os eventos do navegador, inclusive os de antes do login.
- **R10** — `silver/itens/`: `items[]` explodido, uma linha por placa ou plano por evento.

Resultado: 57.894 linhas na Bronze → 568 duplicatas descartadas → 57.326 únicos = 55.572 válidos + 1.754 rejeitados; 6.450 sessões de 2.997 pessoas; 11.379 itens.

CSV exportado: `evidencias/silver_bronze_x_silver.csv` (print 8), `evidencias/silver_rejeitados_por_motivo.csv` (print 9), `evidencias/silver_sessoes_e_stitching.csv` (print 10).

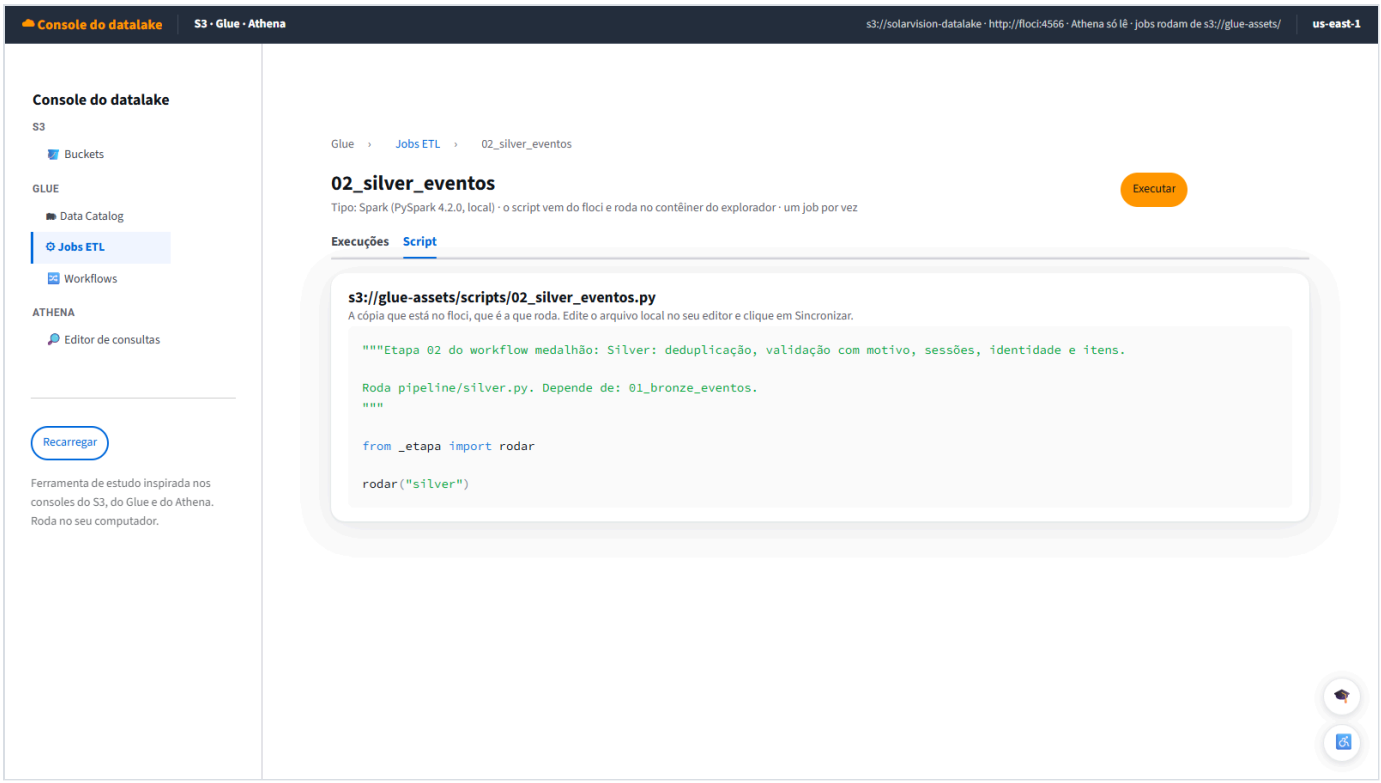
Branch: https://github.com/danieltanjos/SolarVision/tree/feat/datalake-entrega-final

1. Execução do job Silver



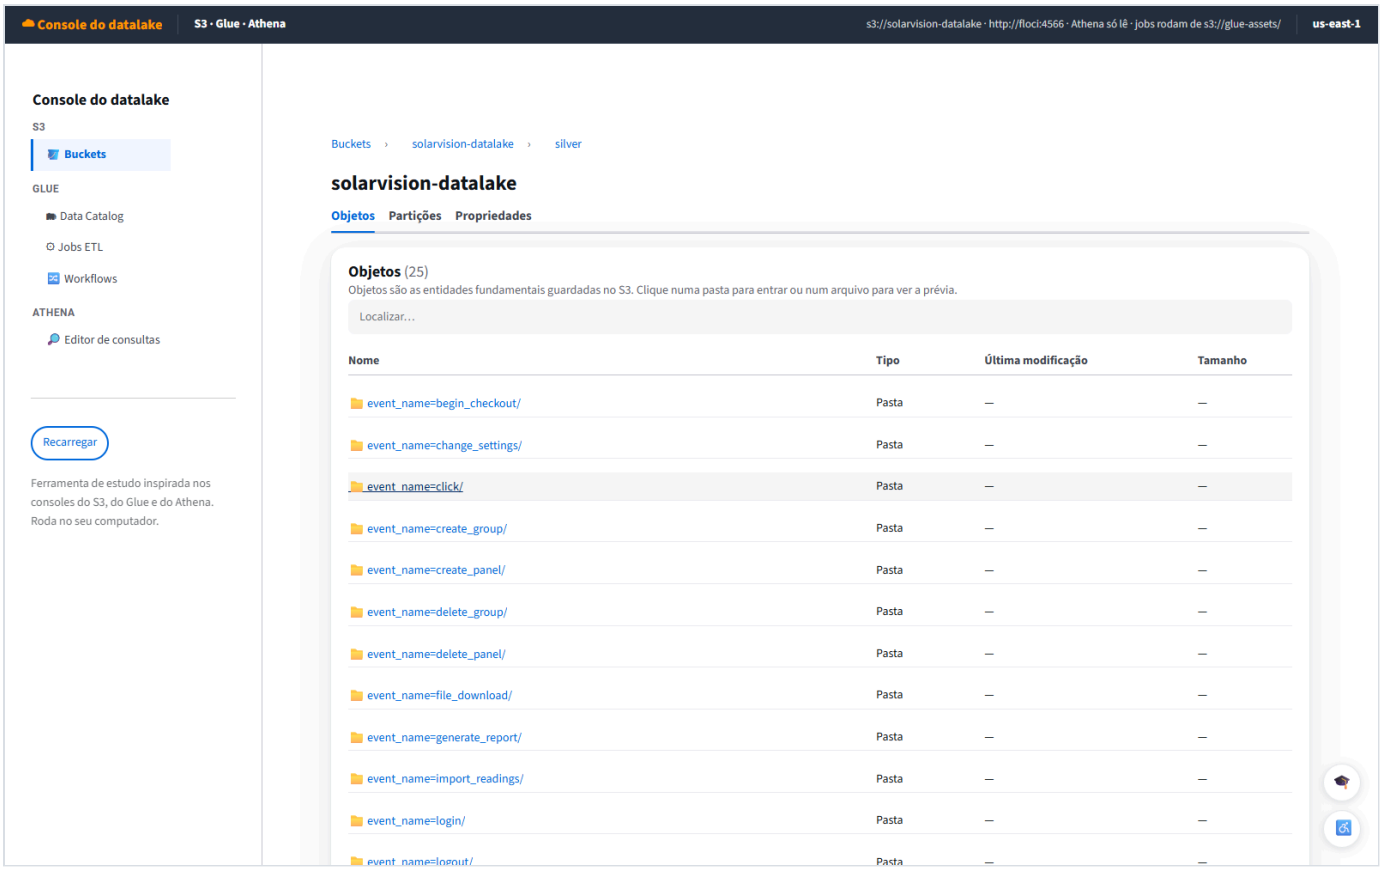
Rodado pelo workflow `medalhao`: Sucesso; o log traz as duplicatas descartadas e os rejeitados por motivo.

2. Script do job



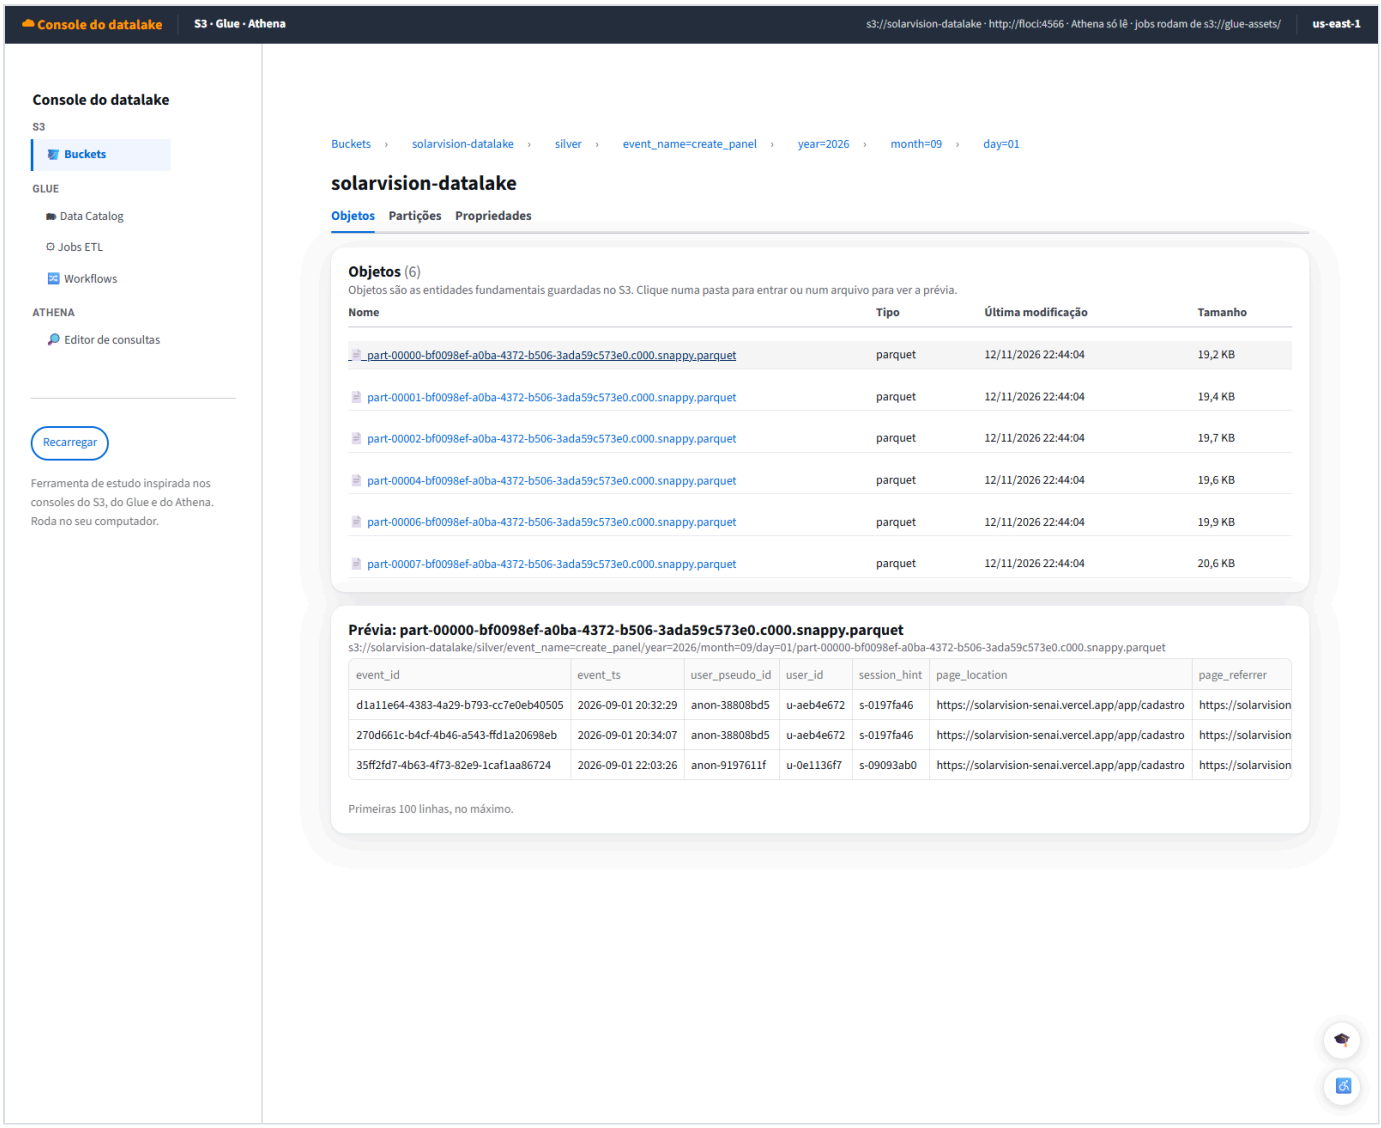
A etapa `02_silver_eventos` chama `pipeline/silver.py`.

3. S3 · silver/



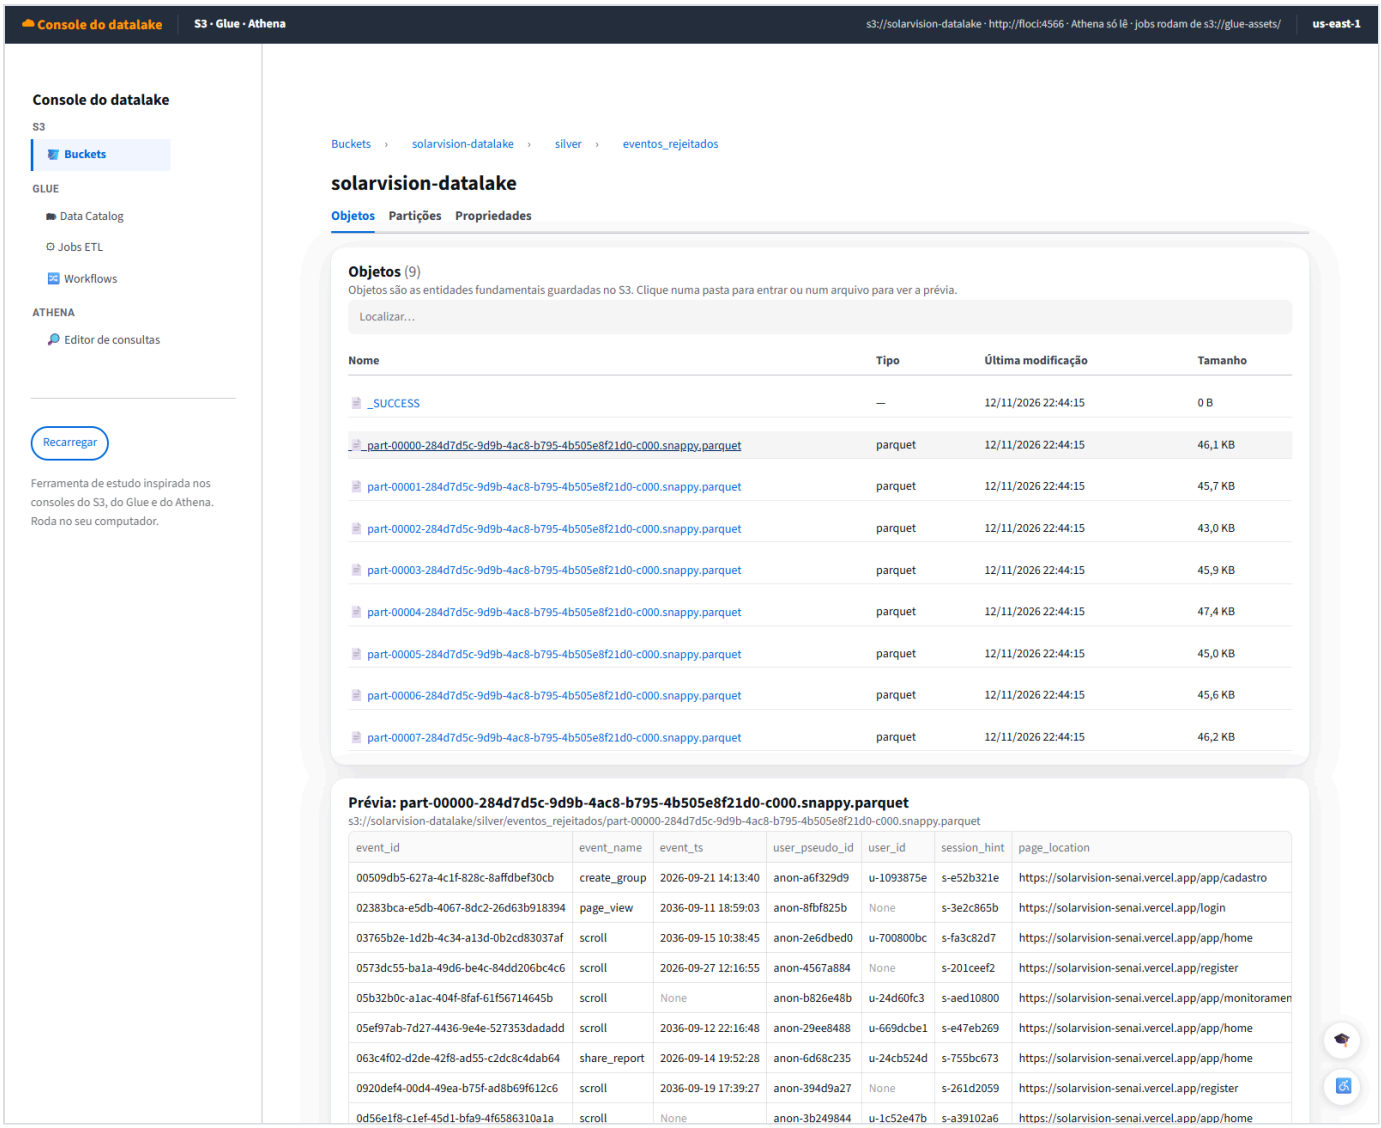
As pastas `event_name=` dos válidos e, ao lado, `itens/` e `eventos_rejeitados/`.

4. S3 · Parquet da Silver



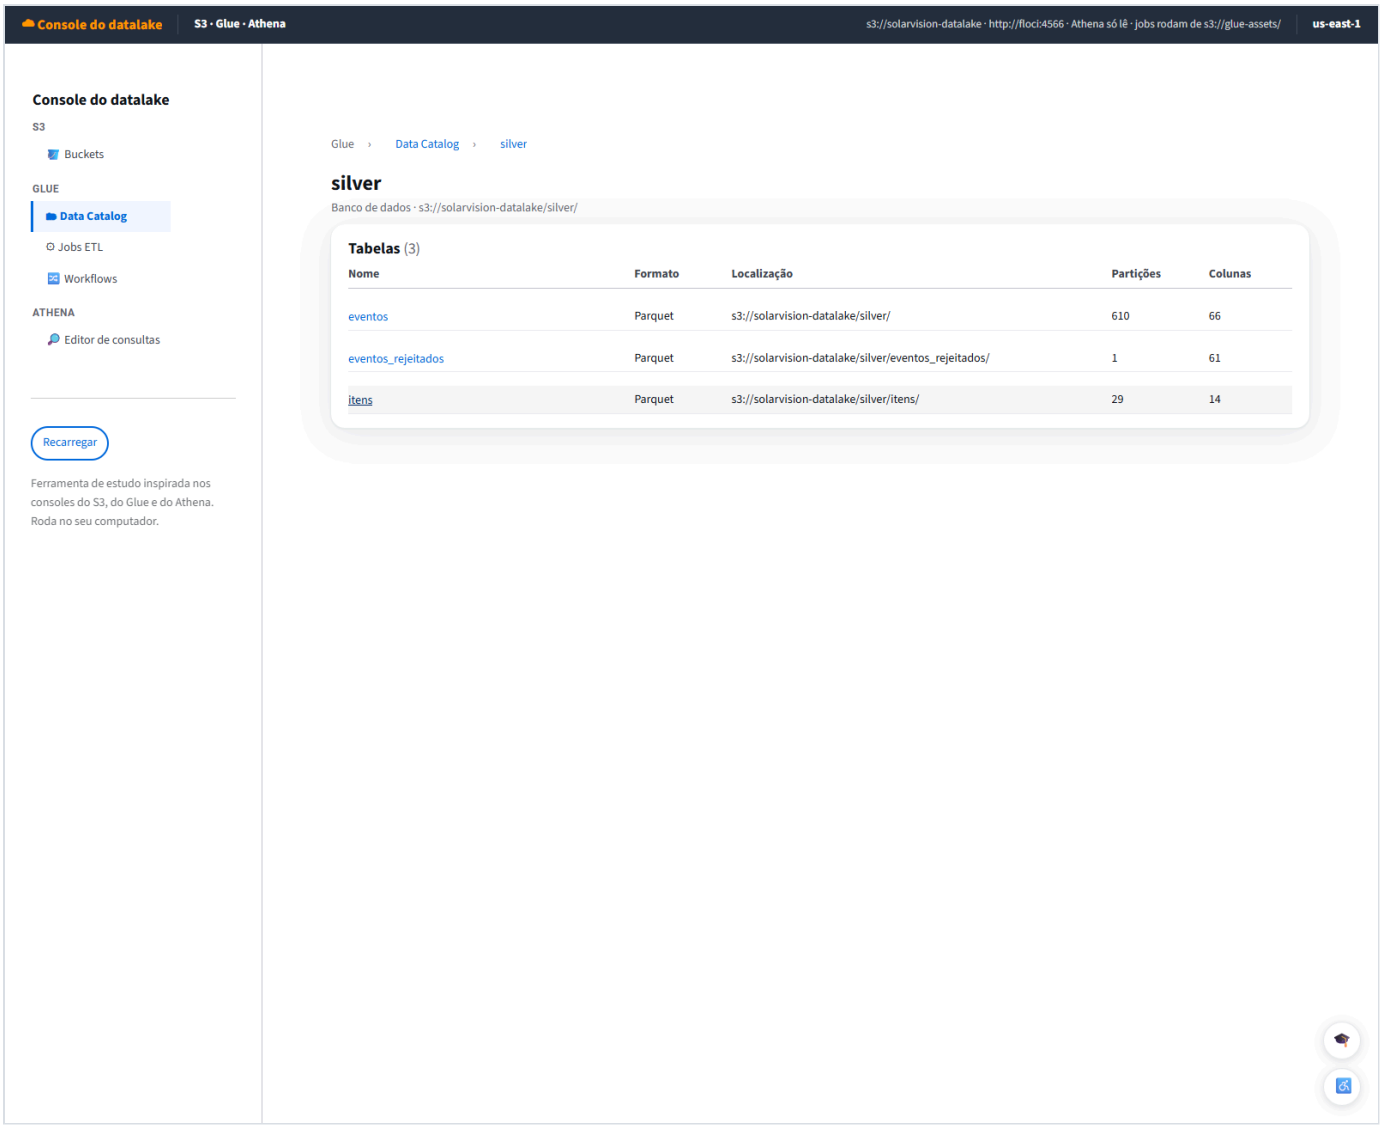
`silver/event_name=create_panel/…/day=01/` : os eventos já tipados, com `pessoa` e `sessao_id`.

5. S3 · eventos_rejeitados/



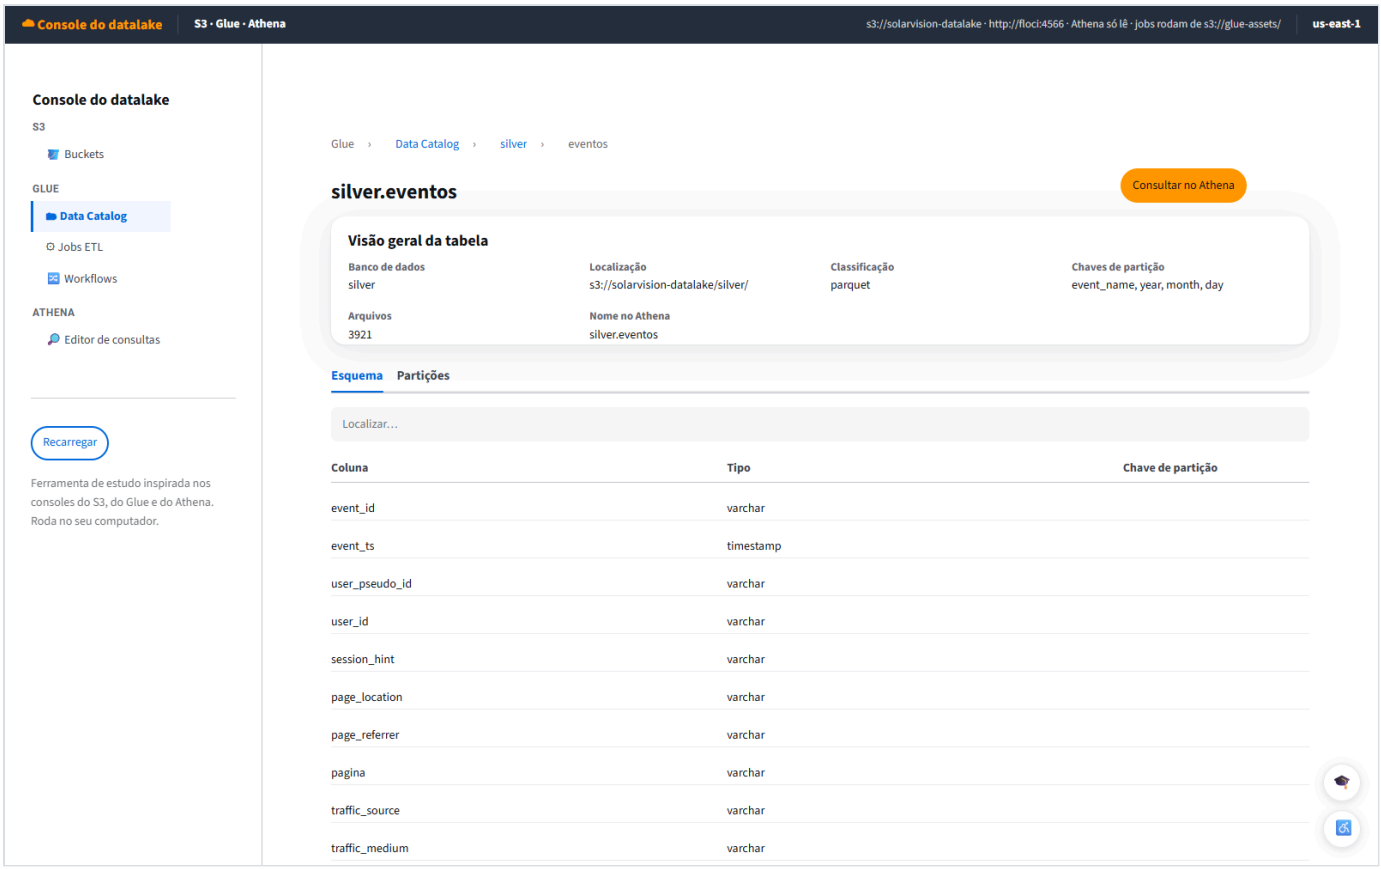
Cada evento rejeitado com o `motivo_rejeicao`.

6. Glue Data Catalog · silver



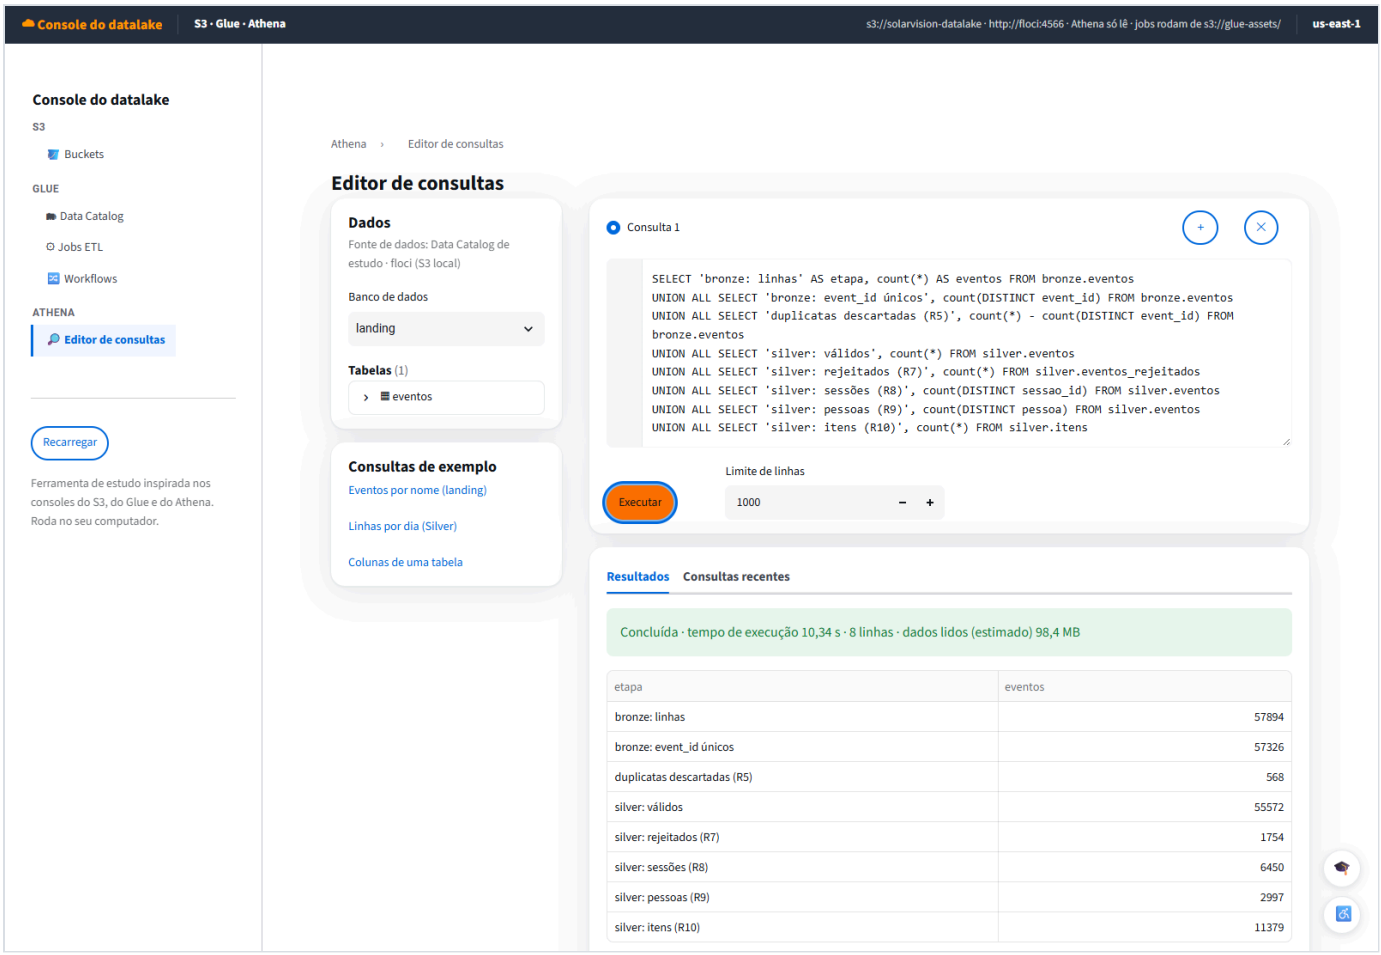
As três tabelas da Silver: `eventos`, `itens` e `eventos_rejeitados`.

7. Glue Data Catalog · silver.eventos



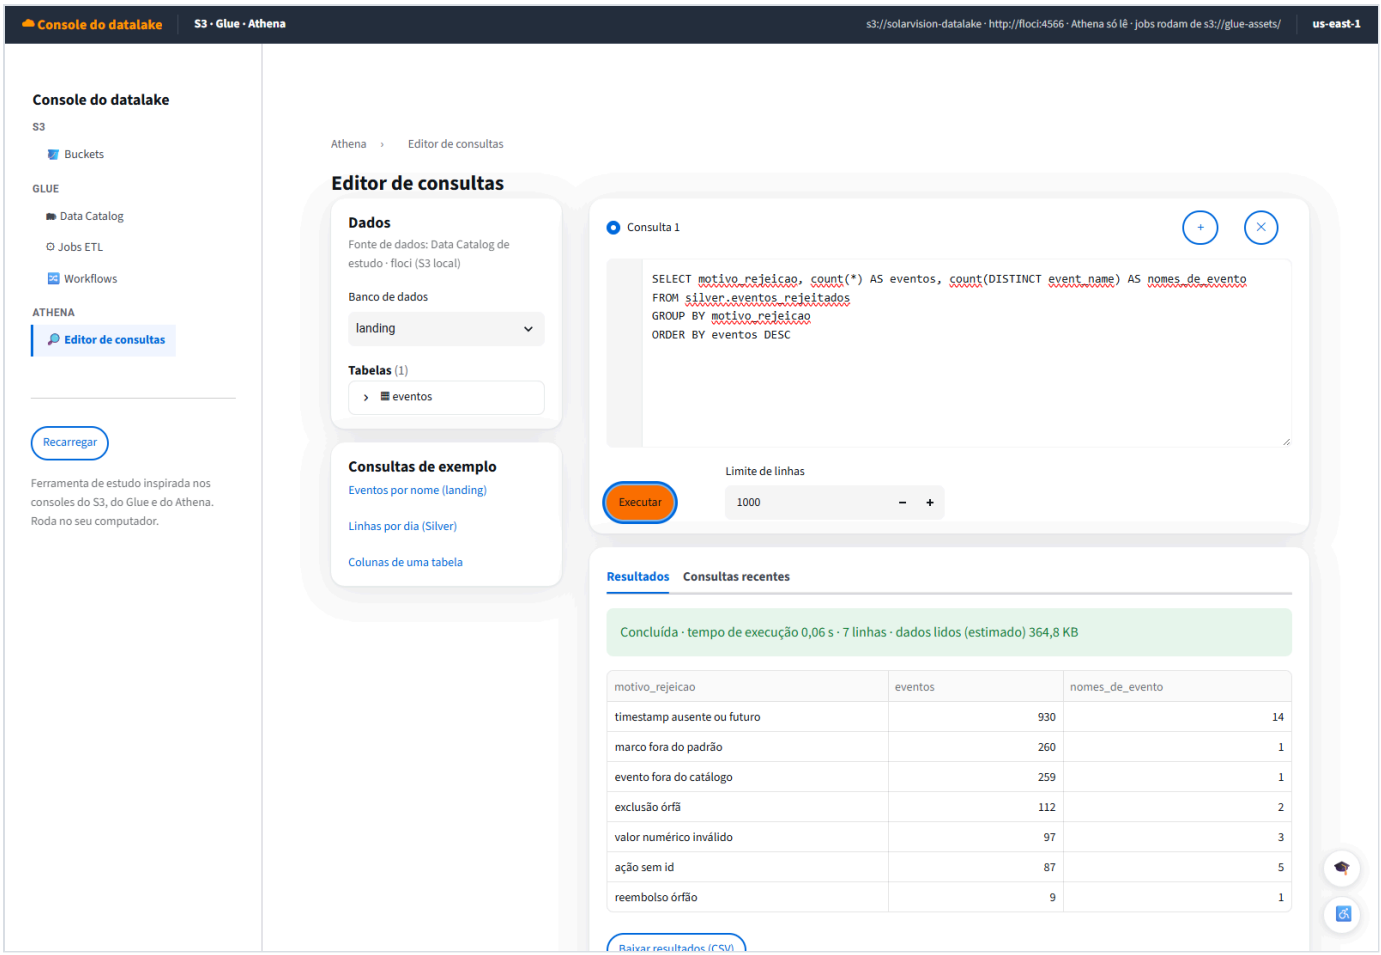
As colunas tipadas de `params` (R6), `pessoa` e `user_id_resolvido` (R9), `sessao_id`, `canal_sessao` e `dispositivo_sessao` (R8).

8. Athena · bronze x silver



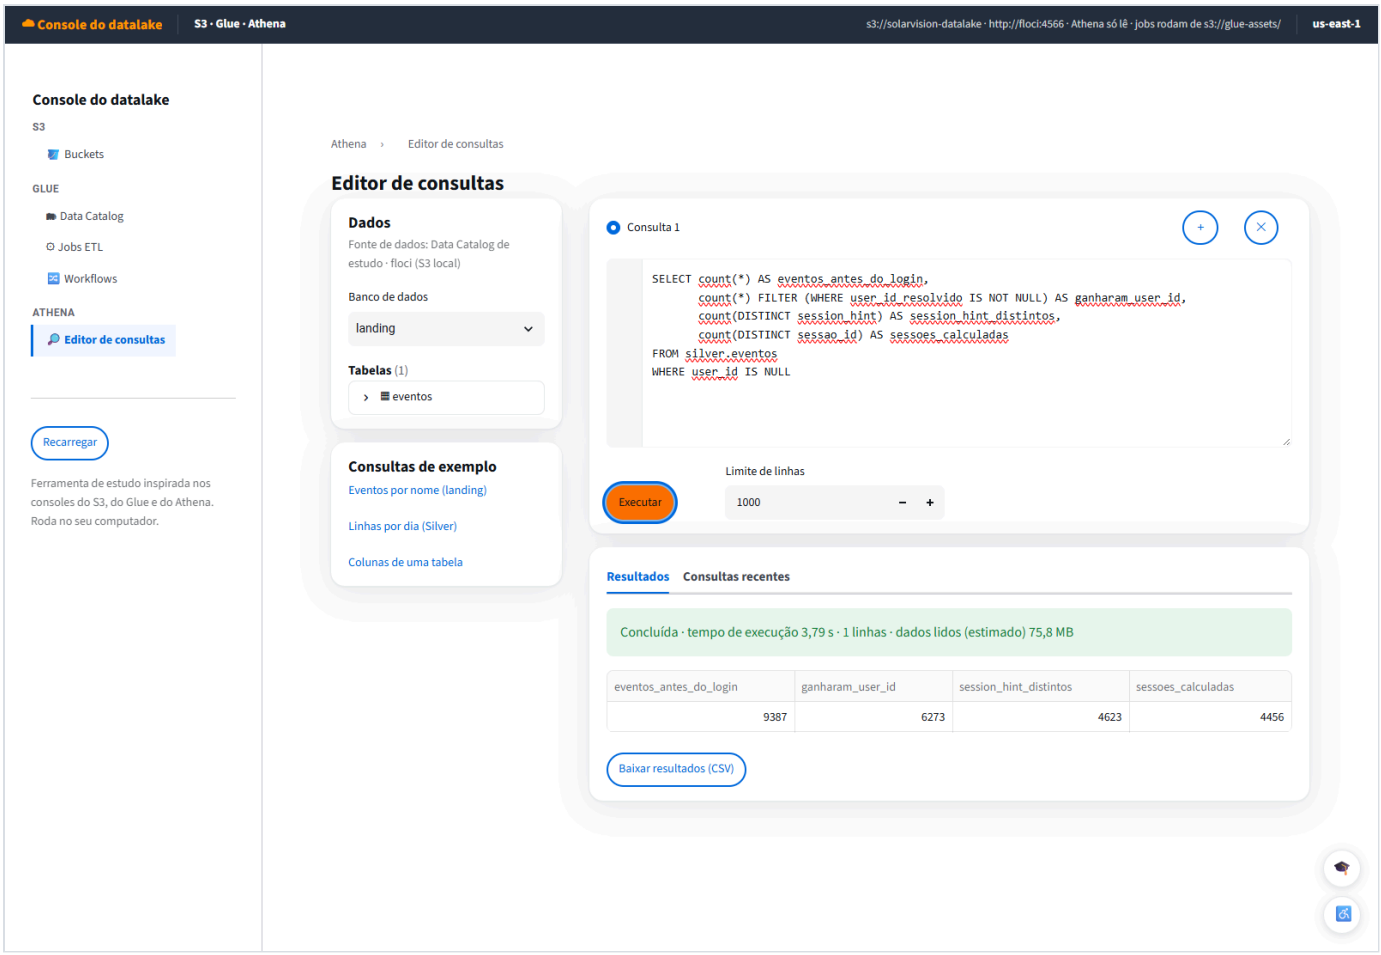
A conta fecha: 57.326 únicos = 55.572 válidos + 1.754 rejeitados; 568 duplicatas (R5).

9. Athena · rejeitados por motivo



Os sete motivos (R7). Os 112 de exclusão órfã incluem 35 exclusões legítimas de usuários antigos, discutidas no RELATORIO.md.

10. Athena · sessões e stitching



Dos 9.387 eventos sem `user_id` (antes do login), 6.273 ganharam o `user_id` pela costura (R9); nesses eventos há 4.623 `session_hint` diferentes para 4.456 sessões calculadas (R8).